

Orthogonalität

Projektion

Definition (7.2)
Eine Projektion ist eine lineare Abbildung $p: \mathbb{R}^n \rightarrow \mathbb{R}^n$, die die Eigenschaft hat, dass für jeden Vektor $\vec{x} \in \mathbb{R}^n$ gilt: $p(p(\vec{x})) = p(\vec{x})$.
Definition (7.5)
Ist P eine Matrix mit der Eigenschaft $P^2 = P$, so heißt P Projektionsmatrix .

Algorithmus (7.52): QR-Zerlegung via Householder-Spiegelungen
Eingabe: $A \in \mathbb{R}^{m \times n}$, $m \geq n$ Ausgabe: $Q \in \mathbb{R}^{m \times n}$ (orthonormale Spalten), $R \in \mathbb{R}^{n \times n}$ (obere Dreiecksmatrix), $A = QR$
1: $B \leftarrow A$ ▷ Arbeitskopie von A
2: for $k = 1$ bis n do
3: $\vec{a} \leftarrow B_{k:m, k}$ ▷ Untervektor der Länge $m - k + 1$ ab Zeile k
4: $\vec{e}_1 \leftarrow (1, 0, \dots, 0)^T \in \mathbb{R}^{m-k+1}$ ▷ Lokal – erster Einheitsvektor im Unterraum
5: $\vec{v} \leftarrow \vec{a} + \text{sign}(a_1) \cdot \vec{a} \vec{e}_1$; $\vec{u}_k \leftarrow \vec{v}/ \vec{v} $ ▷ a_1 = erste Komponente von $\vec{a}$;
6: $\vec{u}_k \in \mathbb{R}^{m-k+1}$
7: Aktualisiere den aktiven Block (nur Zeilen $k:m$, Spalten $k:n$):
8: $B_{k:m, k:n} \leftarrow (E_{m-k+1} - 2\vec{u}_k \vec{u}_k^T) B_{k:m, k:n}$
9: end for
10: $R \leftarrow B_{1:n, 1:n}$ ▷ oberer $n \times n$-Block = obere Dreiecksmatrix
11: $Q \leftarrow$ erste n Spalten von $H_1 H_2 \dots H_n$, $H_k = \begin{pmatrix} E_{k-1} & 0 \\ 0 & E_{m-k+1} - 2\vec{u}_k \vec{u}_k^T \end{pmatrix}$
In der Praxis wird Q nicht explizit aufgebaut, sondern implizit als Folge von Householder-Transformationen gespeichert.

Orthonormale Basen

Definition (7.13): Orthonormal
Eine Menge von Vektoren $\{\vec{q}_1, \dots, \vec{q}_k\} \subseteq \mathbb{R}^n$ heißt orthonormal , wenn gilt:
• Die Vektoren stehen paarweise senkrecht (orthogonal) aufeinander: Das Skalarprodukt $\langle \vec{q}_i, \vec{q}_j \rangle = \vec{q}_i^T \vec{q}_j = 0$ für alle $i \neq j$.
• Jeder Vektor hat die Länge 1: $ \vec{q}_i = \sqrt{\langle \vec{q}_i, \vec{q}_i \rangle} = 1$. Insbesondere ist dann $\langle \vec{q}_i, \vec{q}_i \rangle = \vec{q}_i^T \vec{q}_i = 1$.
Ist zusätzlich noch $k = n$, so spricht man von einer Orthonormalbasis des $\mathbb{R}^n$.
Bemerkung (7.14): Koordinaten in einer ONB
In jeder Orthonormalbasis $\{\vec{q}_1, \dots, \vec{q}_n\}$ lässt sich die Darstellung eines Vektors $\vec{x}$ als
$\vec{x} = \lambda_1 \vec{q}_1 + \dots + \lambda_n \vec{q}_n$
auf simple Skalarprodukte zurückführen: $\lambda_i = \langle \vec{x}, \vec{q}_i \rangle$

Algorithmus (7.18): Gram-Schmidtsches Orthogonalisierungsverfahren
Eingabe: Linear unabhängige Vektoren $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$ Ausgabe: Eine Orthonormalbasis $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$ von $\text{span}(\vec{v}_1, \dots, \vec{v}_n)$.
1: for $k = 1$ bis n do
2: Berechne den orthogonalen Anteil:
3: Normiere den Vektor:
4: end for
Anmerkung: Für $k = 1$ ist die Summe in Zeile 2 leer und gibt 0 zurück, d.h. $\vec{y}_1 = \vec{v}_1$ und wir normieren einfach nur ($\vec{q}_1 = \frac{\vec{v}_1}{ \vec{v}_1 }$).

Orthogonale Matrizen

Definition (7.22)
Eine Matrix $Q \in \mathbb{R}^{n \times n}$ heißt orthogonal , wenn $Q^T Q = E_n$ gilt.
Bemerkung (7.23)
Eine Matrix ist genau dann orthogonal, wenn die Spalten eine Orthonormalbasis des $\mathbb{R}^n$ bilden:
$Q^T Q = E_n \Leftrightarrow \langle \vec{q}_i, \vec{q}_i \rangle = 1 \text{ und } \langle \vec{q}_i, \vec{q}_j \rangle = 0 \text{ für } i \neq j \in \{1, \dots, n\}$ $\Leftrightarrow \{\vec{q}_1, \dots, \vec{q}_n\} \text{ ist eine Orthonormalbasis des } \mathbb{R}^n.$
Lemma (7.26)
Ist $Q \in \mathbb{R}^{n \times n}$ orthogonal, so gilt für alle $\vec{x}, \vec{y} \in \mathbb{R}^n$:
$\langle Q\vec{x}, Q\vec{y} \rangle = \langle \vec{x}, \vec{y} \rangle$
Beweis. $\langle Q\vec{x}, Q\vec{y} \rangle = (Q\vec{x})^T (Q\vec{y}) = \vec{x}^T \underbrace{Q^T Q}_{= E_n} \vec{y} = \vec{x}^T E_n \vec{y} = \vec{x}^T \vec{y} = \langle \vec{x}, \vec{y} \rangle$
Folgerung (7.27)
Für eine orthogonale Matrix $Q \in \mathbb{R}^{n \times n}$ und Vektoren $\vec{x}, \vec{y} \in \mathbb{R}^n$ gilt:
• Die Länge eines Vektors ($ Q\vec{x} = \vec{x} $) bleibt exakt gleich.
• Der Winkel zwischen $\vec{x}$ und $\vec{y}$ ist genau derselbe wie der Winkel zwischen $Q\vec{x}$ und $Q\vec{y}$.

Projektion auf Unterraum
erneute Projektion macht
nichts, da es schon darauf
projiziert wurde
→

Definition (7.38): Orthogonale Projektionsmatrix
Eine Matrix $P \in \mathbb{R}^{n \times n}$ ist eine orthogonale Projektionsmatrix , wenn sie idempotent und symmetrisch ist:
$P^2 = P \quad \text{und} \quad P = P^T$

Householdermatrix

$$H_{\vec{u}} = E_n - 2P$$

Theorem 11: Householder-Spiegelung auf die Koordinatenachse
Gegeben sei ein Spaltenvektor $\vec{a} \in \mathbb{R}^m$ mit der ersten Komponente a_1 . Wir definieren den Zielvektor auf der x-Achse als $\vec{p} = -\text{sign}(a_1) \cdot \vec{a} \vec{e}_1$, wobei
$\text{sign}(a_1) = \begin{cases} 1, & \text{falls } a_1 \geq 0 \\ -1, & \text{falls } a_1 < 0 \end{cases}$
das Vorzeichen von a_1 angibt. Wählen wir nun den Normalenvektor der Spiegelebene als die Differenz zwischen Original und Ziel:
$\vec{v} = \vec{a} - \vec{p} = \vec{a} + \text{sign}(a_1) \cdot \vec{a} \vec{e}_1, \quad \vec{u} = \frac{\vec{v}}{ \vec{v} }$
Dann gilt für die zugehörige Householder-Matrix $H = E_m - 2\vec{u}\vec{u}^T$:
$H\vec{a} = \vec{p} = -\text{sign}(a_1) \cdot \vec{a} \vec{e}_1$

Theorem 8
Jeder lineare Unterraum des $\mathbb{R}^n$ besitzt eine Orthonormalbasis.
Theorem 9
Ist $Q \in \mathbb{R}^{m \times n}$ eine Matrix mit orthonormalen Spalten, so ist $P = QQ^T$ eine orthogonale Projektionsmatrix
Theorem 10: Projektionssatz (Orthogonale Zerlegung)
Sei U ein Unterraum des $\mathbb{R}^n$ und $\vec{b} \in \mathbb{R}^n$ ein beliebiger Vektor. Dann lässt sich $\vec{b}$ eindeutig zerlegen in die Summe
$\vec{b} = \vec{b}_U + \vec{b}_{U^\perp}$
wobei $\vec{b}_U \in U$ und $\vec{b}_{U^\perp} \perp U$. Der Vektor $\vec{b}_U$ heißt orthogonale Projektion von $\vec{b}$ auf U .

Basis = min Anzahl an Vektoren (n)
durch die ein Raum $\mathbb{R}^n$ aufgespannt werden kann

Rotationsmatrix

$$Q = \begin{pmatrix} \cos \varphi & -\sin \varphi \\ \sin \varphi & \cos \varphi \end{pmatrix}$$

Spiegelungsmatrix

$$Q = \begin{pmatrix} \cos \varphi & \sin \varphi \\ \sin \varphi & -\cos \varphi \end{pmatrix}$$

← negativ unten rechts
→ meistens Spiegelung

Bemerkung (7.30)
Im $\mathbb{R}^2$ beschreiben orthogonale Matrizen <i>immer</i> exakt eine dieser beiden Operationen: Spiegelungen oder Rotationen! Das gilt im Kern auch im $\mathbb{R}^n$, ist dort aber für größere Dimensionen deutlich schwerer visuell fassbar.
Folgerung (7.31): Produkt orthogonaler Matrizen
Sind $Q_1, Q_2 \in \mathbb{R}^{n \times n}$ orthogonal, so ist auch ihr Produkt $Q_1 \cdot Q_2$ orthogonal.

Definition (7.57): Die Normalengleichungen
Für ein überbestimmtes System $A\vec{x} = \vec{b}$ finden wir die beste Approximation $\hat{\vec{x}}$ (im Sinne des geringsten quadratischen Fehlers) durch Lösen der Normalengleichungen :
$A^T A \hat{\vec{x}} = A^T \vec{b}$
Wenn die Spalten von A linear unabhängig sind, ist die quadratische Matrix $(A^T A)$ stets invertierbar, und die Lösung ist $\hat{\vec{x}} = (A^T A)^{-1} A^T \vec{b}$.

Wiederholung (7.61): Kapitelzusammenfassung: Orthogonalität

Die zentralen Ergebnisse dieses Kapitels im Überblick:

- **Projektion** ($P^2 = P$): Eine orthogonale Projektionsmatrix ist zusätzlich symmetrisch ($P = P^T$). Für eine Matrix Q mit orthonormalen Spalten gilt: $P = QQ^T$.
- **Orthonormalbasis (ONB)**: Koordinaten erhält man durch einfache Skalarprodukte $\lambda_i = \langle \vec{x}, \vec{q}_i \rangle$ – Aufwand $O(n^2)$ statt $O(n^3)$ bei beliebiger Basis. Jeder Unterraum des $\mathbb{R}^n$ besitzt eine ONB (Theorem 8).
- **Gram-Schmidt-Verfahren**: Konstruiert iterativ eine ONB aus linear unabhängigen Vektoren. Zeitkomplexität: $\Theta(mn^2)$. Numerisch instabil – in der Praxis durch Householder ersetzt.
- **Orthogonale Matrizen**: $Q^T Q = E_n \Rightarrow Q^{-1} = Q^T$ (für quadratisches Q). Geometrisch: starre Transformationen (Rotationen, Spiegelungen), die Längen und Winkel erhalten.
- **QR-Zerlegung** ($A = QR$): $Q \in \mathbb{R}^{m \times n}$ orthonormal, $R \in \mathbb{R}^{n \times n}$ obere Dreiecksmatrix. Via Gram-Schmidt oder (numerisch stabiler) Householder-Spiegelungen. Zeitkomplexität: $O(mn^2)$, für $m \gg n$ linear in der Datenmenge.
- **Methode der kleinsten Quadrate**: Überbestimmte Systeme löst man durch Projektion auf den Spaltenraum. Normalengleichungen: $A^T A \hat{\vec{x}} = A^T \vec{b}$. Numerisch stabiler via QR: $R\hat{\vec{x}} = Q^T \vec{b}$.