

INHALTSVERZEICHNIS

7. Orthogonalität	2
1. Motivation: Wie analysieren wir hochdimensionale Daten?	2
2. Orthonormale Basen: Warum senkrecht am schönsten ist	7
3. Das Gram-Schmidt-Verfahren: Wir bauen eine ONB	9
4. Orthogonale Matrizen	13
4.1. Was sind orthogonale Matrizen?	13
4.2. Orthogonale Matrizen als starre Transformationen	15
4.3. Wichtige Orthogonale Matrizen	16
5. Orthogonale Projektionen	21
5.1. Rechteckige Orthogonale Matrizen erzeugen orthogonale Projek- tionen	23
5.2. Die Geometrie der Projektion	25
5.3. Anwendung: Der schrumpfende Fehler	26
5.4. Ein neuer Blick auf alte Bekannte: Gram-Schmidt und Householder	27
6. Die QR-Zerlegung: Gram-Schmidt als Matrixgleichung	29
6.1. QR-Zerlegung über Gram-Schmidt	29
6.2. QR in der Praxis: Householder-Reflexionen	32
7. Die Methode der kleinsten Quadrate	38
7.1. Das Problem mit der Realität: Zu viele Gleichungen	38
7.2. Die geometrische Rettung: Projektionen	39
7.3. Lineare Regression	40
7.4. Für den kultivierten Data Scientist: Least Squares via QR-Zerlegung	42
A. Lösungen zu den Aktivierungsaufgaben	44
B. Beweise zu ausgewählten Sätzen	51

Kapitel 7

ORTHOGONALITÄT

1. Motivation: Wie analysieren wir hochdimensionale Daten?

Lernziele (7.1)

Nach diesem Abschnitt können Sie...

- das Problem der Verarbeitung und Visualisierung **hochdimensionaler Daten** erläutern.
- den Begriff der **Projektion** mathematisch definieren und anschaulich beschreiben.
- überprüfen und begründen, ob eine gegebene Matrix eine **Projektion** darstellt (Eigenschaft $P^2 = P$).
- das Konzept der **Koordinatendarstellung** von Vektoren bezüglich einer Basis erklären und anwenden.

In der Data Science arbeiten wir häufig mit hochdimensionalen Daten. Ein typisches Beispiel hierfür ist das im Paper *"Genes mirror geography within Europe"* (Novembre et al., 2008) beschriebene Ausgangsproblem: Im Rahmen einer Studie analysierten die Autoren Gen-Marker von 3000 Europäern und erfassten dafür pro Proband rund 500.000 Gen-Marker. Die zugehörige Datenmatrix hat also die Dimension 3000×500.000 . Doch wie können wir **solch eine riesige Matrix analysieren?**

Gelingt es uns, diesen Raum **visuell zu begreifen oder mathematisch effizient darin zu navigieren?** Nein. Wir müssen die **Daten irgendwie in eine niedrige Dimension projizieren, um sie für uns greifbar zu machen**. Die Autoren nutzten dafür eine sogenannte **Hauptkomponentenanalyse (PCA)**. Diese findet zu gegebener Dimension k (hier: $k = 2$) eine Menge von k linear unabhängigen Vektoren, so dass die Projektion der Daten auf den von diesen Vektoren erzeugten Unterraum möglichst viel der ursprünglichen Informationen erhält. Für die Gen-Analyse ergibt sich ein verblüffendes Bild: Die rein genetischen Datenwolken gruppieren sich plötzlich geometrisch exakt so, wie die Landkarte Europas aussieht!




Abbildung 7.1. Gen-Analyse mittels PCA. Quelle: Novembre et al., Nature 456, 98–101.

Abbildung 7.1 zeigt die Projektion der Gen-Daten in einen zwei-dimensionalen Unterraum; die Achsen PC1 und PC2 werden durch zwei Basisvektoren des Unterraums erzeugt. Wichtig: Wir sind eigentlich immer noch im $\mathbb{R}^{500000}$, aber durch die Einschränkung auf 2 Basisvektoren können wir die Datenpunkte in 2D visualisieren: Wir fassen die Richtungen der Basisvektoren als „Achsen“ auf und beschreiben jeden ursprünglichen Probanden gemäß der Achsen (z.B. sehen wir, dass die spanischen Probanden *ES* im dritten Quadranten liegen, d.h. sie ergeben sich durch eine negative Koordinate bezüglich PC1 und PC2).

Was bedeutet „Projektion“?

Die Idee hinter einer Projektion ist es, hochdimensionale Vektoren auf einen Unterraum abzubilden und dabei möglichst viele Informationen zu erhalten. Insbesondere soll die Projektion lineare Beziehungen zwischen Datenpunkten unverändert lassen: Liegt beispielsweise $\vec{y}$ auf halber Strecke zwischen $\vec{x}$ und $\vec{z}$, d.h. $\vec{y} = \frac{1}{2}(\vec{x} + \vec{z})$, so soll auch $p(\vec{y})$ auf halber Strecke zwischen $p(\vec{x})$ und $p(\vec{z})$ liegen. Abbildung 7.2 zeigt die Projektion von 2-dimensionalen Datenpunkten auf 1-dimensionale Unterräume: die x -Achse, die y -Achse und auf die Gerade $y = x$. Mathematisch stellen wir folgende Anforderungen an eine Projektion:

Definition (7.2)

Eine **Projektion** ist eine **lineare Abbildung** $p : \mathbb{R}^n \rightarrow \mathbb{R}^n$, die die Eigenschaft hat, dass für jeden Vektor $\vec{x} \in \mathbb{R}^n$ gilt: $p(p(\vec{x})) = p(\vec{x})$.




Abbildung 7.2. Projektion auf die x -Achse, die y -Achse und auf die Ursprungsgerade $y = x$.

- **Lineare Abbildung** heißt: $p(a\vec{x} + b\vec{y}) = ap(\vec{x}) + bp(\vec{y})$ für alle $\vec{x}, \vec{y} \in \mathbb{R}^n$ und $a, b \in \mathbb{R}$. Genau diese Eigenschaft stellt sicher, dass die Projektion lineare Beziehungen zwischen Datenpunkten erhält.
- Wieso die Bedingung $p(p(\vec{x})) = p(\vec{x})$? Nachdem wir einen Vektor auf einen Unterraum projiziert haben, liegt er ja bereits in diesem. Wenn wir ihn erneut projizieren, ändern wir ihn nicht mehr. Er bleibt, wo er ist. Das ist die Essenz der Projektion.
- Wieso $\mathbb{R}^n \rightarrow \mathbb{R}^n$? Der Vektor hat danach immer noch genauso viele Komponenten wie vorher, aber liegt in einem Unterraum. Hat der Unterraum beispielsweise die Dimension 2, dann können wir den Vektor durch 2 Basisvektoren beschreiben. Zur Visualisierung nutzen wir dann einfach die Basisvektoren als Achsen.

Wir können jede lineare Abbildung durch eine Matrix beschreiben, indem wir die Bilder der Standardbasisvektoren als Spalten der Matrix verwenden:

Beispiel (7.3)

Sei $p: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ definiert durch $p(\vec{x}) = \begin{pmatrix} x_1 \\ 0 \end{pmatrix}$ (Projektion auf die x -Achse). Dann gilt:

$$\begin{aligned} p(\vec{e}_1) &= p\left(\begin{pmatrix} 1 \\ 0 \end{pmatrix}\right) = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ p(\vec{e}_2) &= p\left(\begin{pmatrix} 0 \\ 1 \end{pmatrix}\right) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \end{aligned}$$

Die Matrix P der Projektion p ist damit

$$P = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

Die Matrix P erhält die erste Komponente des Vektors und setzt die zweite auf 0.

Aufgabe (7.4)

Verifizieren Sie, dass für jeden Vektor $\vec{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ gilt: $p(\vec{x}) = P\vec{x}$.

Doch wie erkennen wir, ob durch eine Matrix P wirklich eine Projektion beschrieben wird? Die Antwort ist einfach: Wir überprüfen, ob $P^2 = P$: Da $p(p(\vec{x})) = P(P\vec{x}) = P^2\vec{x}$, muss $P^2\vec{x} = P\vec{x}$ für alle $\vec{x}$ gegeben sein. Das ist äquivalent zu $P^2 = P$.

Definition (7.5)

Ist P eine Matrix mit der Eigenschaft $P^2 = P$, so heißt P **Projektionsmatrix**.

Aufgabe (7.6)

Wir betrachten die Projektion auf die Ursprungsgerade $y = x$ aus Abbildung 7.2, die durch die folgende Vorschrift definiert ist:

$$p\left(\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}\right) = \begin{pmatrix} \frac{x_1+x_2}{2} \\ \frac{x_1+x_2}{2} \end{pmatrix}.$$

Bestimmen Sie die Projektionsmatrix P , indem Sie als Spalten von P die Bilder der Standardbasisvektoren $\vec{e}_1$ und $\vec{e}_2$ einsetzen, und überprüfen Sie, ob $P^2 = P$ gilt.

Wie visualisieren wir die Projektion?

Selbst wenn wir einen Vektor $\vec{x} \in \mathbb{R}^{500000}$ auf einen 2-dimensionalen Unterraum projizieren, hat der resultierende Vektor $p(\vec{x})$ danach immer noch 500000 Komponenten. Der Schlüssel dazu, ihn zu visualisieren, liegt darin, dass wir ihn durch 2 Basisvektoren $\vec{b}_1$ und $\vec{b}_2$ beschreiben können:

$$p(\vec{x}) = \alpha \cdot \vec{b}_1 + \beta \cdot \vec{b}_2$$

In der Abbildung können wir dann $\vec{b}_1$ und $\vec{b}_2$ als Achsen auffassen, und α und β als Koordinaten bezüglich dieser Achsen.

Beispiel (7.7): Visualisierung durch Koordinaten im $\mathbb{R}^4$


Wir betrachten einen 2-dimensionalen Unterraum des $\mathbb{R}^4$, aufgespannt durch die Basisvektoren

$$\vec{b}_1 = (1, 1, 0, 0)^T \quad \text{und} \quad \vec{b}_2 = (0, 0, 1, -1)^T.$$

Jeder Vektor $\vec{v}$ in diesem Unterraum lässt sich als Linearkombination dieser Basisvektoren darstellen, zum Beispiel:

$$\vec{v} = (3, 3, -2, 2)^T = 3 \cdot \vec{b}_1 - 2 \cdot \vec{b}_2.$$

Wenngleich $\vec{v}$ ein 4-dimensionaler Vektor ist, benötigen wir zur Beschreibung innerhalb des Unterraums nur die **Koordinaten** 3 und -2 bezüglich der Basis $\{\vec{b}_1, \vec{b}_2\}$. Zeichnen wir ein 2D-Koordinatensystem, in dem $\vec{b}_1$ und $\vec{b}_2$ die Achsen darstellen, können wir den Vektor $\vec{v}$ dort einfach als den Punkt $(3, -2)$ visualisieren:



Projizieren wir auf einen 2-dimensionalen Unterraum, haben wir viele Möglichkeiten, eine Basis zu wählen. Für den Unterraum

$$U = \text{span} \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\}$$

(entspricht der $x-y$ -Ebene im $\mathbb{R}^3$) könnten wir beispielsweise folgende Basen wählen:

$$\mathcal{B}_0 = \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\}, \quad \mathcal{B}_1 = \left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix} \right\}, \quad \mathcal{B}_2 = \left\{ \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} \right\}, \quad (7.1)$$

oder jede andere Menge von zwei Vektoren aus dem $\mathbb{R}^3$ – solange diese beiden linear unabhängig sind und z -Koordinate Null haben. Doch was kennzeichnet eine *gute* Basis? Das herauszufinden, ist das Ziel des nächsten Abschnitts.

Aufgabe (7.8)

Bestimmen Sie die Koordinaten des Vektors $\vec{x} = (2, 4, 0)^T$ bezüglich der Basisvektoren der Basen $\mathcal{B}_0$, $\mathcal{B}_1$ und $\mathcal{B}_2$ aus (7.1). Welche Basis gefällt Ihnen am besten?

Hinweis: Gesucht sind also Skalare λ_1, λ_2 mit $\vec{x} = \lambda_1 \vec{b}_1 + \lambda_2 \vec{b}_2$. Dies entspricht dem Lösen eines linearen Gleichungssystems (mittels Gauß-Algorithmus oder LR-Zerlegung).

2. Orthonormale Basen: Warum senkrecht am schönsten ist

Lernziele (7.9)

Nach diesem Abschnitt können Sie...

- die Koordinaten eines Vektors bezüglich einer gegebenen Basis über ein LGS bestimmen,
- den Rechenaufwand für die Koordinatenbestimmung in Abhängigkeit von der Basis abschätzen,
- den Begriff der Orthonormalbasis erklären und
- die Koordinaten eines Vektors bezüglich einer Orthonormalbasis über Skalarprodukte berechnen.

Wie Ihnen in der Aufgabe vielleicht aufgefallen ist, kann es – je nach Wahl der Basis – ziemlich unangenehm werden, die Koordinaten eines Vektors bezüglich der gegebenen Basis zu bestimmen. Wollen wir allgemein einen Vektor $\vec{x}$ als Linearkombination von Basisvektoren $\mathcal{B} = \{\vec{b}_1, \dots, \vec{b}_n\}$ aufschreiben, so suchen wir nach Koeffizienten λ_i (den sogenannten Koordinaten), sodass gilt:

$$\vec{x} = \lambda_1 \vec{b}_1 + \lambda_2 \vec{b}_2 + \dots + \lambda_n \vec{b}_n \quad (7.2)$$

Dies entspricht dem Lösen des linearen Gleichungssystems

$$\begin{pmatrix} b_{1,1} & b_{2,1} & \dots & b_{n,1} \\ b_{1,2} & b_{2,2} & \dots & b_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ b_{1,n} & b_{2,n} & \dots & b_{n,n} \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_n \end{pmatrix} = \vec{x}$$

Wollen wir nur die Koordinaten von einem Vektor $\vec{x}$ bestimmen, so können wir den Gauß-Algorithmus anwenden – bei vielen Vektoren ist es effizienter, die LR-Zerlegung zu verwenden. Aber wie effizient ist das wirklich?

Aufgabe (7.10)

Erinnern Sie sich: Wie teuer ist das Lösen eines linearen Gleichungssystems mit n Gleichungen? Welche Zeitkomplexität hat die LR-Zerlegung? Was kostet Vorwärts- und Rückwärtssubstitution? Berechnen Sie den Gesamtaufwand für die Koordinatenbestimmung eines Vektors bezüglich einer beliebigen Basis.

Gibt es Basen, für die die Koordinatenbestimmung effizienter durchgeführt werden kann? Der Schlüssel sind zwei simple Eigenschaften: Wir müssen fordern, dass die Basisvektoren **senkrecht** aufeinander stehen und die **Länge 1** haben.

Ist $\mathcal{B} = \{\vec{b}_1, \dots, \vec{b}_n\}$ eine solche Basis, so wird Problem (7.2) deutlich einfacher: Multiplizieren wir beide Seiten von links mit $\vec{b}_1^T$ (d.h., wir bilden das Skalarprodukt $\langle \vec{b}_1, \vec{x} \rangle$), so ergibt sich

$$\begin{aligned} \vec{b}_1^T \vec{x} &= \vec{b}_1^T (\lambda_1 \vec{b}_1 + \lambda_2 \vec{b}_2 + \dots + \lambda_n \vec{b}_n) \\ &= \lambda_1 \underbrace{\vec{b}_1^T \vec{b}_1}_{=1 \text{ (da Länge 1)}} + \lambda_2 \underbrace{\vec{b}_1^T \vec{b}_2}_{=0 \text{ (da senkrecht)}} + \dots + \lambda_n \underbrace{\vec{b}_1^T \vec{b}_n}_{=0 \text{ (da senkrecht)}} \\ &= \lambda_1, \end{aligned}$$

der Koeffizient λ_1 ist also einfach das Skalarprodukt von $\vec{x}$ mit $\vec{b}_1$! Analog erhalten wir alle anderen Koeffizienten, indem wir mit den entsprechenden Basisvektoren multiplizieren.

Aufgabe (7.11)

Vergleichen Sie: Was ist der Rechenaufwand für die Koeffizientenbestimmung bei einer beliebigen Basis und was bei einer Orthonormalbasis?

Aufgabe (7.12)

Verifizieren Sie, dass sich die Koordinaten des Vektors $\vec{x} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix}$ bezüglich der Basis $\mathcal{B}_2$ in (7.1) aus den Skalarprodukten von $\vec{x}$ mit den Basisvektoren berechnen lassen.

Wollen wir also die Koordinaten für viele Vektoren bezüglich derselben Basis bestimmen, so ist es deutlich einfacher, wenn wir eine sogenannte **Orthonormalbasis** haben.

Definition (7.13): Orthonormal

Eine Menge von Vektoren $\{\vec{q}_1, \dots, \vec{q}_k\} \subseteq \mathbb{R}^n$ heißt **orthonormal**, wenn gilt:

- Die Vektoren stehen paarweise senkrecht (orthogonal) aufeinander: Das Skalarprodukt $\langle \vec{q}_i, \vec{q}_j \rangle = \vec{q}_i^T \vec{q}_j = 0$ für alle $i \neq j$.
- Jeder Vektor hat die Länge 1: $|\vec{q}_i| = \sqrt{\langle \vec{q}_i, \vec{q}_i \rangle} = 1$. Insbesondere ist dann $\langle \vec{q}_i, \vec{q}_i \rangle = \vec{q}_i^T \vec{q}_i = 1$.

Ist zusätzlich noch $k = n$, so spricht man von einer **Orthonormalbasis** des $\mathbb{R}^n$.

Bemerkung (7.14): Koordinaten in einer ONB

In jeder Orthonormalbasis $\{\vec{q}_1, \dots, \vec{q}_n\}$ lässt sich die Darstellung eines Vektors $\vec{x}$ als

$$\vec{x} = \lambda_1 \vec{q}_1 + \dots + \lambda_n \vec{q}_n$$

auf simple Skalarprodukte zurückführen:

$$\lambda_i = \langle \vec{x}, \vec{q}_i \rangle$$

Aufgabe (7.15): Aktivierung: Koordinaten berechnen

Gegeben ist folgende Basis des $\mathbb{R}^3$: $\mathcal{B} = \{\vec{q}_1, \vec{q}_2, \vec{q}_3\}$ mit

$$\vec{q}_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \quad \vec{q}_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}, \quad \vec{q}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

- Verifizieren Sie, dass es sich um eine Orthonormalbasis handelt.
- Finden Sie die Basis-Koordinaten λ_1, λ_2 und λ_3 für den Vektor $\vec{x} = \begin{pmatrix} 0 \\ 3 \\ 0 \end{pmatrix}$.

3. Das Gram-Schmidt-Verfahren: Wir bauen eine ONB

Lernziele (7.16)

Nach diesem Abschnitt können Sie...

- das Gram-Schmidt-Verfahren anwenden, um aus einer Menge von linear unabhängigen Vektoren eine Orthonormalbasis zu konstruieren.
- erläutern, was die einzelnen Schritte im Gram-Schmidtschen Orthogonalisierungsverfahren bewirken.

Wir wissen jetzt: **Orthonormalbasen sind die besten Basen!** Aber wie bekommen wir eine? In der Wildnis der Daten, etwa bei unserer Genetik-PCA, fallen uns Vektoren nicht in perfekten rechten Winkeln in den Schoß. Wir starten meist mit einer Menge gewöhnlicher, linear unabhängiger Vektoren $\vec{v}_1, \vec{v}_2, \vec{v}_3, \dots$, die irgendwie schief zueinander im Raum stehen, und wollen daraus Schritt für Schritt senkrechte (orthogonale), normierte Vektoren $\vec{q}_1, \vec{q}_2, \vec{q}_3, \dots$ bauen.

Der Mechanismus, welcher uns zu einer Orthonormalbasis verhilft, ist das sogenannte **Gram-Schmidt-Verfahren**. Wir gehen iterativ vor – einen Vektor nach dem anderen:

Beispiel (7.17): Gram-Schmidt in $\mathbb{R}^3$

Wir starten mit drei linear unabhängigen Vektoren:

$$\vec{v}_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \vec{v}_2 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \quad \vec{v}_3 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}$$

Schritt 1: Der erste Vektor


Wir nehmen die Richtung von $\vec{v}_1$ und normieren ihn auf Länge 1. Da $|\vec{v}_1| = \sqrt{1^2 + 1^2 + 0^2} = \sqrt{2}$, ergibt sich:

$$\vec{q}_1 = \frac{\vec{v}_1}{|\vec{v}_1|} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

Schritt 2: Der zweite Vektor

Nun entfernen wir aus $\vec{v}_2$ den Anteil, der bereits durch $\vec{q}_1$ abgedeckt ist. Doch wie finden wir diesen? Die Idee ist, dass sich $\vec{v}_2$ aus zwei Teilen zusammensetzt: einer zeigt in Richtung $\vec{q}_1$, und einer orthogonal dazu:

$$\vec{v}_2 = \lambda_1 \vec{q}_1 + \vec{y}_2 \text{ mit } \langle \vec{y}_2, \vec{q}_1 \rangle = 0$$



Den Koeffizienten λ_1 erhalten wir durch

$$\lambda_1 = \langle \vec{v}_2, \vec{q}_1 \rangle = \frac{1}{\sqrt{2}}(1 \cdot 1 + 0 \cdot 1 + 1 \cdot 0) = \frac{1}{\sqrt{2}}$$

(Beweis in der Vorlesung!). Wir ziehen diesen Anteil ab und erhalten den orthogonalen Rest $\vec{y}_2$:

$$\vec{y}_2 = \vec{v}_2 - \langle \vec{v}_2, \vec{q}_1 \rangle \vec{q}_1 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/2 \\ -1/2 \\ 1 \end{pmatrix}$$

Wir normieren $\vec{y}_2$. Die Länge ist $|\vec{y}_2| = \sqrt{\frac{1}{4} + \frac{1}{4} + 1} = \frac{\sqrt{6}}{2}$:


$$\vec{q}_2 = \frac{\vec{y}_2}{|\vec{y}_2|} = \frac{2}{\sqrt{6}} \begin{pmatrix} 1/2 \\ -1/2 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}$$

Damit haben wir unseren zweiten Basisvektor! Überprüfen Sie sicherheitshalber noch einmal: steht $\vec{q}_2$ senkrecht auf $\vec{q}_1$?

Schritt 3: Der dritte Vektor

$\vec{v}_3$ besitzt nun Anteile in Richtung beider bereits etablierter Basisvektoren $\vec{q}_1$ und $\vec{q}_2$. Wir zerlegen $\vec{v}_3$ in einen Anteil, der flach in der Ebene $U = \text{span}(\vec{q}_1, \vec{q}_2)$ liegt, und einen dazu senkrechten Rest $\vec{y}_3$:

$$\vec{v}_3 = \underbrace{\lambda_1 \vec{q}_1 + \lambda_2 \vec{q}_2}_{\text{Projektion } \vec{p}_3 \in U} + \vec{y}_3 \quad \text{mit } \vec{y}_3 \perp \vec{q}_1 \text{ und } \vec{y}_3 \perp \vec{q}_2.$$



Die Koeffizienten ergeben sich durch Skalarprodukte: $\langle \vec{v}_3, \vec{q}_1 \rangle = \frac{1}{\sqrt{2}}$ und $\langle \vec{v}_3, \vec{q}_2 \rangle = \frac{1}{\sqrt{6}}$. Nun bilden wir den orthogonalen Rest $\vec{y}_3$:

$$\vec{y}_3 = \vec{v}_3 - \langle \vec{v}_3, \vec{q}_1 \rangle \vec{q}_1 - \langle \vec{v}_3, \vec{q}_2 \rangle \vec{q}_2 = \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} - \frac{1}{6} \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix} = \begin{pmatrix} -2/3 \\ 2/3 \\ 2/3 \end{pmatrix}$$

Die Länge dieses Vektors ist $|\vec{y}_3| = \sqrt{\frac{4}{9} + \frac{4}{9} + \frac{4}{9}} = \frac{2\sqrt{3}}{3}$. Wir normieren ihn zum finalen Vektor $\vec{q}_3$:

$$\vec{q}_3 = \frac{\vec{y}_3}{|\vec{y}_3|} = \frac{3}{2\sqrt{3}} \begin{pmatrix} -2/3 \\ 2/3 \\ 2/3 \end{pmatrix} = \frac{1}{\sqrt{3}} \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}$$

Damit haben wir eine perfekte Orthonormalbasis $\{\vec{q}_1, \vec{q}_2, \vec{q}_3\}$ konstruiert!

Hinweise:

- Überprüfen Sie, dass $\vec{q}_3$ tatsächlich senkrecht auf $\vec{q}_1$ und $\vec{q}_2$ steht.
- Wieso sich die Anteile in Richtung $\vec{q}_j$ durch $\langle \vec{v}_k, \vec{q}_j \rangle$ berechnen lassen, fällt hier vom Himmel und wird in der Vorlesung aufgeklärt.

Dieses Verfahren funktioniert auch in beliebig hohen Dimensionen:

Algorithmus (7.18): Gram-Schmidtsches Orthogonalisierungsverfahren

Eingabe: Linear unabhängige Vektoren $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$

Ausgabe: Eine Orthonormalbasis $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$ von $\text{span}(\vec{v}_1, \dots, \vec{v}_n)$.

1: **for** $k = 1$ **bis** n **do**

2: Berechne den orthogonalen Anteil:

$$\vec{y}_k = \vec{v}_k - \sum_{j=1}^{k-1} \left(\vec{q}_j^T \vec{v}_k \right) \vec{q}_j$$

3: Normiere den Vektor:

$$\vec{q}_k = \frac{\vec{y}_k}{|\vec{y}_k|}$$

4: **end for**

Anmerkung: Für $k = 1$ ist die Summe in Zeile 2 leer und gibt 0 zurück, d.h. $\vec{y}_1 = \vec{v}_1$ und wir normieren einfach nur ($\vec{q}_1 = \frac{\vec{v}_1}{|\vec{v}_1|}$).

Aus der Korrektheit des Gram-Schmidt Verfahrens folgt sofort:

Theorem 8

Jeder lineare Unterraum des $\mathbb{R}^n$ besitzt eine Orthonormalbasis.

Beweis: Siehe Appendix B.

Aufgabe (7.19): Aktivierung: Gram-Schmidt zum Mitrechnen

Wir starten mit zwei linear unabhängigen Vektoren: $\vec{v}_1 = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$ und $\vec{v}_2 = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$.

Berechnen Sie mit dem Gram-Schmidt-Verfahren eine Orthonormalbasis $\vec{q}_1, \vec{q}_2$ des von $\vec{v}_1$ und $\vec{v}_2$ aufgespannten Unterraums.

Bemerkung (7.20)

Die Schönheit des Gram-Schmidt-Verfahrens liegt darin, dass wir in jedem Schritt nachvollziehen können, was passiert: Wir entziehen dem Vektor $\vec{v}_k$ alle Anteile, die in Richtung der bereits gefundenen Basisvektoren $\vec{q}_1, \dots, \vec{q}_{k-1}$ zeigen. Was übrig bleibt, ist der Teil des Vektors, der wirklich neu und orthogonal zu allem bisher Dagewesenen ist.

Der Nachteil des hier vorgestellten **klassischen Gram-Schmidt-Verfahrens** ist die numerische Instabilität: Wegen Rundungsfehlern ist der Vektor $\vec{y}_k$ nach der Berechnung

nicht zwingend exakt orthogonal zu $\vec{q}_1, \dots, \vec{q}_{k-1}$. Eine einfache Abhilfe schafft das **modifizierte Gram-Schmidt-Verfahren**: Statt alle Projektionen in einem Schritt abzuziehen, wird $\vec{v}_k$ sequenziell orthogonalisiert – nach dem Abziehen des $\vec{q}_1$ -Anteils wird sofort der $\vec{q}_2$ -Anteil neu berechnet usw. Diese kleine Änderung verhindert die Akkumulation von Rundungsfehlern erheblich. Dennoch verwendet man für große Matrizen in der Praxis eher Verfahren wie Householder-Reflexionen oder Givens-Rotationen (siehe Abschnitt 6).

Orthonormalbasen bilden das Herzstück der PCA: Um hochdimensionale Daten optimal auf einen k -dimensionalen Unterraum zu projizieren, benötigen wir eine Orthonormalbasis für diesen Unterraum – Theorem 8 stellt sicher, dass dies immer möglich ist.

4. Orthogonale Matrizen

Lernziele (7.21)

Nach diesem Abschnitt können Sie...

- die Definition einer *orthogonalen Matrix* nennen ($Q^T Q = E_n$) und prüfen, ob eine gegebene Matrix orthogonal ist.
- begründen, warum für quadratische orthogonale Matrizen $Q^{-1} = Q^T$ gilt und welchen rechnerischen Vorteil das bietet.
- erläutern, warum orthogonale Matrizen starre Transformationen beschreiben (Längen und Winkel bleiben erhalten).
- Rotations-, Spiegelungs-, Permutations-, Hadamard- und Householder-Matrizen als orthogonale Matrizen einordnen und ihre geometrische Wirkung beschreiben.
- das Produkt zweier orthogonaler Matrizen als wieder orthogonal begründen.

4.1. Was sind orthogonale Matrizen?

Was passiert, wenn wir all diese hart erarbeiteten orthonormalen Vektoren $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$ nehmen und sie als Spalten nebeneinander in eine Matrix packen? Wir erhalten eine sogenannte **orthogonale Matrix**, üblicherweise mit Q benannt:

$$Q = \begin{pmatrix} | & | & \dots & | \\ \vec{q}_1 & \vec{q}_2 & \dots & \vec{q}_n \\ | & | & \dots & | \end{pmatrix}$$

Diese Matrizen besitzen eine grandiose Eigenschaft: Schauen wir uns an, was passiert, wenn wir Q^T mit Q multiplizieren. Die Zeilen von Q^T sind einfach die Transponierten

Spalten von Q :

$$Q^T Q = \begin{pmatrix} - & \vec{q}_1^T & - \\ - & \vec{q}_2^T & - \\ & \vdots & \\ - & \vec{q}_n^T & - \end{pmatrix} \begin{pmatrix} | & | & \dots & | \\ \vec{q}_1 & \vec{q}_2 & \dots & \vec{q}_n \\ | & | & & | \end{pmatrix}$$

Der Eintrag an der Stelle (i, j) der resultierenden Matrix ist das Skalarprodukt $\vec{q}_i^T \vec{q}_j$. Erinnern Sie sich an die Orthonormalität! Wenn wir $\langle \vec{q}_i, \vec{q}_j \rangle$ berechnen, erhalten wir 1 für $i = j$ und 0 für $i \neq j$. Was also kommt heraus? Auf der Diagonalen stehen lauter Einsen, überall sonst Nullen. Wir erhalten die Einheitsmatrix E_n !

$$\boxed{Q^T Q = E_n} \quad \text{und da } Q \text{ quadratisch ist, folgt direkt: } \boxed{Q^{-1} = Q^T}$$

Normalerweise bedeutet das Berechnen einer Inversen für eine große Matrix wahnsinnig viel Rechenaufwand. Ist die Matrix aber orthogonal, müssen wir sie nur transponieren – die Inverse gibt es völlig umsonst!

Achtung – quadratisch ist Pflicht! Aus $Q^T Q = E_n$ folgt $Q^{-1} = Q^T$ *nur dann*, wenn Q eine **quadratische** ($n \times n$)-Matrix ist. Warum? Weil nicht-quadratische Matrizen keine Inverse besitzen – der Begriff Q^{-1} ist für sie schlicht undefiniert. In Abschnitt 5 werden wir auch rechteckige Matrizen $Q \in \mathbb{R}^{m \times n}$ mit $m > n$ und orthonormalen Spalten kennenlernen. Für diese gilt zwar weiterhin $Q^T Q = E_n$, aber $Q Q^T \neq E_m$, und eine Inverse existiert gar nicht erst. Die Definition und der Satz $Q^{-1} = Q^T$ gelten ausschließlich im quadratischen Fall.

Für quadratische Matrizen $Q \in \mathbb{R}^{n \times n}$ ist die Eigenschaft $Q^T Q = E_n$ tatsächlich äquivalent dazu, dass die Spalten von Q eine Orthonormalbasis des $\mathbb{R}^n$ bilden:

Definition (7.22)

Eine Matrix $Q \in \mathbb{R}^{n \times n}$ heißt **orthogonal**, wenn $Q^T Q = E_n$ gilt.

Bemerkung (7.23)

Eine Matrix ist genau dann orthogonal, wenn die Spalten eine Orthonormalbasis des $\mathbb{R}^n$ bilden:

$$\begin{aligned} Q^T Q = E_n &\Leftrightarrow \langle \vec{q}_i, \vec{q}_i \rangle = 1 \text{ und } \langle \vec{q}_i, \vec{q}_j \rangle = 0 \text{ für } i \neq j \in \{1, \dots, n\} \\ &\Leftrightarrow \{\vec{q}_1, \dots, \vec{q}_n\} \text{ ist eine Orthonormalbasis des } \mathbb{R}^n. \end{aligned}$$

Wichtig: Der Name *orthogonale Matrix* ist irreführend – eigentlich müsste es *orthonormale Matrix* heißen.

Aufgabe (7.24)

Überprüfen Sie: Ist die Matrix $Q = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ orthogonal?

4.2. Orthogonale Matrizen als starre Transformationen**Aufgabe (7.25)**

Bevor Sie weiterlesen, schauen Sie sich folgendes Video von 3blue1brown an:
<https://youtu.be/kYB8IZa5AuE?si=AkBmF-kyeHbYC2LD>

Wenn wir eine beliebige Matrix A auf unseren Vektorraum anwenden – stellen Sie sich das unendliche Gitternetz aus Linien im $\mathbb{R}^2$ oder $\mathbb{R}^3$ vor – verzerrt sich der Raum normalerweise. Quadrate werden zu langgezogenen Parallelogrammen, Strecken dehnen oder stauchen sich.

Bei einer orthogonalen Matrix Q passiert das *nicht*. Eine orthogonale Matrix beschreibt eine **starre Transformation**. Das Raster bleibt vollkommen intakt. Es wird lediglich um den Ursprung **rotiert** oder an einer Ebene **gespiegelt**. Das liegt an einer einfachen Eigenschaft: Q erhält das Skalarprodukt und somit alle Längen und Winkel:

Lemma (7.26)

Ist $Q \in \mathbb{R}^{n \times n}$ orthogonal, so gilt für alle $\vec{x}, \vec{y} \in \mathbb{R}^n$:

$$\langle Q\vec{x}, Q\vec{y} \rangle = \langle \vec{x}, \vec{y} \rangle$$

Beweis.

$$\langle Q\vec{x}, Q\vec{y} \rangle = (Q\vec{x})^T (Q\vec{y}) = \vec{x}^T \underbrace{Q^T Q}_{=E_n} \vec{y} = \vec{x}^T E_n \vec{y} = \vec{x}^T \vec{y} = \langle \vec{x}, \vec{y} \rangle$$

■

Folgerung (7.27)

Für eine orthogonale Matrix $Q \in \mathbb{R}^{n \times n}$ und Vektoren $\vec{x}, \vec{y} \in \mathbb{R}^n$ gilt:

- Die Länge eines Vektors ($|Q\vec{x}| = |\vec{x}|$) bleibt exakt gleich.
- Der Winkel zwischen $\vec{x}$ und $\vec{y}$ ist genau derselbe wie der Winkel zwischen $Q\vec{x}$ und $Q\vec{y}$.

Aufgabe (7.28)

Überlegen Sie sich, wie sich diese Folgerung aus Lemma (7.26) ergibt.

Erinnerung: Der Winkel θ zwischen zwei Vektoren $\vec{x}$ und $\vec{y}$ ist gegeben durch

$$\cos(\theta) = \frac{\langle \vec{x}, \vec{y} \rangle}{\|\vec{x}\| \|\vec{y}\|}.$$

4.3. Wichtige Orthogonale Matrizen

Wir haben gesehen, dass orthogonale Matrizen geometrisch starre Transformationen darstellen. Welche Kandidaten gibt es für solche Matrizen? Wir beginnen simpel und arbeiten uns zu den Matrizen vor, die das Rückgrat moderner Machine-Learning-Algorithmen bilden.

Die einfachsten Vertreter: Einheits- und Permutationsmatrizen

Die trivialste orthogonale Matrix ist die Einheitsmatrix E_n . Ihre Spalten sind die Standardbasisvektoren, die offensichtlich Länge 1 haben und senkrecht aufeinander stehen. Geometrisch passiert hier... absolut nichts (Rotation um 0°).

Wenn wir die Spalten der Einheitsmatrix vertauschen, erhalten wir sogenannte **Permutationsmatrizen**. Da wir lediglich die Reihenfolge der senkrechten Einheitsvektoren ändern, bleiben sie orthonormal. Multiplizieren wir einen Vektor mit einer Permutationsmatrix, ändert sich seine Länge nicht – wir vertauschen lediglich seine Koordinaten. Geometrisch entspricht dies Spiegelungen an den Winkelhalbierenden der Koordinatenachsen.

Beispiel (7.29): Permutationsmatrix im $\mathbb{R}^3$

Wir betrachten die Permutationsmatrix, welche die Koordinatenachsen zyklisch vertauscht ($x \rightarrow y \rightarrow z \rightarrow x$):

$$P = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \quad \text{mit} \quad P \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} z \\ x \\ y \end{pmatrix}$$

Rotationsmatrizen im $\mathbb{R}^2$


Wie drehen wir den gesamten zweidimensionalen Raum um einen Winkel φ ? Wir wissen, dass eine lineare Abbildung komplett dadurch bestimmt ist, was sie mit den Basisvektoren macht. Der Vektor $\vec{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ landet nach der Drehung auf $\begin{pmatrix} \cos \varphi \\ \sin \varphi \end{pmatrix}$. Der Vektor $\vec{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ landet auf $\begin{pmatrix} -\sin \varphi \\ \cos \varphi \end{pmatrix}$. Packen wir diese neuen Spalten in eine Matrix, erhalten wir:

$$Q = \begin{pmatrix} \cos \varphi & -\sin \varphi \\ \sin \varphi & \cos \varphi \end{pmatrix}$$

Ist diese Matrix wirklich orthogonal? Wir prüfen die Orthonormalität der Spalten:

Länge 1: $\cos^2 \varphi + \sin^2 \varphi = 1$ (Trigonometrischer Pythagoras)


Orthogonal: $\langle \vec{q}_1, \vec{q}_2 \rangle = -\cos \varphi \sin \varphi + \sin \varphi \cos \varphi = 0$



Spiegelungsmatrizen im $\mathbb{R}^2$

Ein weiterer klassischer Fall ist die Spiegelung. Wenn wir den Raum an einer Ursprungsgeraden spiegeln, die im Winkel $\frac{\varphi}{2}$ zur x -Achse liegt, ergibt sich eine verblüffend ähnliche Matrix, nur mit einem entscheidenden Vorzeichenwechsel:

$$Q = \begin{pmatrix} \cos \varphi & \sin \varphi \\ \sin \varphi & -\cos \varphi \end{pmatrix}$$



Bemerkung (7.30)

Im $\mathbb{R}^2$ beschreiben orthogonale Matrizen *immer* exakt eine dieser beiden Operationen: Spiegelungen oder Rotationen! Das gilt im Kern auch im $\mathbb{R}^n$, ist dort aber für größere Dimensionen deutlich schwerer visuell fassbar.

Was passiert, wenn wir orthogonale Matrizen hintereinanderschalten? Führen wir erst eine Drehung und dann eine Spiegelung aus, multiplizieren wir einfach die Matrizen. Geht dabei die Orthogonalität verloren? Nein!

Folgerung (7.31): Produkt orthogonaler Matrizen

Sind $Q_1, Q_2 \in \mathbb{R}^{n \times n}$ orthogonal, so ist auch ihr Produkt $Q_1 \cdot Q_2$ orthogonal.

Beweis. Wir prüfen die Definition $(Q_1 \cdot Q_2)^T (Q_1 \cdot Q_2) = E_n$. Mithilfe der Rechenregeln für die Transponierte ergibt sich:

$$(Q_1 \cdot Q_2)^T (Q_1 \cdot Q_2) = Q_2^T \underbrace{Q_1^T Q_1}_{=E_n} Q_2 = Q_2^T E_n Q_2 = Q_2^T Q_2 = E_n. \quad \blacksquare$$

Anschaulich bedeutet dies für unsere Transformationen im Raum:

- Drehung $\cdot$ Drehung = Drehung
- Spiegelung $\cdot$ Spiegelung = Drehung (*Tipp: Rechnen Sie das Produkt zweier Spiegelungsmatrizen zur Übung einmal aus!*)
- Drehung $\cdot$ Spiegelung = Spiegelung

Den ersten Punkt können wir direkt am Beispiel der Rotationsmatrizen nachrechnen:

Beispiel (7.32): Rotation $\cdot$ Rotation = Rotation

Wir drehen den Raum erst um den Winkel α und danach um den Winkel β . Behauptung: Das Ergebnis ist dieselbe wie eine einzige Drehung um $\alpha + \beta$.

$$\begin{aligned} R(\beta) \cdot R(\alpha) &= \begin{pmatrix} \cos \beta & -\sin \beta \\ \sin \beta & \cos \beta \end{pmatrix} \begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix} \\ &= \begin{pmatrix} \cos \beta \cos \alpha - \sin \beta \sin \alpha & -\cos \beta \sin \alpha - \sin \beta \cos \alpha \\ \sin \beta \cos \alpha + \cos \beta \sin \alpha & -\sin \beta \sin \alpha + \cos \beta \cos \alpha \end{pmatrix} \end{aligned}$$


Die Einträge entsprechen exakt den **trigonometrischen Additionstheoremen**:

$$\boxed{\cos(\alpha+\beta) = \cos \alpha \cos \beta - \sin \alpha \sin \beta, \quad \sin(\alpha+\beta) = \sin \alpha \cos \beta + \cos \alpha \sin \beta.}$$

Einsetzen liefert:

$$R(\beta) R(\alpha) = \begin{pmatrix} \cos(\alpha + \beta) & -\sin(\alpha + \beta) \\ \sin(\alpha + \beta) & \cos(\alpha + \beta) \end{pmatrix} = R(\alpha + \beta).$$

Die Additionstheoreme der Trigonometrie sind also die algebraische Entsprechung der geometrischen Aussage „zwei Drehungen hintereinander“:



Aufgabe (7.33)

Was passiert, wenn wir um den Winkel 75° drehen und danach an der Ursprungsgerade spiegeln, die im Winkel 30° zur x -Achse liegt? Berechnen Sie die resultierende Matrix Q und interpretieren Sie das Ergebnis geometrisch.

Hinweis: Nutzen Sie die Additionstheoreme aus Beispiel (7.32).

4. Hadamard-Matrizen

Bisher hatten unsere Matrizen viele Nullen oder trigonometrische Funktionen. **Hadamard-Matrizen** sind völlig anders: Sie bestehen ausschließlich aus den Einträgen $+1$ und -1 und lassen sich elegant rekursiv als Blockmatrizen konstruieren (siehe Übung 1).


$$H_2 = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad H_4 = \begin{pmatrix} H_2 & H_2 \\ H_2 & -H_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{pmatrix}, \quad H_8 = \begin{pmatrix} H_4 & H_4 \\ H_4 & -H_4 \end{pmatrix}$$

Aufgabe (7.34): Hadamard in Python

Hadamard-Matrizen erzeugen wunderschöne, fraktale Schwarz-Weiß-Muster (siehe Abbildung 7.3). In Python können Sie diese Rekursion mit wenigen Zeilen Code über `scipy.linalg.hadamard` aufrufen oder selbst programmieren:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.linalg import hadamard
```

```
H64 = hadamard(64)
```

Abbildung 7.3. Hadamard-Matrix H_{64} .

```
plt.imshow(H64, cmap='gray')
plt.title("Hadamard  $H_{64}$ ")
plt.show()
```

Achtung: Hadamard-Matrizen sind so, wie sie dort stehen, noch keine *orthogonalen Matrizen* nach unserer strikten Definition, denn die Spaltenvektoren haben nicht die Länge 1, sondern $\sqrt{2}, \sqrt{4}, \sqrt{8}, \dots$. Normieren wir die Spalten jedoch (teilen wir z.B. H_2 durch $\sqrt{2}$), so erhalten wir orthogonale Matrizen der Dimensionen 2, 4, 8, 16, ...

Trotz – oder gerade wegen – ihrer simplen Einträge ± 1 spielen Hadamard-Matrizen in überraschend vielen Bereichen eine wichtige Rolle:

- **Walsh-Hadamard-Transformation:** Analog zur Fourier-Transformation zerlegt die Hadamard-Matrix ein Signal in Frequenzkomponenten – aber ausschließlich mit Additionen und Subtraktionen, ohne eine einzige Multiplikation. Das macht sie extrem schnell und hardwarefreundlich.
- **Fehlerkorrigierende Codes:** Die Zeilen einer Hadamard-Matrix unterscheiden sich in genau der Hälfte aller Positionen voneinander (maximaler Hamming-Abstand). Das ermöglicht besonders robuste Übertragungsverfahren.
- **Quantencomputing:** Das *Hadamard-Gate* $\frac{1}{\sqrt{2}}H_2$ versetzt ein einzelnes Qubit in eine Superposition und ist damit das grundlegende Gatter jedes Quantenalgorithmus.

Aufgabe (7.35)

Beweisen Sie die **Hadamard-Vermutung**: Zu jedem Vielfachen n von 4 gibt es eine Hadamard-Matrix der Dimension n .

Warnhinweis: Das zu beweisen hat noch niemand geschafft – die kleinste unbekannte

Dimension ist derzeit $n = 668$.

Hinweis zum Hinweis: Falls Sie es schaffen, werden Sie berühmt und – noch besser – kriegen eine 1.0 in *Mathematik des maschinellen Lernens*.

Householder-Spiegelungen (Der Motor der QR-Zerlegung)

Zum Abschluss betrachten wir eine Matrix, die für die numerische lineare Algebra (und damit für das Trainieren von Machine Learning Modellen) extrem wichtig ist.

Wir wählen einen beliebigen Normalenvektor $\vec{u} \in \mathbb{R}^n$ der Länge $|\vec{u}| = 1$ und definieren die Matrix:

$$H_{\vec{u}} = E_n - 2\vec{u}\vec{u}^T$$

Solche **Householder-Matrizen** sind nicht nur symmetrisch ($H_{\vec{u}} = H_{\vec{u}}^T$), sondern auch orthogonal ($H_{\vec{u}}^T H_{\vec{u}} = E_n$).

Aufgabe (7.36)

Rechnen Sie nach, dass Householder-Matrizen symmetrisch und orthogonal sind.

Aber was tut diese Matrix? Betrachten wir die Struktur $H_{\vec{u}} = E_n - 2\vec{u}\vec{u}^T$ ganz genau. Der Term $P_{\vec{u}} = \vec{u}\vec{u}^T$ hat eine eigene geometrische Bedeutung: Er *projiziert* jeden Vektor auf die Gerade entlang $\vec{u}$ – was genau eine solche *orthogonale Projektion* ist, klären wir im nächsten Abschnitt. Die Householder-Matrix lässt sich dann kompakt schreiben als:

$$H_{\vec{u}} = E_n - 2P_{\vec{u}}$$

Wenden wir nun $H_{\vec{u}}$ auf einen Vektor $\vec{x}$ an, so erhalten wir $H_{\vec{u}}\vec{x} = \vec{x} - 2P_{\vec{u}}\vec{x}$, d.h., wir ziehen die Projektion von $\vec{x}$ auf die Gerade entlang $\vec{u}$ doppelt von $\vec{x}$ ab. Das entspricht geometrisch einer Spiegelung von $\vec{x}$ an der Hyperebene, die senkrecht auf $\vec{u}$ steht (siehe Abschnitt 5).

5. Orthogonale Projektionen

Lernziele (7.37)

Nach diesem Abschnitt können Sie...


- erläutern, warum die Symmetrie $P = P^T$ eine Projektion zu einer *orthogonalen* Projektion macht.
- die universelle Projektionsmatrix $P = QQ^T$ auf den Spaltenraum einer Matrix Q aufstellen.
- die Existenz und Eindeutigkeit der orthogonalen Projektion auf einen Unterraum begründen.
- das Gram-Schmidt-Verfahren und Householder-Spiegelungen geometrisch als

einfache Projektionsoperationen interpretieren.

Wenn wir in der Data Science hochdimensionale Daten (wie in unserer Gen-PCA) zur Analyse in einen niederdimensionalen Unterraum projizieren, haben wir ein klares Ziel: Wir wollen so wenig Information wie möglich verlieren. Die Projektion $\vec{p}$ soll dem Originalvektor $\vec{b}$ so nah wie möglich sein.

Das bedeutet, die Länge des Fehlervektors $\vec{e} = \vec{b} - \vec{p}$ muss minimiert werden. Geometrisch ist intuitiv sofort klar: Der kürzeste Weg von einem Punkt zu einer Ebene ist das Lot. Der Fehlervektor muss senkrecht auf dem Unterraum stehen. Eine „schiefe“ Projektion würde unseren Fehler künstlich vergrößern.

Warum das so ist, beweist uns der mehrdimensionale Satz des Pythagoras. Nehmen wir an, wir wählen anstelle des Lotes eine beliebige andere, „schiefe“ Projektion $\vec{v}$ im Unterraum U . Dann bilden der orthogonale Fehler $\vec{b} - \vec{p}$, die Differenz in der Ebene $\vec{v} - \vec{p}$ und der neue, schiefe Fehler $\vec{b} - \vec{v}$ ein rechtwinkliges Dreieck:



Da der Fehlervektor $\vec{b} - \vec{p}$ senkrecht auf jedem Vektor in U steht (also auch auf $\vec{v} - \vec{p}$), gilt nach Pythagoras:

$$\|\vec{b} - \vec{v}\|^2 = \|\vec{b} - \vec{p}\|^2 + \|\vec{v} - \vec{p}\|^2$$

Quadrierte Längen sind immer positiv ($\|\vec{v} - \vec{p}\|^2 > 0$), also ist die Hypotenuse $\|\vec{b} - \vec{v}\|$ länger als das Lot $\|\vec{b} - \vec{p}\|$ – die optimale Projektion ist somit tatsächlich diejenige, deren Fehler orthogonal zum Unterraum ist. Diese fundamentale Erkenntnis ist der Kern der Methode der kleinsten Quadrate (Abschnitt 7).

In Abschnitt 1 haben wir gesehen, dass sich jede Projektion durch eine Matrix beschreiben lässt. Verblüffenderweise können wir an der Projektionsmatrix direkt ablesen, ob eine orthogonale Projektion vorliegt:

Definition (7.38): Orthogonale Projektionsmatrix

Eine Matrix $P \in \mathbb{R}^{n \times n}$ ist eine **orthogonale Projektionsmatrix**, wenn sie idempotent und symmetrisch ist:

$$P^2 = P \quad \text{und} \quad P = P^T$$

Wieso erzwingt die Symmetrie $P = P^T$ den rechten Winkel? Nehmen wir einen beliebigen Vektor $\vec{x}$. Seine Projektion ist $P\vec{x}$, der „Fehler“ ist $\vec{x} - P\vec{x}$. Wir berechnen das Skalarprodukt zwischen Projektion und Fehler:

$$\begin{aligned}\langle P\vec{x}, (\vec{x} - P\vec{x}) \rangle &= (P\vec{x})^T (\vec{x} - P\vec{x}) \\ &= \vec{x}^T P^T (\vec{x} - P\vec{x}) \\ &= \vec{x}^T P (\vec{x} - P\vec{x}) \quad (\text{hier nutzen wir die Symmetrie } P^T = P) \\ &= \vec{x}^T (P\vec{x} - P^2\vec{x}) \\ &= \vec{x}^T (P\vec{x} - P\vec{x}) \quad (\text{hier nutzen wir } P^2 = P) \\ &= \vec{x}^T \vec{0} = 0\end{aligned}$$

Projektion und Fehler stehen also tatsächlich senkrecht aufeinander.

5.1. Rechteckige Orthogonale Matrizen erzeugen orthogonale Projektionen

Bisher haben wir orthogonale Matrizen Q als quadratische Matrizen betrachtet, die den gesamten Raum starr drehen oder spiegeln. In der Data Science begegnen uns aber häufiger Matrizen $Q \in \mathbb{R}^{m \times n}$, die „höher als breit“ sind ($m > n$). Ihre Spalten sind zwar immer noch orthonormal, aber sie spannen nur noch einen **Teilraum** (einen Unterraum) des $\mathbb{R}^m$ auf.

Sei $Q = (\vec{q}_1, \dots, \vec{q}_n) \in \mathbb{R}^{m \times n}$ eine Matrix mit orthonormalen Spalten. Dann gilt noch immer

$$\boxed{Q^T Q = E_n} \quad (\text{da } \vec{q}_i^T \vec{q}_j = 1 \text{ für } i = j \text{ und } 0 \text{ sonst}).$$

Aber was passiert bei $Q Q^T$? Im Allgemeinen gilt hier:

$$\boxed{Q Q^T \neq E_m}$$

Beispiel (7.39): Vom Einheits-Skalar zur Projektionsmatrix

Betrachten wir den einfachsten Fall: Einen Vektor im $\mathbb{R}^3$, der eine Gerade (einen 1D-Unterraum) aufspannt.

$$Q = \frac{1}{3} \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix}$$

Die Probe $Q^T Q$ ergibt $\frac{1}{9} (2, 2, -1) \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix} = \frac{9}{9} = 1 = E_1$.

Bilden wir jedoch $Q Q^T$, erhalten wir eine 3×3 -Matrix:

$$P = Q Q^T = \frac{1}{9} \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix} (2 \quad 2 \quad -1) = \frac{1}{9} \begin{pmatrix} 4 & 4 & -2 \\ 4 & 4 & -2 \\ -2 & -2 & 1 \end{pmatrix} \neq E_3.$$

Diese Matrix ist zwar nicht die Einheitsmatrix, aber hat eine andere Besonderheit: Sie ist die **orthogonale Projektionsmatrix** auf den von Q aufgespannten Unterraum:

- Sie ist symmetrisch: $P^T = P$
- Sie ist idempotent: $P^2 = P$:

$$P^2 = (QQ^T)(QQ^T) = Q \underbrace{(Q^T Q)}_{=E} Q^T = QE Q^T = QQ^T = P.$$

Das gilt sogar allgemein:

Theorem 9

Ist $Q \in \mathbb{R}^{m \times n}$ eine Matrix mit orthonormalen Spalten, so ist $P = QQ^T$ eine orthogonale Projektionsmatrix

Beweis. Seien Q und P wie oben definiert. Dann gilt:

- **P ist idempotent:** $P^2 = (QQ^T)(QQ^T) = Q \underbrace{(Q^T Q)}_{=E} Q^T = QE Q^T = QQ^T = P.$
- **P ist symmetrisch:** $P^T = (QQ^T)^T = (Q^T)^T Q^T = QQ^T = P.$ ■

Zwei Zeilen Rechnung, und die komplette Geometrie ist bewiesen.

Aufgabe (7.40)

Überlegen Sie sich: was passiert, wenn Q eine quadratische orthogonale Matrix ist? Was ist $P = QQ^T$ in diesem Fall, was ist der Projektionsfehler?

Beispiel (7.41): Projektion auf die Winkelhalbierende

Wir suchen die Projektionsmatrix P , die jeden Vektor im $\mathbb{R}^2$ senkrecht auf die Gerade durch den Vektor $\vec{a} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ projiziert.


Zuerst normieren wir $\vec{a}$, um eine Orthonormalbasis Q (hier nur eine Spalte $\vec{q}$) des eindimensionalen Unterraums zu erhalten:

$$\vec{q} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Die Projektionsmatrix P ergibt sich direkt aus dem äußeren Produkt $\vec{q}\vec{q}^T$:

$$P = \vec{q}\vec{q}^T = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}$$

Wir erkennen sofort: P ist symmetrisch ($P = P^T$) und ein kurzer Test zeigt $P^2 = P$.




5.2. Die Geometrie der Projektion

Was macht $P = QQ^T$ mit einem Vektor $\vec{b}$? Sie projiziert $\vec{b}$ orthogonal auf den Unterraum U , der von den Spalten von Q aufgespannt wird. Das liefert natürlicherweise eine Zerlegung von $\vec{b}$ in zwei Teile:

$$\vec{b} = \vec{b}_U + \vec{b}_{U^\perp}$$

Dabei ist $\vec{b}_U = P\vec{b}$ der Anteil, der **im** Unterraum liegt, und $\vec{b}_{U^\perp} = \vec{b} - P\vec{b}$ der **Fehlervektor**, der senkrecht auf dem Unterraum steht.



Umgekehrt stellt sich folgende Frage: Gegeben sei ein Unterraum U und ein Vektor $\vec{b}$. Kann man $\vec{b}$ eindeutig zerlegen in die Summe

$$\vec{b} = \vec{b}_U + \vec{b}_{U^\perp}$$

mit $\vec{b}_U \in U$ und $\vec{b}_{U^\perp} \perp U$? Und wenn ja, wie findet man diese Zerlegung? Die Antwort darauf liefert das nächste Theorem.

Theorem 10: Projektionssatz (Orthogonale Zerlegung)

Sei U ein Unterraum des $\mathbb{R}^n$ und $\vec{b} \in \mathbb{R}^n$ ein beliebiger Vektor. Dann lässt sich $\vec{b}$ **eindeutig** zerlegen in die Summe

$$\vec{b} = \vec{b}_U + \vec{b}_{U^\perp}$$

wobei $\vec{b}_U \in U$ und $\vec{b}_{U^\perp} \perp U$. Der Vektor $\vec{b}_U$ heißt **orthogonale Projektion** von $\vec{b}$ auf U .

Beweis. Dank des Gram-Schmidt-Verfahrens wissen wir bereits, dass jeder lineare Unterraum U eine Orthonormalbasis besitzt. Nennen wir diese Basisvektoren $\vec{q}_1, \dots, \vec{q}_k$ und schreiben sie als Spalten nebeneinander in eine Matrix Q .

Wir behaupten nun schlicht, dass die Projektionsmatrix $P = QQ^T$ genau die gesuchte Zerlegung liefert. Wir definieren:

$$\vec{b}_U = P\vec{b} = QQ^T\vec{b} \quad \text{und} \quad \vec{b}_{U^\perp} = \vec{b} - P\vec{b}$$

Offensichtlich gilt $\vec{b} = \vec{b}_U + \vec{b}_{U^\perp}$. Wir müssen nur noch zwei Dinge überprüfen:

1. Liegt $\vec{b}_U$ wirklich in U ?

Ja! Da $\vec{b}_U = Q \cdot (Q^T\vec{b})$ ist, handelt es sich um eine Linearkombination der Spalten von Q : die Koeffizienten sind die Einträge von $Q^T\vec{b}$. Da die Spalten von Q den Unterraum U aufspannen, liegt $\vec{b}_U$ per Definition in U .

2. Steht der Fehlervektor $\vec{b}_{U^\perp}$ senkrecht auf U ?

Ein Vektor steht genau dann senkrecht auf dem kompletten Unterraum U , wenn er senkrecht auf jedem einzelnen Basisvektor (also auf jeder Spalte von Q) steht. Das bedeutet: Das Skalarprodukt jeder Zeile von Q^T mit unserem Fehlervektor muss Null ergeben. Wir prüfen also, ob $Q^T \cdot \vec{b}_{U^\perp} = \vec{0}$ gilt:

$$\begin{aligned} Q^T(\vec{b}_{U^\perp}) &= Q^T(\vec{b} - QQ^T\vec{b}) \\ &= Q^T\vec{b} - \underbrace{(Q^TQ)}_{=E_k} Q^T\vec{b} \quad (\text{Hier nutzen wir die Orthonormalität!}) \\ &= Q^T\vec{b} - E_k Q^T\vec{b} \\ &= Q^T\vec{b} - Q^T\vec{b} \\ &= \vec{0} \end{aligned}$$

Also steht $\vec{b}_{U^\perp}$ senkrecht auf U . Beweis der Eindeutigkeit: siehe Appendix B. ■

5.3. Anwendung: Der schrumpfende Fehler

In der Praxis wollen wir Daten oft in Unterräume projizieren. Dabei gilt eine intuitive Regel: **Je mehr (relevante) Dimensionen wir unserem Unterraum spendieren, desto kleiner wird der Informationsverlust (der Fehlervektor):**

Beispiel (7.42): Projektion in Unterräume unterschiedlicher Dimensionen

Gegeben sei der Vektor $\vec{b} = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}$. Wir bestimmen die orthogonale Projektion von $\vec{b}$ in Unterräume steigender Dimension:

1. Projektion auf eine Gerade ($n = 1$): Mit $Q_1 = \frac{1}{3} \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix}$ und $P_1 = Q_1 Q_1^T$

berechnen wir:

$$P_1 \vec{b} = \frac{1}{9} \begin{pmatrix} 4 & 4 & -2 \\ 4 & 4 & -2 \\ -2 & -2 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix}.$$

Der Fehler ist $\vec{e}_1 = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix} - \begin{pmatrix} 2 \\ 2 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 4 \end{pmatrix}$ mit der Länge $|\vec{e}_1| = \sqrt{18} \approx 4.24$.

2. Projektion auf eine Ebene ($n = 2$): Wir fügen eine zweite orthonormale Richtung hinzu: $Q_2 = \frac{1}{3} \begin{pmatrix} 2 & 2 \\ 2 & -1 \\ -1 & 2 \end{pmatrix}$.

$$P_2 \vec{b} = Q_2 (Q_2^T \vec{b}) = Q_2 \left(\frac{1}{3} \begin{pmatrix} 2 & 2 & -1 \\ 2 & -1 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix} \right) = Q_2 \begin{pmatrix} 3 \\ 3 \end{pmatrix} = \begin{pmatrix} 4 \\ 1 \\ 1 \end{pmatrix}.$$

Der Fehlervektor ist nun $\vec{e}_2 = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix} - \begin{pmatrix} 4 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \\ 2 \end{pmatrix}$ mit der Länge $|\vec{e}_2| = \sqrt{9} = 3$.

Der Fehler ist geschrumpft!

3. Projektion auf den vollen Raum ($n = 3$): Ergänzen wir Q_2 zu einer quadratischen orthogonalen Matrix Q_3 , dann spannen die Spalten den gesamten $\mathbb{R}^3$ auf. In diesem Fall wird $Q_3 Q_3^T = E_3$. Die Projektion ist $P_3 \vec{b} = \vec{b}$ und der Fehler $\vec{e}_3 = \vec{0}$.

Aufgabe (7.43)

Gegeben sei der Vektor $\vec{b} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$ und die Gerade durch den Vektor $\vec{a} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$.

1. Bestimmen Sie die orthogonale Projektionsmatrix P auf die Gerade entlang $\vec{a}$.
2. Berechnen Sie die Projektion $\vec{p} = P\vec{b}$ und den Fehlervektor $\vec{e} = \vec{b} - \vec{p}$.
3. Überprüfen Sie, dass $\vec{e} \perp \vec{a}$, d. h. $\langle \vec{a}, \vec{e} \rangle = 0$.

5.4. Ein neuer Blick auf alte Bekannte: Gram-Schmidt und Householder


Mit Hilfe orthogonaler Projektionen ergeben die in den vorherigen Abschnitten eingeführten Verfahren einen tieferen Sinn:

Householder-Spiegelungen entmystifiziert

Im vorherigen Abschnitt fiel die Householder-Matrix $H_{\vec{u}} = E_n - 2\vec{u}\vec{u}^T$ (mit $|\vec{u}| = 1$) etwas vom Himmel. Schauen wir jetzt noch einmal genau hin: Der Vektor $\vec{u}$ ist im Grunde eine $n \times 1$ Matrix mit orthonormalen Spalten (es ist ja nur eine, mit Länge 1). Also ist $P = \vec{u}\vec{u}^T$ exakt die orthogonale Projektionsmatrix auf die Gerade durch $\vec{u}$! Wir können die Householder-Matrix also schreiben als:

$$H_{\vec{u}} = E_n - 2P$$

Geometrisch wird es jetzt nachvollziehbar: Wenden wir $H_{\vec{u}}$ auf einen Vektor $\vec{x}$ an, erhalten wir $\vec{x} - 2P\vec{x}$. Wir nehmen den Vektor $\vec{x}$, ziehen seine Projektion auf $\vec{u}$ einmal ab ($\vec{x} - P\vec{x}$) – jetzt stehen wir exakt senkrecht auf $\vec{u}$, d.h., wir befinden uns in der Hyperebene senkrecht zu $\vec{u}$. Ziehen wir die Projektion noch ein zweites Mal ab, so rutschen wir auf die exakt gegenüberliegende Seite. Wir haben an der Hyperebene senkrecht zu $\vec{u}$ gespiegelt!



Gram-Schmidt ist nur ein Abziehen von orthogonalen Projektionen

Auch der Kern des Gram-Schmidt-Verfahrens lässt sich nun auf einen Blick begreifen. Wir rechneten dort:

$$\vec{y}_k = \vec{v}_k - \sum_{j=1}^{k-1} (\vec{q}_j^T \vec{v}_k) \vec{q}_j$$

Da Skalare vertauschbar sind, ist

$$\underbrace{(\vec{q}_j^T \vec{v}_k)}_{\in \mathbb{R}} \vec{q}_j = \vec{q}_j (\vec{q}_j^T \vec{v}_k) = (\vec{q}_j \vec{q}_j^T) \vec{v}_k = P_j \vec{v}_k$$

Der Term in der Summe ist also die orthogonale Projektion P_j auf den Basisvektor $\vec{q}_j$. Gram-Schmidt tut damit nichts anderes, als von einem Vektor nacheinander seine orthogonalen Projektionen auf die bereits etablierten Basisvektoren abzuziehen, bis nur noch ein komplett orthogonaler „Rest“ übrig bleibt.

Aufgabe (7.44)

Nutzen Sie die Projektionsmatrix $P = \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}$ aus Beispiel (7.41). Gegeben sei der Vektor $\vec{x} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$.

1. Berechnen Sie die Projektion $\vec{p} = P\vec{x}$.
2. Berechnen Sie den Fehlervektor $\vec{e} = \vec{x} - \vec{p}$.
3. Zeigen Sie explizit durch Berechnung des Skalarprodukts $\langle \vec{p}, \vec{e} \rangle$, dass der Fehler senkrecht auf der Projektion steht.

6. Die QR-Zerlegung: Gram-Schmidt als Matrixgleichung**Lernziele (7.45)**

Nach diesem Abschnitt können Sie...

- die **QR-Zerlegung** als Matrixfaktorisierung $A = QR$ erklären.
- ausführen, wie die Einträge der Matrix R direkt aus dem Gram-Schmidt-Verfahren abgelesen werden können.
- erläutern, warum R zwingend eine obere Dreiecksmatrix sein muss.
- die Grundidee der **Householder-QR-Zerlegung** skizzieren und ihren numerischen Vorteil gegenüber Gram-Schmidt begründen.

6.1. QR-Zerlegung über Gram-Schmidt

In der linearen Algebra ist es Tradition, mächtige Algorithmen in simple Matrixgleichungen zu verpacken. Die Gauß-Elimination wird zu $A = LR$. Das Gram-Schmidt-Verfahren hat ebenfalls eine solche Signatur: die **QR-Zerlegung**.

Das Ziel: Wir wollen eine Matrix $A \in \mathbb{R}^{m \times n}$ (mit linear unabhängigen Spalten, $\text{rank}(A) = n \leq m$) faktorisieren in:

$$A = QR$$

Dabei ist Q eine $m \times n$ Matrix mit orthonormalen Spalten, welche eine ONB des Spaltenraums von A bilden, und R eine quadratische, rechte obere Dreiecksmatrix ($n \times n$).

Gram-Schmidt R-ückwärts gelesen

Wenn wir eine Matrix A haben, sind ihre Spalten $\vec{a}_1, \vec{a}_2, \dots, \vec{a}_n$ genau die Startvektoren für unser Gram-Schmidt-Verfahren. Das Verfahren liefert uns schrittweise die orthonormalen Vektoren $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$. Diese packen wir als Spalten in die Matrix Q .

Doch woher kommt R ? Um das zu sehen, müssen wir die Gram-Schmidt-Gleichungen einfach *nach den ursprünglichen Vektoren $\vec{a}_k$ auflösen*. Wir formen um:

$$\begin{aligned}
 \text{Schritt 1: } \vec{q}_1 &= \frac{\vec{a}_1}{|\vec{a}_1|} \implies \vec{a}_1 = |\vec{a}_1| \cdot \vec{q}_1 \\
 \text{Schritt 2: } \vec{q}_2 &= \frac{\vec{y}_2}{|\vec{y}_2|} \quad \text{mit } \vec{y}_2 = \vec{a}_2 - \langle \vec{a}_2, \vec{q}_1 \rangle \vec{q}_1 \\
 &\implies \vec{a}_2 = \vec{y}_2 + \langle \vec{a}_2, \vec{q}_1 \rangle \vec{q}_1 = |\vec{y}_2| \cdot \vec{q}_2 + \langle \vec{a}_2, \vec{q}_1 \rangle \cdot \vec{q}_1 \\
 &\vdots \\
 \text{Schritt k: } \vec{q}_k &= \frac{\vec{y}_k}{|\vec{y}_k|} \quad \text{mit } \vec{y}_k = \vec{a}_k - \sum_{i=1}^{k-1} \langle \vec{a}_k, \vec{q}_i \rangle \vec{q}_i \\
 &\implies \vec{a}_k = |\vec{y}_k| \cdot \vec{q}_k + \sum_{i=1}^{k-1} \langle \vec{a}_k, \vec{q}_i \rangle \cdot \vec{q}_i
 \end{aligned}$$

Schreiben wir dies nun als Matrixmultiplikation auf. Wir erinnern uns: Das Produkt Matrix mal Vektor ist eine Linearkombination der Spalten der Matrix.

$$\underbrace{(\vec{a}_1 \mid \vec{a}_2 \mid \cdots \mid \vec{a}_n)}_{=A} = \underbrace{(\vec{q}_1 \mid \vec{q}_2 \mid \cdots \mid \vec{q}_n)}_{=Q} \cdot \underbrace{\begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ 0 & r_{22} & & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & r_{nn} \end{pmatrix}}_{=R}$$

Die Koeffizienten r_{ij} sind exakt die Längen und Skalarprodukte, die wir während Gram-Schmidt ohnehin ausrechnen müssen!

- **Auf der Diagonalen** stehen die Längen der orthogonalisierten Restvektoren: $r_{kk} = |\vec{y}_k|$ (bzw. $r_{11} = |\vec{a}_1|$).
- **Über der Diagonalen** stehen die Projektionskoeffizienten: $r_{ik} = \langle \vec{a}_k, \vec{q}_i \rangle$ für $i < k$.

Warum ist R zwingend eine obere Dreiecksmatrix?

Um den ersten Vektor $\vec{a}_1$ zu bauen, brauchen wir nur $\vec{q}_1$. Um $\vec{a}_2$ zu bauen, brauchen wir nur $\vec{q}_1$ und $\vec{q}_2$. Die späteren Vektoren $(\vec{q}_3, \vec{q}_4, \dots)$ spielen keine Rolle! Deshalb stehen unterhalb der Diagonalen ausschließlich Nullen. Die obere Dreiecksform von R ist also eine direkte Konsequenz der schrittweisen Konstruktion der orthonormalen Basis durch Gram-Schmidt.

Beispiel (7.46): QR-Zerlegung einer 3×2 -Matrix

Gegeben: $A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}$.

Schritt 1 ($k = 1$):

$$r_{11} = |\vec{a}_1| = \sqrt{3}, \quad \vec{q}_1 = \frac{\vec{a}_1}{r_{11}} = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Schritt 2 ($k = 2$):

$$r_{12} = \langle \vec{a}_2, \vec{q}_1 \rangle = \frac{1 + 2 + 3}{\sqrt{3}} = 2\sqrt{3}.$$

$$\vec{y}_2 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} - 2\sqrt{3} \cdot \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}, \quad r_{22} = |\vec{y}_2| = \sqrt{2}, \quad \vec{q}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

Ergebnis:

$$Q = \begin{pmatrix} \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & 0 \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} \end{pmatrix}, \quad R = \begin{pmatrix} \sqrt{3} & 2\sqrt{3} \\ 0 & \sqrt{2} \end{pmatrix}.$$

Probe: $QR = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} = A.$

Algorithmus (7.47): Algorithmus: QR-Zerlegung via Gram-Schmidt

Eingabe: $A = (\vec{a}_1 \mid \dots \mid \vec{a}_n) \in \mathbb{R}^{m \times n}$ mit linear unabhängigen Spalten

Ausgabe: $Q \in \mathbb{R}^{m \times n}$ (orthonormale Spalten), $R \in \mathbb{R}^{n \times n}$ (obere Dreiecksmatrix), $A = QR$

- 1: $r_{11} \leftarrow |\vec{a}_1|; \quad \vec{q}_1 \leftarrow \vec{a}_1 / r_{11}$
- 2: **for** $k = 2$ **bis** n **do**
- 3: **for** $i = 1$ **bis** $k - 1$ **do**
- 4: $r_{ik} \leftarrow \langle \vec{a}_k, \vec{q}_i \rangle$ ▷ Projektionskoeffizient
- 5: **end for**
- 6: Berechne den Restvektor:

$$\vec{y}_k \leftarrow \vec{a}_k - \sum_{i=1}^{k-1} r_{ik} \vec{q}_i$$

- 7: $r_{kk} \leftarrow |\vec{y}_k|; \quad \vec{q}_k \leftarrow \vec{y}_k / r_{kk}$
- 8: **end for**

Aufgabe (7.48)

Berechnen Sie die QR-Zerlegung der Matrix $A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 2 & 1 \end{pmatrix}$ mithilfe des Gram-Schmidt-Verfahrens.

Hinweis: Lassen Sie sich von der Dimension von A (3×2) nicht irritieren. In diesem

Fall ist Q eine 3×2 -Matrix mit orthonormalen Spalten, und R ist eine 2×2 -obere Dreiecksmatrix.

Bemerkung (7.49): Wofür brauchen wir das?

Die QR-Zerlegung hat eine Vielzahl von Anwendungen: Sie verrät uns sofort eine Orthonormalbasis für den Spaltenraum von A (die Spalten von Q) und bildet außerdem die Grundlage zur Lösung überbestimmter Systeme (Methode der kleinsten Quadrate, Abschnitt 7).

Zeitkomplexität

Wie teuer ist die QR-Zerlegung via Gram-Schmidt für eine Matrix $A \in \mathbb{R}^{m \times n}$?

In **Schritt** k zählen wir die Multiplikationen: $(k - 1)$ Skalarprodukte (je m Multiplikationen), $(k - 1)$ skalierte Vektorsubtraktionen (je m Multiplikationen) und eine Normierung (m Multiplikationen). Das ergibt exakt $(2k - 1) \cdot m$ Multiplikationen pro Schritt. Summieren wir über alle n Schritte:

$$\sum_{k=1}^n (2k - 1) \cdot m = m \cdot \underbrace{\sum_{k=1}^n (2k - 1)}_{= n^2 \text{ (vollständige Induktion!)}} = \boxed{mn^2}$$

Für quadratische Matrizen ($m = n$) ergibt sich eine Zeitkomplexität von $O(n^3)$.

6.2. QR in der Praxis: Householder-Reflexionen

Die QR-Zerlegung über das Gram-Schmidt-Verfahren hat einen großen Nachteil: Sie ist in der Praxis für große Matrizen auf dem Computer unbrauchbar. Da der Computer mit begrenzter Genauigkeit (Gleitkommazahlen) rechnet, entstehen bei jedem Abziehen einer Projektion kleine Rundungsfehler, wodurch erzeugten Vektoren nicht mehr exakt orthogonal zueinander sind. Man nennt dies den *Orthogonalitätsverlust*.

Die Lösung für dieses Problem ist die **Householder-QR-Zerlegung**. Anstatt die Spalten von A nacheinander zu orthogonalisieren, verwenden wir eine Reihe von Householder-Spiegelungen, um die Matrix A direkt in eine obere Dreiecksmatrix zu verwandeln. Das Verfahren ist numerisch stabiler, da es keine aufeinanderfolgenden Projektionen und Abzüge erfordert, sondern stattdessen die gesamte Spalte auf einmal spiegelt. Aber *wohin* wollen wir die Spalte spiegeln?

Die Grundidee des Householder-QR

Wir wollen unterhalb der Hauptdiagonalen von A Nullen erzeugen, um R zu erhalten.

1. **Spalte 1:** Wir betrachten die erste Spalte $\vec{a}_1$. Wir suchen uns geschickt einen Normalenvektor $\vec{u}_1$, sodass die Spiegelung H_1 diesen Vektor **auf die x-Achse klappt**.

$$H_1 \vec{a}_1 = \begin{pmatrix} * \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Wir wenden H_1 auf die gesamte Matrix A an. Die erste Spalte hat nun unten Nullen.

2. **Spalte 2:** Wir lassen die erste Zeile und Spalte in Ruhe und definieren eine zweite Spiegelung H_2 , die in der zweiten Spalte alles unterhalb der Diagonalen zu Null spiegelt. Dann liefert die Nacheinanderanwendung von H_2 und H_1 auf A :

$$H_2 H_1 A = \begin{pmatrix} * & * & * & \ddots & * \\ 0 & * & * & \dots & * \\ 0 & 0 & * & \dots & * \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & * & \dots & * \end{pmatrix}$$


3. **Spalte n:** Nach n Spiegelungen haben wir eine obere Dreiecksmatrix erreicht: Wir multiplizieren A von links mit vielen orthogonalen Householder-Matrizen, bis R übrig bleibt:

$$H_n \cdots H_2 H_1 A = R$$

Da Householder-Matrizen orthogonal und symmetrisch sind, sind sie ihre eigene Inverse ($H^{-1} = H^T = H$). Wir bringen sie einfach auf die andere Seite:

$$A = \underbrace{H_1 H_2 \cdots H_n}_{=Q} R$$

Das Produkt orthogonaler Matrizen ist wieder orthogonal. Wir haben unser $A = QR$ gefunden!



Wie finden wir den Normalenvektor $\vec{u}$?

Das ist die entscheidende Frage: Für welchen Vektor $\vec{u}$ klappt die Spiegelung $H = E - 2\vec{u}\vec{u}^T$ eine gegebene Spalte $\vec{a}$ exakt auf die erste Koordinatenachse? Die Antwort liefert das folgende Theorem.

Theorem 11: Householder-Spiegelung auf die Koordinatenachse

Gegeben sei ein Spaltenvektor $\vec{a} \in \mathbb{R}^m$ mit der ersten Komponente a_1 . Wir definieren den Zielvektor auf der x-Achse als $\vec{p} = -\text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1$, wobei

$$\text{sign}(a_1) = \begin{cases} 1, & \text{falls } a_1 \geq 0 \\ -1, & \text{falls } a_1 < 0 \end{cases}$$

das Vorzeichen von a_1 angibt.

Wählen wir nun den Normalenvektor der Spiegelebene als die Differenz zwischen Original und Ziel:

$$\vec{v} = \vec{a} - \vec{p} = \vec{a} + \text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1, \quad \vec{u} = \frac{\vec{v}}{|\vec{v}|}$$

Dann gilt für die zugehörige Householder-Matrix $H = E_m - 2\vec{u}\vec{u}^T$:

$$H \vec{a} = \vec{p} = -\text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1$$

Beweis: Siehe Appendix B.

Warum $\text{sign}(a_1)$? Wir wollen, dass die erste Komponente $v_1 = a_1 + \text{sign}(a_1)|\vec{a}|$ betragsmäßig möglichst groß wird. Da $|\vec{a}| \geq |a_1|$, verhindert das Vorzeichen, dass sich die Werte bei der Addition gegenseitig auslöschen (numerische Stabilität).

Aufgabe (7.50): Aktivierung: Householder-Normalenvektor bestimmen

Gegeben sei der Vektor $\vec{a} = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix}$.

1. Bestimmen Sie nach Theorem 11 den normierten Normalenvektor $\vec{u}$, sodass $H_{\vec{u}}\vec{a}$ auf die erste Koordinatenachse fällt. Geben Sie dazu explizit $\vec{p}$, $\vec{v}$ und $\vec{u}$ an.
2. Berechnen Sie $H_{\vec{u}}\vec{a} = \vec{a} - 2(\vec{u}^T \vec{a})\vec{u}$ und überprüfen Sie, dass das Ergebnis die Form $-\text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1$ hat.
3. Warum wählen wir $\vec{v} = \vec{a} + \text{sign}(a_1)|\vec{a}| \vec{e}_1$ und nicht einfach $\vec{v} = \vec{a} - |\vec{a}| \vec{e}_1$? Was könnte bei $a_1 > 0$ numerisch schiefgehen?

Beispiel (7.51): Householder-QR für $A \in \mathbb{R}^{3 \times 3}$ – zwei Schritte

Gegeben: $A = \begin{pmatrix} 3 & 3 & 2 \\ 4 & 4 & 1 \\ 0 & 5 & 3 \end{pmatrix}$.

Schritt 1 ($k=1$): Untervektor ist die gesamte erste Spalte $\vec{a} = (3, 4, 0)^T \in \mathbb{R}^3$.

$$|\vec{a}| = 5, \quad a_1 = 3 > 0 \Rightarrow \text{sign}(a_1) = +1,$$

$$\vec{v} = \begin{pmatrix} 3 \\ 4 \\ 0 \end{pmatrix} + 5 \underbrace{\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}}_{\vec{e}_1 \in \mathbb{R}^3} = \begin{pmatrix} 8 \\ 4 \\ 0 \end{pmatrix}, \quad \vec{u}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}.$$

Die dritte Komponente von $\vec{u}_1$ ist Null – daher bleibt Zeile/Spalte 3 von H_1 unverändert:

$$H_1 = I_3 - 2\vec{u}_1\vec{u}_1^T = \begin{pmatrix} -\frac{3}{5} & -\frac{4}{5} & 0 \\ -\frac{4}{5} & \frac{3}{5} & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

$$B_1 = H_1 A = \begin{pmatrix} -5 & -5 & -2 \\ 0 & 0 & -1 \\ 0 & 5 & 3 \end{pmatrix}.$$

Schritt 2 ($k=2$): Wir lassen Zeile 1 in Ruhe. Untervektor = zweite Spalte ab Zeile 2:

$$\vec{a} = \begin{pmatrix} 0 \\ 5 \end{pmatrix} \in \mathbb{R}^2, \quad |\vec{a}| = 5, \quad a_1 = 0 \Rightarrow \text{sign}(0) = 1$$

$$\vec{v} = \begin{pmatrix} 0 \\ 5 \end{pmatrix} + 5 \underbrace{\begin{pmatrix} 1 \\ 0 \end{pmatrix}}_{\vec{e}_1 \in \mathbb{R}^2 \text{ (lokal!)}} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}, \quad \vec{u}'_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \in \mathbb{R}^2.$$

Auffüllen auf $\mathbb{R}^3$: eine Null oben einfügen, dann H_2 als Blockmatrix:

$$\tilde{\vec{u}}_2 = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \in \mathbb{R}^3, \quad H_2 = I_3 - 2\tilde{\vec{u}}_2\tilde{\vec{u}}_2^T = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & -1 & 0 \end{pmatrix} = \begin{pmatrix} I_1 & 0 \\ 0 & H'_2 \end{pmatrix}.$$

$$R = H_2 B_1 = \begin{pmatrix} -5 & -5 & -2 \\ 0 & -5 & -3 \\ 0 & 0 & 1 \end{pmatrix}.$$

Ergebnis:

$$Q = H_1 H_2 = \begin{pmatrix} -\frac{3}{5} & 0 & \frac{4}{5} \\ -\frac{4}{5} & 0 & -\frac{3}{5} \\ 0 & -1 & 0 \end{pmatrix}, \quad A = QR. \checkmark$$

Algorithmus (7.52): QR-Zerlegung via Householder-Spiegelungen

Eingabe: $A \in \mathbb{R}^{m \times n}$, $m \geq n$

Ausgabe: $Q \in \mathbb{R}^{m \times n}$ (orthonormale Spalten), $R \in \mathbb{R}^{n \times n}$ (obere Dreiecksmatrix), $A = QR$

- 1: $B \leftarrow A$ ▷ Arbeitskopie von A
- 2: **for** $k = 1$ **bis** n **do**
- 3: $\vec{a} \leftarrow B_{k:m, k}$ ▷ Untervektor der Länge $m - k + 1$ ab Zeile k
- 4: $\vec{e}_1 \leftarrow (1, 0, \dots, 0)^T \in \mathbb{R}^{m-k+1}$ ▷ Lokal – erster Einheitsvektor im Unterraum
- 5: $\vec{v} \leftarrow \vec{a} + \text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1$; $\vec{u}_k \leftarrow \vec{v}/|\vec{v}|$ ▷ a_1 = erste Komponente von $\vec{a}$;
 $\vec{u}_k \in \mathbb{R}^{m-k+1}$
- 6: Aktualisiere den aktiven Block (nur Zeilen $k:m$, Spalten $k:n$):

$$B_{k:m, k:n} \leftarrow (E_{m-k+1} - 2\vec{u}_k\vec{u}_k^T) B_{k:m, k:n}$$

7: **end for**

8: $R \leftarrow B_{1:n, 1:n}$ ▷ oberer $n \times n$ -Block = obere Dreiecksmatrix

9: $Q \leftarrow$ erste n Spalten von $H_1 H_2 \dots H_n$, $H_k = \begin{pmatrix} E_{k-1} & 0 \\ 0 & E_{m-k+1} - 2\vec{u}_k\vec{u}_k^T \end{pmatrix}$

In der Praxis wird Q nicht explizit aufgebaut, sondern implizit als Folge von Householder-Transformationen gespeichert.

Wichtig im QR-Kontext: Bei Schritt k ist $\vec{a} = B_{k:m, k} \in \mathbb{R}^{m-k+1}$ ein Untervektor, und $\vec{e}_1$ bezeichnet den ersten Einheitsvektor dieses lokalen Unterraums.

Aufgabe (7.53)

Gegeben sei die Matrix $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$.

1. Bestimmen Sie die Householder-Matrix H , die die erste Spalte von A auf $-|\vec{a}_1| \vec{e}_1$ abbildet.
2. Berechnen Sie $R = HA$ und $Q = H^T = H$ und verifizieren Sie $A = QR$.

Bemerkung (7.54): Warum Householder?

Bei der Multiplikation mit Householder-Matrizen bleiben die Spaltenvektoren stets von Länge 1 und die orthogonalen Eigenschaften sind tief in der Struktur der Matrix verankert. Selbst wenn der Computer rundet, bleibt die Matrix Q perfekt orthogonal. Daher verwenden Bibliotheken wie `numpy.linalg.qr` oder `scipy` im Hintergrund sehr häufig Householder-Spiegelungen und fast nie klassisches Gram-Schmidt.

Zeitkomplexität

In **Schritt** k wird die Householder-Matrix $H_k = E - 2\vec{u}_k\vec{u}_k^T$ auf eine schrumpfende Teilmatrix der Größe $(m - k + 1) \times (n - k + 1)$ angewendet. Dank der Rang-1-Struktur kostet das pro Spalte $\vec{x}$ nur zwei Rechenschritte:

$$H_k \vec{x} = \vec{x} - \underbrace{2\vec{u}_k}_{(2) \text{ Sklierung}} \underbrace{(\vec{u}_k^T \vec{x})}_{(1) \text{ Skalarprodukt}}$$

1. **Skalarprodukt** $s = \vec{u}_k^T \vec{x}$: $(m - k + 1)$ Multiplikationen
2. **Sklierung** $2s \cdot \vec{u}_k$: $(m - k + 1)$ Multiplikationen

Die abschließende Subtraktion $\vec{x} - 2s\vec{u}_k$ kostet nur Additionen. Damit ergeben sich $2(m - k + 1)$ Multiplikationen pro Spalte, und somit $2(m - k + 1)(n - k + 1)$ Multiplikationen für den gesamten Blockschrift.

Summieren wir über alle n Schritte und schätzen für hohe Matrizen $(m - k + 1) \leq m$ ab:

$$\begin{aligned} \sum_{k=1}^n 2(m - k + 1)(n - k + 1) &\leq 2m \sum_{k=1}^n (n - k + 1) \\ &= 2m \cdot \underbrace{\frac{n(n+1)}{2}}_{\text{Gaußsche Summe}} = mn(n+1) \in \boxed{\mathcal{O}(mn^2)} \end{aligned}$$

Für eine *quadratische* Matrix ($m = n$) können wir die exakte Summe der Quadratzahlen bilden. Durch vollständige Induktion ergibt sich:

$$\sum_{k=1}^n 2(n - k + 1)^2 = 2 \cdot \frac{n(n+1)(2n+1)}{6} \approx \frac{2}{3}n^3 \text{ Multiplikationen}$$

Das ist ein Drittel *weniger* als die QR-Zerlegung mit dem klassischen Gram-Schmidt-Verfahren (mit $\approx n^3$). Householder-Spiegelungen sind also nicht nur numerisch stabiler, sondern für große quadratische Matrizen auch signifikant schneller.

In der Data Science ist der typische Fall $m \gg n$: viele Datenpunkte, wenige Parameter. Die Komplexität von $\mathcal{O}(mn^2)$ bedeutet, dass die Laufzeit linear mit der Anzahl der Datenpunkte m wächst, aber quadratisch mit der Anzahl der Features n – für festes n (Anzahl der Features) ist Householder-QR also ein skalierbarer Algorithmus.

7. Die Methode der kleinsten Quadrate

Lernziele (7.55)

Nach diesem Kapitel können Sie...

- das Konzept überbestimmter Gleichungssysteme ($A\vec{x} = \vec{b}$) im Kontext realer Daten erklären.
- die Normalengleichung $A^T A \hat{\vec{x}} = A^T \vec{b}$ geometrisch aus dem Orthogonalitätsprinzip (Fehler steht senkrecht auf dem Spaltenraum) herleiten.
- lineare Regression als ein Projektionsproblem formulieren und lösen.
- erklären, warum die QR-Zerlegung in der Praxis der stabilere Weg zur Lösung von Ausgleichsproblemen ist.

7.1. Das Problem mit der Realität: Zu viele Gleichungen

Im Kapitel über die LR-Zerlegung hatten wir ein Lineares Gleichungsproblem $A\vec{x} = \vec{b}$, bei dem A eine quadratische und invertierbare Matrix ist. Es gibt genau so viele Gleichungen wie Unbekannte, und die Lösung ist exakt: $\vec{x} = A^{-1}\vec{b}$.

In der Realität funktioniert das meistens leider nicht so. Wenn wir versuchen, den Preis eines Hauses ($\vec{b}$) anhand seiner Wohnfläche und Zimmeranzahl (die Spalten von A) vorherzusagen, haben wir vielleicht 2 Variablen (Unbekannte), aber 10.000 Häuser (Gleichungen). Unsere Matrix A ist extrem hoch und schmal (10.000×2). Wir haben ein **überbestimmtes Gleichungssystem**.

Wenn wir nun $A\vec{x} = \vec{b}$ lösen wollen, sagt uns die Mathematik fast immer: **Es gibt keine Lösung**. Dafür reichen bereits zwei Häuser aus, die zwar die gleiche Wohnfläche und Zimmeranzahl haben, aber unterschiedliche Preise. Es ist schlicht unmöglich, eine einzige Gerade durch alle Punkte zu legen.

Bemerkung (7.56)


Geometrisch bedeutet *Keine Lösung*: Der Vektor $\vec{b}$ liegt irgendwo im Raum, aber eben nicht exakt in der Ebene $\mathcal{C}(A)$. Was tun wir? Wir geben auf, nach der *exakten* Lösung $\vec{x}$ zu suchen. Stattdessen suchen wir nach dem bestmöglichen Kompromiss: Wir suchen den Vektor $\hat{\vec{x}}$ (sprich: „x-Dach“), sodass $A\hat{\vec{x}}$ so nah wie möglich an $\vec{b}$ herankommt.

7.2. Die geometrische Rettung: Projektionen

Hier schließt sich der Kreis. Wenn wir den Punkt im Spaltenraum $\mathcal{C}(A)$ suchen, der unserem un erreichbaren Vektor $\vec{b}$ am nächsten ist, dann ist das exakt die **orthogonale Projektion** von $\vec{b}$ auf den Spaltenraum! Nennen wir diesen projizierten Vektor $\vec{p}$.

Anstatt das unlösbare System $A\vec{x} = \vec{b}$ zu betrachten, lösen wir das *immer* lösbare Ersatzsystem:

$$A\hat{\vec{x}} = \vec{p}$$



Wie finden wir $\hat{\vec{x}}$? Schauen Sie sich das Bild an: Der Fehlervektor $\vec{e} = \vec{b} - A\hat{\vec{x}}$ steht **senkrecht** auf dem gesamten Spaltenraum $\mathcal{C}(A)$. Das bedeutet, der Fehlervektor steht senkrecht auf *jeder einzelnen Spalte* von A .

Erinnern wir uns, wie wir „senkrecht auf allen Spalten“ mathematisch ausdrücken: Das Skalarprodukt des Fehlers mit jeder Spalte ist Null. Das ist exakt die Multiplikation mit der transponierten Matrix A^T !

$$\begin{aligned} A^T \cdot \vec{e} &= \vec{0} \\ A^T (\vec{b} - A\hat{\vec{x}}) &= \vec{0} \\ A^T \vec{b} - A^T A \hat{\vec{x}} &= \vec{0} \end{aligned}$$

Bringen wir den Term auf die andere Seite, erhalten wir eines der grundlegenden Gleichungssysteme der angewandten Statistik und des maschinellen Lernens:

Definition (7.57): Die Normalengleichungen

Für ein überbestimmtes System $A\vec{x} = \vec{b}$ finden wir die beste Approximation $\hat{\vec{x}}$ (im Sinne des geringsten quadratischen Fehlers) durch Lösen der **Normalengleichungen**:

$$\boxed{A^T A \hat{\vec{x}} = A^T \vec{b}}$$

Wenn die Spalten von A linear unabhängig sind, ist die quadratische Matrix $(A^T A)$ stets invertierbar, und die Lösung ist $\hat{\vec{x}} = (A^T A)^{-1} A^T \vec{b}$.

Aufgabe (7.58)

Prüfen Sie Ihr Verständnis: Wir haben im letzten Kapitel gelernt, dass die Projektionsmatrix auf den Spaltenraum von Q (mit orthonormalen Spalten) einfach $P = QQ^T$ lautet. Nun haben wir eine beliebige Matrix A (mit linear unabhängigen, aber nicht zwingend orthonormalen Spalten). Der projizierte Vektor ist $\vec{p} = A\hat{\vec{x}}$. Setzen Sie die Lösung $\hat{\vec{x}}$ aus der Normalengleichung dort ein und leiten Sie die *allgemeine Projektionsmatrix* P für eine beliebige Matrix A her!

7.3. Lineare Regression

Die bekannteste Anwendung dieses Prinzips ist die **Lineare Regression**. Wir haben eine Reihe von Datenpunkten $(t_1, y_1), (t_2, y_2), \dots, (t_m, y_m)$ und vermuten einen linearen Zusammenhang: $y = C + Dt$. Wir suchen den Achsenabschnitt C und die Steigung D .

Setzen wir unsere Datenpunkte in die gewünschte Geradengleichung ein, erhalten wir ein Gleichungssystem:

$$\begin{aligned} C + Dt_1 &= y_1 \\ C + Dt_2 &= y_2 \\ &\vdots \\ C + Dt_m &= y_m \end{aligned}$$

In Matrixschreibweise $A\vec{x} = \vec{b}$ ergibt das:

$$\begin{pmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{pmatrix} \begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Die erste Spalte von A besteht nur aus Einsen (für den konstanten Term C), die zweite Spalte enthält unsere Input-Daten t_i . Wir wenden einfach unsere Normalengleichung $A^T A \hat{\vec{x}} = A^T \vec{b}$ an, Achsenabschnitt und Steigung zu erhalten:

Beispiel (7.59): Lineare Regression für drei Messpunkte

Gegeben seien die Datenpunkte $(0, 1)$, $(1, 2)$, $(2, 4)$. Gesucht: beste Ausgleichsgerade $y = C + Dt$.

Schritt 1 – Aufstellen von A und $\vec{b}$:

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad \vec{b} = \begin{pmatrix} 1 \\ 2 \\ 4 \end{pmatrix}.$$

Schritt 2 – Normalengleichungen $A^T A \hat{x} = A^T \vec{b}$:

$$A^T A = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}, \quad A^T \vec{b} = \begin{pmatrix} 7 \\ 10 \end{pmatrix}.$$

Schritt 3 – LGS lösen:


$$3C + 3D = 7$$

$$3C + 5D = 10$$

Subtraktion: $2D = 3 \Rightarrow D = \frac{3}{2}$. Einsetzen: $C = \frac{5}{6}$.

Ergebnis: $\hat{y} = \frac{5}{6} + \frac{3}{2}t$. Residuen: $\vec{e} = (\frac{1}{6}, -\frac{1}{3}, \frac{1}{6})^T$, $|\vec{e}|^2 = \frac{1}{6}$.

Warum heißt es „kleinste Quadrate“ (Least Squares)? Die Geometrie maximiert die Orthogonalität. Algebraisch entspricht dies der Minimierung der Länge des Fehlervektors $|\vec{e}|^2$. Da $|\vec{e}|^2 = e_1^2 + e_2^2 + \dots + e_m^2$ ist, minimieren wir die *Summe der quadrierten vertikalen Abweichungen* zwischen unserer Geraden und den tatsächlichen Datenpunkten.



7.4. Für den kultivierten Data Scientist: Least Squares via QR-Zerlegung

In Lehrbüchern wird Least Squares fast immer über die Normalengleichungen

$$A^T A \hat{\vec{x}} = A^T \vec{b}$$

gelehrt. In der Praxis macht das aber niemand so.

Warum nicht? Das Berechnen von $A^T A$ quadriert die sogenannte Konditionszahl der Matrix. Wenn Ihre Daten auch nur leicht ungünstig skaliert sind (was bei realen Daten ständig passiert), wird die Matrix $(A^T A)$ numerisch so instabil, dass der Computer beim Invertieren extrem fehlerhafte Ergebnisse produziert.

Glücklicherweise gibt es eine bessere Methode: die **QR-Zerlegung**: Ersetzen wir in unserem ursprünglichen, überbestimmten Gleichungssystem $A\vec{x} \approx \vec{b}$ die Matrix A durch QR :

$$QR\hat{\vec{x}} \approx \vec{b}$$

Jetzt wenden wir denselben Trick wie bei der Normalengleichung an und multiplizieren von links mit A^T . Da $A = QR$ ist, ist $A^T = (QR)^T = R^T Q^T$.

$$(R^T Q^T)(QR\hat{\vec{x}}) = (R^T Q^T)\vec{b}$$

Jetzt nutzen wir aus, dass Q orthonormale Spalten hat und dass Matrix-Multiplikation assoziativ ist: In der Mitte kollabiert $Q^T Q$ zu E !

$$R^T R \hat{\vec{x}} = R^T Q^T \vec{b}$$

Da R (und damit auch R^T) für linear unabhängige Spalten von A invertierbar ist, können wir auf beiden Seiten mit $(R^T)^{-1}$ multiplizieren. Übrig bleibt eine ganz simple Gleichung:

$$\boxed{R\hat{\vec{x}} = Q^T \vec{b}}$$

Warum ist das so praktisch?

1. Wir müssen nie $A^T A$ berechnen! Die numerische Stabilität (Konditionszahl) bleibt perfekt erhalten.
2. Schauen Sie sich die linke Seite an: R ist eine *rechte obere Dreiecksmatrix*. Wir müssen keine Matrix invertieren! Wir können das Gleichungssystem für $\hat{\vec{x}}$ von unten nach oben durch simples Einsetzen (Rückwärtssubstitution) extrem schnell vom Computer lösen lassen.

Aufgabe (7.60)

Lösen Sie das Regressionsproblem aus Beispiel (7.59) (Datenpunkte $(0, 1)$, $(1, 2)$, $(2, 4)$) via *QR-Zerlegung* statt über die Normalengleichungen.

1. Berechnen Sie die QR-Zerlegung der Designmatrix $A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$ mittels Gram-Schmidt.
2. Bestimmen Sie $Q^T \vec{b}$ für $\vec{b} = (1, 2, 4)^T$.
3. Lösen Sie $R\hat{\vec{x}} = Q^T \vec{b}$ durch Rückwärtssubstitution und vergleichen Sie Ihr Ergebnis mit Beispiel (7.59).

Wiederholung (7.61): Kapitelzusammenfassung: Orthogonalität

Die zentralen Ergebnisse dieses Kapitels im Überblick:

- **Projektion** ($P^2 = P$): Eine orthogonale Projektionsmatrix ist zusätzlich symmetrisch ($P = P^T$). Für eine Matrix Q mit orthonormalen Spalten gilt: $P = QQ^T$.
- **Orthonormalbasis (ONB)**: Koordinaten erhält man durch einfache Skalarprodukte $\lambda_i = \langle \vec{x}, \vec{q}_i \rangle$ – Aufwand $O(n^2)$ statt $O(n^3)$ bei beliebiger Basis. Jeder Unterraum des $\mathbb{R}^n$ besitzt eine ONB (Theorem 8).
- **Gram-Schmidt-Verfahren**: Konstruiert iterativ eine ONB aus linear unabhängigen Vektoren. Zeitkomplexität: $\Theta(mn^2)$. Numerisch instabil – in der Praxis durch Householder ersetzt.
- **Orthogonale Matrizen**: $Q^T Q = E_n \Rightarrow Q^{-1} = Q^T$ (für quadratisches Q). Geometrisch: starre Transformationen (Rotationen, Spiegelungen), die Längen und Winkel erhalten.
- **QR-Zerlegung** ($A = QR$): $Q \in \mathbb{R}^{m \times n}$ orthonormal, $R \in \mathbb{R}^{n \times n}$ obere Dreiecksmatrix. Via Gram-Schmidt oder (numerisch stabiler) Householder-Spiegelungen. Zeitkomplexität: $O(mn^2)$, für $m \gg n$ linear in der Datenmenge.
- **Methode der kleinsten Quadrate**: Überbestimmte Systeme löst man durch Projektion auf den Spaltenraum. Normalengleichungen: $A^T A \hat{\vec{x}} = A^T \vec{b}$. Numerisch stabiler via QR: $R\hat{\vec{x}} = Q^T \vec{b}$.

A. Lösungen zu den Aktivierungsaufgaben**Lösung zu Aufgabe (7.4) (Projektionsmatrix für $y = 0$)**

Es gilt:

$$P\vec{x} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 0 \end{pmatrix} + x_2 \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} x_1 \\ 0 \end{pmatrix} = p(\vec{x}).$$

Lösung zu Aufgabe (7.6) (Projektionsmatrix für $y = x$)

Wir wenden p auf die Standardbasisvektoren an:

$$p(\vec{e}_1) = p\begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/2 \\ 1/2 \end{pmatrix}, \quad p(\vec{e}_2) = p\begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1/2 \\ 1/2 \end{pmatrix}.$$

Als Spalten ergibt sich:

$$P = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

Verifikation $P^2 = P$:

$$P^2 = \frac{1}{4} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = P. \quad \checkmark$$

Lösung zu Aufgabe (7.8) (Koordinaten bezüglich $\mathcal{B}_0, \mathcal{B}_1, \mathcal{B}_2$)

Gesucht: $\vec{x} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix} = \lambda_1 \vec{b}_1 + \lambda_2 \vec{b}_2.$

Basis $\mathcal{B}_0$: Direkt ablesbar: $(\lambda_1, \lambda_2) = (2, 4).$

Basis $\mathcal{B}_1$: LGS $\lambda_1 \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} + \lambda_2 \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix}:$

$$\lambda_1 + \lambda_2 = 2, \quad \lambda_1 - 2\lambda_2 = 4 \quad \Rightarrow \quad 3\lambda_2 = -2 \quad \Rightarrow \quad \lambda_2 = -\frac{2}{3}, \quad \lambda_1 = \frac{8}{3}.$$

Basis $\mathcal{B}_2$: LGS $\lambda_1 \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} + \lambda_2 \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix}:$

$$\frac{\lambda_1 + \lambda_2}{\sqrt{2}} = 2 \Rightarrow \lambda_1 + \lambda_2 = 2\sqrt{2}, \quad \frac{\lambda_1 - \lambda_2}{\sqrt{2}} = 4 \Rightarrow \lambda_1 - \lambda_2 = 4\sqrt{2}.$$

Addition und Subtraktion ergibt: $\lambda_1 = 3\sqrt{2}, \quad \lambda_2 = -\sqrt{2}.$ Auffällig: Das LGS für $\mathcal{B}_2$ entkoppelt sofort – der Grund dafür wird im nächsten Abschnitt klar.

Lösung zu Aufgabe (7.10) (Aufwand LGS)

- **LR-Zerlegung:** $\approx \frac{2}{3}n^3$ Operationen $\Rightarrow O(n^3)$.
- **Vorwärtssubstitution** ($L\vec{z} = \vec{x}$): $O(n^2)$ Operationen.
- **Rückwärtssubstitution** ($R\vec{\lambda} = \vec{z}$): $O(n^2)$ Operationen.

Der Gesamtaufwand wird durch die LR-Zerlegung dominiert: $O(n^3)$ Operationen.

Lösung zu Aufgabe (7.11) (Aufwandsvergleich)

- **Beliebige Basis:** LGS lösen $\Rightarrow O(n^3)$ Operationen.
- **ONB:** n Skalarprodukte à n Multiplikationen/Additionen $\Rightarrow O(n^2)$ Operationen.

Bei $n = 500.000$ ist der Unterschied enorm: statt $\sim 10^{17}$ nur $\sim 10^{11}$ Operationen.

Lösung zu Aufgabe (7.12) (Verifikation ONB-Koordinaten für B_2)

Mit $\vec{b}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$ und $\vec{b}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}$:

$$\lambda_1 = \langle \vec{x}, \vec{b}_1 \rangle = 3\sqrt{2}, \quad \lambda_2 = \langle \vec{x}, \vec{b}_2 \rangle = -\sqrt{2}.$$

$$\text{Probe: } 3\sqrt{2} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} + (-\sqrt{2}) \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \\ 0 \end{pmatrix} + \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 0 \end{pmatrix}. \checkmark$$

Lösung zu Aufgabe (7.15) (ONB verifizieren; Koordinaten für $\vec{x} = (0, 3, 0)^T$)

Orthogonalität:

$$\langle \vec{q}_1, \vec{q}_2 \rangle = \frac{1}{2} - \frac{1}{2} = 0, \quad \langle \vec{q}_1, \vec{q}_3 \rangle = 0, \quad \langle \vec{q}_2, \vec{q}_3 \rangle = 0. \quad \checkmark$$

Normiertheit: $|\vec{q}_1| = |\vec{q}_2| = \sqrt{\frac{1}{2} + \frac{1}{2}} = 1, \quad |\vec{q}_3| = 1. \quad \checkmark$

Koordinaten:

$$\lambda_1 = \langle \vec{x}, \vec{q}_1 \rangle = \frac{3}{\sqrt{2}} = \frac{3\sqrt{2}}{2}, \quad \lambda_2 = \langle \vec{x}, \vec{q}_2 \rangle = -\frac{3}{\sqrt{2}} = -\frac{3\sqrt{2}}{2}, \quad \lambda_3 = \langle \vec{x}, \vec{q}_3 \rangle = 0.$$

$$\text{Probe: } \frac{3\sqrt{2}}{2} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} - \frac{3\sqrt{2}}{2} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 3/2 \\ 3/2 \\ 0 \end{pmatrix} + \begin{pmatrix} -3/2 \\ 3/2 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \\ 0 \end{pmatrix}. \checkmark$$

Lösung zu Aufgabe (7.19) (Gram-Schmidt für $\vec{v}_1 = (3, 4)^\top$, $\vec{v}_2 = (-1, 2)^\top$)

Schritt 1: $|\vec{v}_1| = \sqrt{9 + 16} = 5$, also $\vec{q}_1 = \frac{1}{5} \begin{pmatrix} 3 \\ 4 \end{pmatrix}$.

Schritt 2: Anteil in Richtung $\vec{q}_1$: $\lambda = \langle \vec{v}_2, \vec{q}_1 \rangle = \frac{-3+8}{5} = 1$.

$$\vec{y}_2 = \begin{pmatrix} -1 \\ 2 \end{pmatrix} - 1 \cdot \frac{1}{5} \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} -8/5 \\ 6/5 \end{pmatrix}, \quad |\vec{y}_2| = \frac{1}{5} \sqrt{64 + 36} = 2.$$

$$\vec{q}_2 = \frac{\vec{y}_2}{|\vec{y}_2|} = \begin{pmatrix} -4/5 \\ 3/5 \end{pmatrix}.$$

Probe: $\langle \vec{q}_1, \vec{q}_2 \rangle = \frac{3}{5} \cdot \left(-\frac{4}{5}\right) + \frac{4}{5} \cdot \frac{3}{5} = 0$. ✓

Lösung zu Aufgabe (7.24) (Ist $Q = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ orthogonal?)

$$Q^\top Q = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = E_2. \quad \checkmark$$

Ja, Q ist orthogonal. Geometrisch ist Q die Spiegelung an der x -Achse.

Lösung zu Aufgabe (7.28) (Längen- und Winkelerhaltung aus Lemma)

Sei $\langle Q\vec{x}, Q\vec{y} \rangle = \langle \vec{x}, \vec{y} \rangle$ für alle $\vec{x}, \vec{y}$.

Länge: Setze $\vec{y} = \vec{x}$: $|Q\vec{x}|^2 = \langle Q\vec{x}, Q\vec{x} \rangle = \langle \vec{x}, \vec{x} \rangle = |\vec{x}|^2$, also $|Q\vec{x}| = |\vec{x}|$.

Winkel: Der Winkel θ' zwischen $Q\vec{x}$ und $Q\vec{y}$ erfüllt:

$$\cos \theta' = \frac{\langle Q\vec{x}, Q\vec{y} \rangle}{|Q\vec{x}| |Q\vec{y}|} = \frac{\langle \vec{x}, \vec{y} \rangle}{|\vec{x}| |\vec{y}|} = \cos \theta. \quad \checkmark$$

Lösung zu Aufgabe (7.33) (Drehung $\circ$ Spiegelung)

Die Spiegelung an der Geraden im Winkel 30° hat $\varphi = 60^\circ$:

$$S = \begin{pmatrix} \cos 60^\circ & \sin 60^\circ \\ \sin 60^\circ & -\cos 60^\circ \end{pmatrix}, \quad R(75^\circ) = \begin{pmatrix} \cos 75^\circ & -\sin 75^\circ \\ \sin 75^\circ & \cos 75^\circ \end{pmatrix}.$$

Mit den Additionstheoremen aus Beispiel (7.32):

$$Q = S \cdot R(75^\circ) = \begin{pmatrix} \cos(60^\circ - 75^\circ) & -\sin(60^\circ - 75^\circ) \\ -\sin(60^\circ - 75^\circ) & -\cos(60^\circ - 75^\circ) \end{pmatrix} = \begin{pmatrix} \cos 15^\circ & \sin(-15^\circ) \\ \sin(-15^\circ) & -\cos 15^\circ \end{pmatrix}.$$

Dies ist eine **Spiegelungsmatrix** (an der Geraden im Winkel $-7,5^\circ$). Geometrisch: Drehung $\cdot$ Spiegelung = Spiegelung – konsistent mit dem Muster aus Abschnitt 5.

Lösung zu Aufgabe (7.36) (Householder: symmetrisch und orthogonal)

Symmetrie:

$$H_{\vec{u}}^T = (E_n - 2\vec{u}\vec{u}^T)^T = E_n - 2(\vec{u}\vec{u}^T)^T = E_n - 2\vec{u}\vec{u}^T = H_{\vec{u}}. \quad \checkmark$$

Orthogonalität (mit $H_{\vec{u}} = H_{\vec{u}}^T$):

$$H_{\vec{u}}^T H_{\vec{u}} = H_{\vec{u}}^2 = (E_n - 2\vec{u}\vec{u}^T)^2 = E_n - 4\vec{u}\vec{u}^T + 4\vec{u} \underbrace{(\vec{u}^T \vec{u})}_{=1} \vec{u}^T = E_n. \quad \checkmark$$

Lösung zu Aufgabe (7.40) ($P = QQ^T$ für quadratisches Q)Ist $Q \in \mathbb{R}^{n \times n}$ orthogonal, so gilt $QQ^T = E_n$, also $P = QQ^T = E_n$.Der Projektionsfehler ist $\vec{b} - P\vec{b} = \vec{b} - E_n\vec{b} = \vec{0}$.Geometrisch: Die Spalten von Q bilden eine ONB des gesamten $\mathbb{R}^n$ – jeder Vektor liegt schon im Unterraum, es gibt keinen Informationsverlust.**Lösung zu Aufgabe (7.43) (Projektion auf eine Gerade im $\mathbb{R}^3$)**(a) Projektionsmatrix: Normieren von $\vec{d}$: $\vec{q} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$.

$$P = \vec{q}\vec{q}^T = \frac{1}{2} \begin{pmatrix} 1 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & 0 & 1 \end{pmatrix}.$$

(b) Projektion und Fehler:

$$\vec{p} = P\vec{b} = \frac{1}{2} \begin{pmatrix} 3 \\ 0 \\ 3 \end{pmatrix} = \begin{pmatrix} 3/2 \\ 0 \\ 3/2 \end{pmatrix}, \quad \vec{e} = \vec{b} - \vec{p} = \begin{pmatrix} -1/2 \\ 2 \\ 1/2 \end{pmatrix}.$$

(c) Orthogonalität:

$$\langle \vec{d}, \vec{e} \rangle = 1 \cdot \left(-\frac{1}{2}\right) + 0 \cdot 2 + 1 \cdot \frac{1}{2} = 0. \quad \checkmark$$

Probe (Pythagoras): $|\vec{p}|^2 + |\vec{e}|^2 = \frac{9}{2} + \frac{9}{2} = 9 = |\vec{b}|^2. \quad \checkmark$ **Lösung zu Aufgabe (7.44) (Projektion und Fehlervektor)**Mit $P = \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}$ und $\vec{x} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$:

1. $\vec{p} = P\vec{x} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$
2. $\vec{e} = \vec{x} - \vec{p} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$
3. $\langle \vec{p}, \vec{e} \rangle = 3 \cdot 1 + 3 \cdot (-1) = 0. \quad \checkmark$

Lösung zu Aufgabe (7.48) (QR-Zerlegung via Gram-Schmidt für

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 2 & 1 \end{pmatrix}$$

Schritt 1 ($k = 1$):

$$r_{11} = |(1, 2, 2)^T| = 3, \quad \vec{q}_1 = \frac{1}{3} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

Schritt 2 ($k = 2$):

$$r_{12} = \langle \vec{a}_2, \vec{q}_1 \rangle = \frac{2+2+2}{3} = 2.$$

$$\vec{y}_2 = \begin{pmatrix} 2 \\ 1 \\ 1 \end{pmatrix} - 2 \cdot \frac{1}{3} \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 4/3 \\ -1/3 \\ -1/3 \end{pmatrix}, \quad r_{22} = |\vec{y}_2| = \sqrt{\frac{16+1+1}{9}} = \sqrt{2}.$$

$$\vec{q}_2 = \frac{1}{\sqrt{2}} \cdot \frac{1}{3} \begin{pmatrix} 4 \\ -1 \\ -1 \end{pmatrix} = \frac{1}{3\sqrt{2}} \begin{pmatrix} 4 \\ -1 \\ -1 \end{pmatrix}.$$

Ergebnis:

$$Q = \begin{pmatrix} \frac{1}{3} & \frac{4}{3\sqrt{2}} \\ \frac{2}{3} & -\frac{1}{3\sqrt{2}} \\ \frac{2}{3} & -\frac{1}{3\sqrt{2}} \end{pmatrix}, \quad R = \begin{pmatrix} 3 & 2 \\ 0 & \sqrt{2} \end{pmatrix}.$$

Probe: $QR = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 2 & 1 \end{pmatrix} = A. \checkmark$

Lösung zu Aufgabe (7.53) (Householder-QR für $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$)**(a) Householder-Matrix** (erste Spalte $\vec{a}_1 = (3, 4)^T$, identisch zum Beispiel):

$$H = \begin{pmatrix} -\frac{3}{5} & -\frac{4}{5} \\ -\frac{4}{5} & \frac{3}{5} \end{pmatrix}.$$

(b) $R = HA$:

$$R = \begin{pmatrix} -\frac{3}{5} & -\frac{4}{5} \\ -\frac{4}{5} & \frac{3}{5} \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} = \begin{pmatrix} -\frac{9}{5} - \frac{16}{5} & 0 - 4 \\ -\frac{12}{5} + \frac{12}{5} & 0 + 3 \end{pmatrix} = \begin{pmatrix} -5 & -4 \\ 0 & 3 \end{pmatrix}.$$

Da $H = H^T = H^{-1}$, ist $Q = H$ und $A = QR$.

Probe: $QR = H \cdot \begin{pmatrix} -5 & -4 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} = A. \checkmark$

Lösung zu Aufgabe (7.58) (Allgemeine Projektionsmatrix P_A)

Aus der Normalengleichung folgt $\hat{\vec{x}} = (A^T A)^{-1} A^T \vec{b}$. Der projizierte Vektor ist:

$$\vec{p} = A \hat{\vec{x}} = A(A^T A)^{-1} A^T \vec{b}.$$

Da dies für alle $\vec{b}$ gilt, ist die allgemeine Projektionsmatrix:

$$P = A(A^T A)^{-1} A^T.$$

Für den Spezialfall orthonormaler Spalten ($A^T A = E$) vereinfacht sich das zu $P = A E A^T = A A^T = Q Q^T$. ✓

Lösung zu Aufgabe (7.60) (Lineare Regression via QR-Zerlegung)

Schritt 1 – QR-Zerlegung von A : Mit $\vec{a}_1 = (1, 1, 1)^T$ und $\vec{a}_2 = (0, 1, 2)^T$:

$$r_{11} = \sqrt{3}, \quad \vec{q}_1 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad r_{12} = \langle \vec{a}_2, \vec{q}_1 \rangle = \frac{3}{\sqrt{3}} = \sqrt{3}$$

$$\vec{y}_2 = \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} - \sqrt{3} \cdot \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}, \quad r_{22} = \sqrt{2}, \quad \vec{q}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$$

$$Q = \begin{pmatrix} \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & 0 \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} \end{pmatrix}, \quad R = \begin{pmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{pmatrix}$$

Schritt 2 – Rechte Seite:

$$Q^T \vec{b} = \begin{pmatrix} \frac{1+2+4}{\sqrt{3}} \\ \frac{-1+0+4}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{7}{\sqrt{3}} \\ \frac{3}{\sqrt{2}} \end{pmatrix}$$

Schritt 3 – Rückwärtssubstitution:

$$\begin{aligned} \sqrt{2} D &= \frac{3}{\sqrt{2}} & \Rightarrow D &= \frac{3}{2} \\ \sqrt{3} C + \sqrt{3} \cdot \frac{3}{2} &= \frac{7}{\sqrt{3}} & \Rightarrow C &= \frac{7}{3} - \frac{3}{2} = \frac{5}{6} \end{aligned}$$

Ergebnis: $\hat{y} = \frac{5}{6} + \frac{3}{2} t$ – identisch mit Beispiel (7.59). ✓

Lösung zu Aufgabe (7.50) (Householder-Normalenvektor für $\vec{a} = (0, 3, 4)^\top$)**(a) Herleitung von $\vec{u}$:**

$$|\vec{a}| = \sqrt{0 + 9 + 16} = 5, \quad a_1 = 0 \Rightarrow \text{sign}(0) = 1.$$

Der Zielvektor und der Differenzvektor sind:

$$\vec{p} = -\text{sign}(0) \cdot 5 \vec{e}_1 = \begin{pmatrix} -5 \\ 0 \\ 0 \end{pmatrix}, \quad \vec{v} = \vec{a} - \vec{p} = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix} - \begin{pmatrix} -5 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 5 \\ 3 \\ 4 \end{pmatrix}.$$

$$|\vec{v}| = \sqrt{25 + 9 + 16} = \sqrt{50} = 5\sqrt{2}, \quad \vec{u} = \frac{\vec{v}}{|\vec{v}|} = \frac{1}{5\sqrt{2}} \begin{pmatrix} 5 \\ 3 \\ 4 \end{pmatrix}.$$

(b) Verifikation $H_{\vec{u}}\vec{a} = \vec{p}$:

$$\vec{u}^\top \vec{a} = \frac{1}{5\sqrt{2}} (5 \cdot 0 + 3 \cdot 3 + 4 \cdot 4) = \frac{25}{5\sqrt{2}} = \frac{5}{\sqrt{2}}.$$

$$H_{\vec{u}}\vec{a} = \vec{a} - 2(\vec{u}^\top \vec{a}) \vec{u} = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix} - 2 \cdot \frac{5}{\sqrt{2}} \cdot \frac{1}{5\sqrt{2}} \begin{pmatrix} 5 \\ 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \\ 4 \end{pmatrix} - \begin{pmatrix} 5 \\ 3 \\ 4 \end{pmatrix} = \begin{pmatrix} -5 \\ 0 \\ 0 \end{pmatrix} = -5 \vec{e}_1. \quad \checkmark$$

(c) Numerische Begründung: Bei $a_1 > 0$ und $\vec{v} = \vec{a} - |\vec{a}| \vec{e}_1$ wäre die erste Komponente $v_1 = a_1 - |\vec{a}|$. Wenn $\vec{a}$ fast parallel zu $\vec{e}_1$ liegt (d. h. $a_1 \approx |\vec{a}|$), wird v_1 sehr klein. Die Subtraktion zweier fast gleicher Zahlen verursacht starken **Auslöschungsfehler**: die Differenz hat viel weniger gültige Stellen als die Operanden. Mit $\text{sign}(a_1) \cdot |\vec{a}|$ in der Addition wird dagegen $|v_1| = a_1 + |\vec{a}| \geq |\vec{a}|$ – stets groß und numerisch stabil.

B. Beweise zu ausgewählten Sätzen

Satz 8: Existenz einer Orthonormalbasis

Beweis von Satz 8. Sei $U = \text{span}(\{\vec{x}_1, \dots, \vec{x}_k\})$ ein linearer Unterraum der Dimension $k \geq 1$. Wir erzeugen induktiv eine ONB $\{\vec{q}_1, \dots, \vec{q}_k\}$ durch das **Gram-Schmidt-Verfahren**:

$$\begin{aligned}\vec{q}_1 &= \frac{\vec{x}_1}{|\vec{x}_1|} \\ \vec{q}_2 &= \frac{\vec{y}_2}{|\vec{y}_2|}, \quad \vec{y}_2 = \vec{x}_2 - \langle \vec{x}_2, \vec{q}_1 \rangle \vec{q}_1 \\ &\vdots \\ \vec{q}_k &= \frac{\vec{y}_k}{|\vec{y}_k|}, \quad \vec{y}_k = \vec{x}_k - \sum_{i=1}^{k-1} \langle \vec{x}_k, \vec{q}_i \rangle \vec{q}_i\end{aligned}$$

Behauptung: Für alle $j = 1, \dots, k$ gilt (1) $\text{span}(\{\vec{x}_1, \dots, \vec{x}_j\}) = \text{span}(\{\vec{q}_1, \dots, \vec{q}_j\})$ und (2) $\{\vec{q}_1, \dots, \vec{q}_j\}$ ist orthonormal.

Beweis per vollständiger Induktion nach j:

Induktionsanfang ($j = 1$): $\text{span}(\{\vec{q}_1\}) = \text{span}(\{\vec{x}_1\}) \Rightarrow$ (1) $\checkmark$. Da $|\vec{q}_1| = 1$, ist $\{\vec{q}_1\}$ orthonormal $\Rightarrow$ (2) $\checkmark$.

Induktionsschritt ($j \rightarrow j+1$): Gelte (1)+(2) für $\{\vec{q}_1, \dots, \vec{q}_j\}$.

Zu (1):

$$\vec{y}_{j+1} = \vec{x}_{j+1} - \sum_{i=1}^j \underbrace{\langle \vec{x}_{j+1}, \vec{q}_i \rangle}_{\in \mathbb{R}} \vec{q}_i \in \text{span}(\{\vec{x}_1, \dots, \vec{x}_{j+1}\})$$

da $\vec{q}_i \stackrel{(1)}{\in} \text{span}(\{\vec{x}_1, \dots, \vec{x}_j\})$. Also $\text{span}(\{\vec{q}_1, \dots, \vec{q}_{j+1}\}) \subseteq \text{span}(\{\vec{x}_1, \dots, \vec{x}_{j+1}\})$. Andererseits ist $\vec{x}_{j+1} = |\vec{y}_{j+1}| \vec{q}_{j+1} + \sum_{i=1}^j \langle \vec{x}_{j+1}, \vec{q}_i \rangle \vec{q}_i$, also $\text{span}(\{\vec{x}_1, \dots, \vec{x}_{j+1}\}) \subseteq \text{span}(\{\vec{q}_1, \dots, \vec{q}_{j+1}\})$, damit Gleichheit $\Rightarrow$ (1) $\checkmark$.

Zu (2): $|\vec{q}_{j+1}| = 1$ nach Konstruktion. Für $l = 1, \dots, j$:

$$\begin{aligned}\langle \vec{q}_{j+1}, \vec{q}_l \rangle &= \frac{1}{|\vec{y}_{j+1}|} \left(\langle \vec{x}_{j+1}, \vec{q}_l \rangle - \sum_{i=1}^j \langle \vec{x}_{j+1}, \vec{q}_i \rangle \underbrace{\langle \vec{q}_i, \vec{q}_l \rangle}_{=\delta_{il}} \right) \\ &= \frac{1}{|\vec{y}_{j+1}|} (\langle \vec{x}_{j+1}, \vec{q}_l \rangle - \langle \vec{x}_{j+1}, \vec{q}_l \rangle) = 0 \quad \checkmark\end{aligned}$$

■

Satz 10: Eindeutigkeit der orthogonalen Zerlegung

Beweis von Eindeutigkeit in Satz 10. Angenommen, es gibt zwei Zerlegungen $\vec{b} = \vec{b}_U + \vec{b}_{U^\perp} = \vec{b}'_U + \vec{b}'_{U^\perp}$. Dann gilt:

$$\underbrace{\vec{b}_U - \vec{b}'_U}_{\in U} = \underbrace{\vec{b}'_{U^\perp} - \vec{b}_{U^\perp}}_{\in U^\perp}$$

Sei $\vec{w} := \vec{b}_U - \vec{b}'_U$. Dann liegt $\vec{w}$ gleichzeitig in U (als Differenz zweier Vektoren aus U) und in $U^\perp$ (als Differenz zweier Vektoren aus $U^\perp$). Da $\vec{w} \in U^\perp$, steht $\vec{w}$ insbesondere senkrecht auf sich selbst:

$$\langle \vec{w}, \vec{w} \rangle = 0$$

Das ist nur möglich für $\vec{w} = \vec{0}$, also $\vec{b}_U = \vec{b}'_U$. Aus der ursprünglichen Gleichung $\vec{b}_U - \vec{b}'_U = \vec{b}'_{U^\perp} - \vec{b}_{U^\perp}$ folgt dann sofort auch $\vec{b}_{U^\perp} = \vec{b}'_{U^\perp}$. ■

Satz 11: Householder-Spiegelung auf die Koordinatenachse

Beweis von Satz 11. Wir wollen zeigen, dass $H\vec{a} = \vec{p}$ gilt, wobei

$$\vec{p} = -\text{sign}(a_1) \cdot |\vec{a}| \vec{e}_1$$

der Zielvektor auf der Koordinatenachse ist und die Householder-Matrix durch den Spiegelvektor $\vec{v} = \vec{a} - \vec{p}$ definiert wird:

$$H = E_m - 2 \frac{\vec{v} \vec{v}^T}{\vec{v}^T \vec{v}}.$$

Warum diese Wahl von $\vec{v}$? Geometrisch ist die Spiegelebene genau die Mittelsenkrechte zwischen $\vec{a}$ und $\vec{p}$. Der Normalenvektor dieser Ebene zeigt von $\vec{p}$ nach $\vec{a}$, also $\vec{v} = \vec{a} - \vec{p}$.

Einsetzen liefert:

$$H\vec{a} = \vec{a} - 2 \frac{\vec{v}^T \vec{a}}{\vec{v}^T \vec{v}} \vec{v}$$

Es genügt zu zeigen, dass $2 \frac{\vec{v}^T \vec{a}}{\vec{v}^T \vec{v}} = 1$, denn dann gilt $H\vec{a} = \vec{a} - \vec{v} = \vec{a} - (\vec{a} - \vec{p}) = \vec{p}$.

Da Householder-Spiegelungen längenerhaltend sind, gilt $|\vec{a}|^2 = |\vec{p}|^2$. Wir berechnen Zähler und Nenner separat:

$$\begin{aligned} \vec{v}^T \vec{v} &= (\vec{a} - \vec{p})^T (\vec{a} - \vec{p}) \\ &= |\vec{a}|^2 - 2\vec{p}^T \vec{a} + |\vec{p}|^2 \\ &= 2|\vec{a}|^2 - 2\vec{p}^T \vec{a} \quad (|\vec{a}|^2 = |\vec{p}|^2) \\ &= 2 \left(|\vec{a}|^2 - \vec{p}^T \vec{a} \right) \end{aligned}$$

$$\begin{aligned} \vec{v}^T \vec{a} &= (\vec{a} - \vec{p})^T \vec{a} \\ &= |\vec{a}|^2 - \vec{p}^T \vec{a} \end{aligned}$$

Der Nenner $\vec{v}^T \vec{v}$ ist exakt doppelt so groß wie der Zähler $\vec{v}^T \vec{a}$, also:

$$2 \frac{\vec{v}^T \vec{a}}{\vec{v}^T \vec{v}} = 2 \cdot \frac{|\vec{a}|^2 - \vec{p}^T \vec{a}}{2(|\vec{a}|^2 - \vec{p}^T \vec{a})} = 1$$

■