

INHALTSVERZEICHNIS

9. Positiv definite Matrizen	2
1. Motivation: Kovarianzmatrizen messen gemeinsame Streuung	2
2. Erste Charakterisierung: positive Eigenwerte	7
3. Zweite Charakterisierung: die quadratische Form	10
4. Dritte Charakterisierung: führende Hauptminoren	15
5. Vierte Charakterisierung: positive Pivots	19
6. Cholesky-Zerlegung und fünfte Charakterisierung	22
7. Positiv semidefinite Matrizen	30
A. Lösungen zu den Aktivierungsaufgaben	34
B. Beweis der Äquivalenz der Charakterisierungen	40
C. Python-Skripte zu den Aktivierungen	44

Kapitel 9

POSITIV DEFINITE MATRIZEN

1. Motivation: Kovarianzmatrizen messen gemeinsame Streuung

Lernziele (9.1)

Nach diesem Abschnitt können Sie...

- eine zentrierte Datenmatrix aus Beobachtungen und Merkmalen beschreiben,
- die empirische Kovarianzmatrix als $S = \frac{1}{n-1} A^\top A$ berechnen,
- erklären, warum Kovarianzmatrizen immer symmetrisch sind,
- an der quadratischen Form $\vec{x}^\top S \vec{x}$ erkennen, warum Kovarianzmatrizen keine negativen Eigenwerte besitzen, und
- den Übergang von **positiv semidefinit** zu **positiv definit** motivieren.

In Data Science arbeiten wir **selten mit einzelnen Zahlen**. Meist haben wir viele Beobachtungen und mehrere Merkmale: Körpergröße, Gewicht, Alter, Einkommen, Pixelintensitäten, Sensormesswerte oder Aktivierungen in einem neuronalen Netz. Unser Ziel ist es dann, aus den **Rohdaten Informationen über die gemeinsamen Streuungen der Merkmale zu gewinnen**: Geht ein hoher Konsum von Nürnberger Rostbratwürsten mit einer hohen Zustimmung zu Markus Söder einher? Gibt es einen linearen Zusammenhang zwischen Bierkonsum und Prüfungsleistungen? Diese **Informationen sind in der sogenannten (empirischen) Kovarianzmatrix enthalten**.

Der Einfachheit halber betrachten wir zunächst nur **zentrierte Daten**, also Daten, bei denen von jedem Merkmal bereits der **Mittelwert abgezogen** wurde. Dies hat keinen Einfluss auf die Streuung der Daten, aber vereinfacht die Berechnung der Kovarianzmatrix erheblich. Haben wir zum Beispiel Probanden $\vec{x}_1, \dots, \vec{x}_n$ mit jeweils **m** Merkmalen, dann

erhalten wir die **zentrierte Datenmatrix** A durch:

$$A = \begin{pmatrix} \vec{a}_1^*{}^\top \\ \vdots \\ \vec{a}_n^*{}^\top \end{pmatrix} \quad \text{mit} \quad \vec{a}_i^* = \vec{x}_i - \underbrace{\frac{1}{n} \sum_{j=1}^n \vec{x}_j}_{\text{empirischer Mittelwert}}$$

(haben Sie die Bezeichnung $\vec{a}_i^*$ schon vermisst?)¹. Insbesondere gilt $\vec{1}^\top A = \vec{0}^\top$.

Für eine zentrierte Datenmatrix

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix} \in \mathbb{R}^{n \times m}$$

mit m Merkmalen und n Beobachtungen ist die empirische Kovarianz zwischen Merkmal i und Merkmal k gegeben durch

$$\text{Cov}_{ik} = \frac{1}{n-1} \sum_{j=1}^n a_{ji} a_{jk}.$$

Das ist ein Skalarprodukt der beiden Merkmalsspalten $\vec{a}_i$ und $\vec{a}_k$, nur noch durch $n-1$ geteilt:

$$\text{Cov}_{ik} = \frac{1}{n-1} \vec{a}_i^\top \vec{a}_k.$$

Anmerkung: Wenn Sie sich fragen, wieso wir hier $n-1$ statt n verwenden, können Sie sich die sehr empfehlenswerte Youtube-Serie von Sam Levey zu *Freiheitsgraden* ansehen: <https://youtu.be/VDlnu096p58?si=rmlRpdsH99cxwCBg>. Wir beschränken uns hier aber auf die objektiv bessere Mathematik: Lineare Algebra.

Definition (9.2): Empirische Kovarianzmatrix

Ist $A \in \mathbb{R}^{n \times m}$ eine zentrierte Datenmatrix, deren Zeilen die n Beobachtungen und deren Spalten die m Merkmale enthalten, dann heißt

$$S = \frac{1}{n-1} A^\top A$$

die **empirische Kovarianzmatrix** der Daten.

¹In manchen mathematischen Darstellungen werden Beobachtungen stattdessen als Spalten angeordnet. Beide Konventionen sind äquivalent, für uns bietet die „Zeilen“-Darstellung allerdings einige rechnerische Vorteile

Für die Einträge von S gilt

$$s_{ik} = \text{Cov}_{ik} = \frac{1}{n-1} \sum_{j=1}^n a_{ji} a_{jk}.$$

Insbesondere gilt $s_{ii} = \text{Var}_i$: Auf der Diagonale stehen die Varianzen der einzelnen Merkmale.

$$\begin{array}{ccc} \text{zentrierte Daten} & & \text{Kovarianzen} \\ A = \begin{pmatrix} \text{Beobachtung 1} \\ \text{Beobachtung 2} \\ \vdots \\ \text{Beobachtung } n \end{pmatrix} & \xrightarrow{\frac{1}{n-1} A^\top A} & S = \begin{pmatrix} \text{Var}_1 & \text{Cov}_{12} & \cdots & \text{Cov}_{1m} \\ \text{Cov}_{21} & \text{Var}_2 & \cdots & \text{Cov}_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}_{m1} & \text{Cov}_{m2} & \cdots & \text{Var}_m \end{pmatrix} \end{array}$$

Aus Rohdaten wird eine Matrix gemeinsamer Streuungen.

Beispiel (9.3): Kovarianzmatrix berechnen

Für

$$A = \begin{pmatrix} 2 & 0 \\ -1 & 1 \\ -1 & -1 \end{pmatrix}$$

gilt

$$A^\top A = \begin{pmatrix} 2 & 0 \\ -1 & 1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} 2 & -1 & -1 \\ 0 & 1 & -1 \end{pmatrix} = \begin{pmatrix} 6 & 0 \\ 0 & 2 \end{pmatrix}.$$

Da $n = 3$ Beobachtungen vorliegen, ist

$$S = \frac{1}{3-1} A^\top A = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}.$$

Das erste Merkmal hat also empirische Varianz 3, das zweite Varianz 1, und die beiden Merkmale haben Kovarianz 0 (d.h., sie sind unkorreliert).

Kovarianzmatrizen haben zwei essenzielle Eigenschaften:

Kovarianzmatrizen sind symmetrisch und haben nur nicht-negative Eigenwerte.

Bemerkung (9.4): Warum ist eine Kovarianzmatrix symmetrisch?

Transponieren vertauscht die Reihenfolge der Faktoren:

$$S^T = \left(\frac{1}{n-1} A^T A \right)^T = \frac{1}{n-1} A^T A = S.$$

Inhaltlich ist das auch plausibel: Die Kovarianz von Merkmal i mit Merkmal k ist dieselbe Zahl wie die Kovarianz von Merkmal k mit Merkmal i .

$$\text{Cov}_{ik} = \text{Cov}_{ki}.$$

Bemerkung (9.5): Warum können keine negativen Eigenwerte auftreten?

Nehmen wir irgendeine Richtung $\vec{x} \in \mathbb{R}^m$. Dann können wir $A\vec{x}$ als Kombination der Spalten von A lesen, also als neues Merkmal, das aus den ursprünglichen Merkmalen durch die Gewichtung mit $\vec{x}$ entsteht. Die Zahl

$$\vec{x}^T S \vec{x}$$

ist dann die Streuung der Daten in dieser kombinierten Merkmalsrichtung, d.h., die Varianz von $A\vec{x}$. Für eine Kovarianzmatrix ist das immer eine quadrierte Länge:

$$\vec{x}^T S \vec{x} = \frac{1}{n-1} \vec{x}^T A^T A \vec{x} = \frac{1}{n-1} (A\vec{x})^T (A\vec{x}) = \boxed{\frac{1}{n-1} \|A\vec{x}\|^2 \geq 0}.$$

Intuitiv ist das klar: Streuung kann nicht negativ sein.

Setzen wir speziell einen Eigenvektor $\vec{v} \neq \vec{0}$ von S ein, also $S\vec{v} = \lambda\vec{v}$, dann folgt

$$0 \leq \vec{v}^T S \vec{v} = \vec{v}^T \lambda \vec{v} = \lambda \|\vec{v}\|^2.$$

Da $\|\vec{v}\|^2 > 0$ ist, muss $\lambda \geq 0$ gelten. Kovarianzmatrizen haben also nur nichtnegative Eigenwerte.

Kovarianzmatrizen sind nicht die einzigen Matrizen, die keine negativen Eigenwerte haben. Allgemein bezeichnen wir solche Matrizen als **positiv semidefinit**.

Definition (9.6): Positiv semidefinit als erste Beobachtung

Eine symmetrische Matrix $S \in \mathbb{R}^{m \times m}$ heißt **positiv semidefinit**, wenn

$$\vec{x}^T S \vec{x} \geq 0 \quad \text{für alle } \vec{x} \in \mathbb{R}^m$$

gilt (in Abschnitt 7 sehen wir, dass dies äquivalent zur Bedingung ist, dass alle Eigenwerte nicht negativ sind).

Bezeichnung: $\vec{x}^T S \vec{x}$ heißt die **quadratische Form** oder **Energie** zu S .

Aufgabe (9.7): Kovarianzmatrix

Gegeben sei die zentrierte Datenmatrix

$$A = \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ -1 & -1 \end{pmatrix}.$$

1. Berechnen Sie $S = \frac{1}{2}A^\top A$.
2. Lesen Sie aus S die Varianzen der beiden Merkmale und ihre Kovarianz ab.
3. Überprüfen Sie für $\vec{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$, dass $\vec{x}^\top S \vec{x} \geq 0$ gilt.
4. Erklären Sie in einem Satz, warum dieses Ergebnis für jeden Vektor $\vec{x}$ gelten muss.

Bemerkung (9.8): Von semidefinit zu definit

Bei Kovarianzmatrizen kann eine Richtung Streuung 0 haben. Das passiert, wenn die Daten in dieser Richtung gar nicht variieren. Dann ist

$$\vec{x}^\top S \vec{x} = 0$$

für einen Vektor $\vec{x} \neq \vec{0}$. Solche Matrizen sind positiv semidefinit, aber nicht positiv definit.

Im nächsten Schritt betrachten wir zuerst den strengeren Fall:

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

Geometrisch heißt das: Jede von null verschiedene Richtung hat positive Energie beziehungsweise positive Streuung. Algebraisch entspricht das bei symmetrischen Matrizen genau der Bedingung, dass alle Eigenwerte strikt positiv sind.

Wiederholung (9.9)

Die wichtigsten Punkte dieses Abschnitts:

- Aus einer zentrierten Datenmatrix A entsteht die Kovarianzmatrix

$$S = \frac{1}{n-1} A^\top A.$$

- S ist symmetrisch, weil $(A^\top A)^\top = A^\top A$ gilt.

- Für jede Richtung $\vec{x}$ gilt

$$\vec{x}^\top S \vec{x} = \frac{1}{n-1} \|A\vec{x}\|^2 \geq 0.$$

- Deshalb haben Kovarianzmatrizen keine negativen Eigenwerte: Sie sind positiv semidefinit.
- Positiv definite Matrizen sind der strengere Spezialfall, in dem jede Richtung $\vec{x} \neq \vec{0}$ strikt positive Energie hat.

2. Erste Charakterisierung: positive Eigenwerte

Lernziele (9.10)

Nach diesem Abschnitt können Sie...

- positiv definite Matrizen über ihre Eigenwerte charakterisieren,
- einfache Beispiele positiv definiter, positiv semidefiniter und nicht positiv definiter Matrizen unterscheiden,
- erklären, warum wir in diesem Kapitel symmetrische Matrizen betrachten, und
- die Eigenwert-Charakterisierung geometrisch als Streckung entlang orthogonaler Hauptachsen deuten.

Wir betrachten in diesem Kapitel ausschließlich symmetrische Matrizen

$$S = S^\top \in \mathbb{R}^{n \times n}.$$

Symmetrische Matrizen sind toll: Aus Kapitel 8 wissen wir, dass alle Eigenwerte reell sind und es eine Orthonormalbasis aus Eigenvektoren gibt. Dadurch können wir eine symmetrische Matrix als Transformation interpretieren, die den Raum entlang senkrechter Hauptachsen (den orthonormalen Eigenvektoren) streckt oder staucht. Dieses Kapitel widmet sich noch besseren Matrizen: denjenigen, die in jeder Richtung positiv strecken.


Definition (9.11): Positiv definit – erste Charakterisierung

Eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ heißt positiv definit, falls alle Eigenwerte von S strikt positiv sind:

$$S \text{ positiv definit} \iff \lambda_i > 0 \text{ für alle Eigenwerte } \lambda_i \text{ von } S.$$

Die Definition klingt zunächst rein algebraisch: Wir berechnen die Eigenwerte und schauen auf ihre Vorzeichen. Die geometrische Idee zeigt uns aber, was das tatsäch-

lich bedeutet: Eine **symmetrische Matrix besitzt orthogonale Eigenrichtungen**. Ist jeder Eigenwert positiv, dann wird **in jeder dieser Hauptachsenrichtungen nur mit einem positiven Faktor skaliert**; keine Richtung wird umgedreht!



Beispiel (9.12): Diagonalmatrix

Die Matrix

$$S_1 = \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix}$$

ist symmetrisch. Ihre Eigenwerte sind direkt ablesbar:

$$\lambda_1 = 2, \quad \lambda_2 = 6.$$

Beide sind positiv, also ist S_1 positiv definit. Geometrisch streckt S_1 die erste Koordinatenrichtung mit Faktor 2 und die zweite mit Faktor 6.

Wir haben bereits in Kapitel 8 gesehen, dass ähnliche Matrizen dieselben Eigenwerte besitzen. Das gilt insbesondere für orthogonale Ähnlichkeitstransformationen:

Beispiel (9.13): Gleiche Eigenwerte nach orthogonaler Drehung

Sei Q eine orthogonale Matrix, also $Q^T Q = E_n$. Dann besitzt

$$S_2 = Q \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix} Q^T$$

dieselben Eigenwerte wie S_1 , nämlich 2 und 6 (die rechte Seite ist die Diagonalisierung von S_2). Deshalb ist auch S_2 positiv definit.

Anschaulich dreht oder spiegelt Q zuerst das Koordinatensystem, danach wird entlang der neuen Hauptachsen positiv gestreckt, und schließlich wird zurückgedreht.

Beispiel (9.14): Semidefinit ist nicht definit

Die Matrix

$$S_3 = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$$

hat Eigenwerte

$$\lambda_1 = 2, \quad \lambda_2 = 0.$$

Damit ist sie nicht positiv definit, denn ein Eigenwert ist nicht strikt positiv. Sie ist aber positiv semidefinit: Alle Eigenwerte sind ≥ 0 .

Geometrisch gibt es eine Richtung mit Energie 0: Die zweite Koordinatenrichtung wird vollständig abgeflacht.

Obwohl die Eigenwertcharakterisierung für positive Definitheit einfach zu verstehen ist, ist sie für konkrete Rechnungen fast nie der richtige Test – die Berechnung von Eigenwerten großer Matrizen ist numerisch sehr aufwendig und sollte möglichst vermieden werden. In den kommenden Abschnitten lernen wir deshalb vier äquivalente Charakterisierungen kennen, die alle ihre eigenen Vorteile mit sich bringen.

Aufgabe (9.15): Eigenwert-Test

Entscheiden Sie jeweils mithilfe der Eigenwerte, ob die Matrix positiv definit, positiv semidefinit oder keines von beiden ist.

$$A = \begin{pmatrix} 4 & 0 \\ 0 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 3 \\ 3 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{pmatrix}.$$

Wiederholung (9.16)

Die wichtigsten Punkte dieses Abschnitts:

- In Kapitel 9 betrachten wir symmetrische Matrizen $S = S^\top$.
- Symmetrische Matrizen besitzen reelle Eigenwerte und orthogonale Eigenrichtungen.
- Die erste Charakterisierung lautet:

$$S \text{ positiv definit} \iff \lambda_i > 0 \text{ für alle Eigenwerte } \lambda_i.$$

3. Zweite Charakterisierung: die quadratische Form

Lernziele (9.17)

Nach diesem Abschnitt können Sie...

- die quadratische Form $q_S(\vec{x}) = \vec{x}^\top S \vec{x}$ zu einer symmetrischen Matrix S berechnen,
- positive Definitheit über die Bedingung $\vec{x}^\top S \vec{x} > 0$ für alle $\vec{x} \neq \vec{0}$ charakterisieren,
- die quadratische Form geometrisch als Energie oder Krümmung lesen,
- einfache quadratische Formen durch Umformen als positiv erkennen, und
- erklären, warum positive Definitheit bei lokalen Minima und Gradientenverfahren auftaucht.

Eigenwerte geben uns die Hauptachsen einer symmetrischen Matrix. Es gibt aber eine zweite Sicht, die oft noch direkter ist: Wir testen nicht einzelne Eigenrichtungen, sondern jede beliebige Richtung $\vec{x}$ mit der Zahl

$$\vec{x}^\top S \vec{x}.$$

Diese Zahl ist ein Skalar. Man kann sie als Energie, als quadratische Messung oder in der Optimierung als Krümmung in Richtung $\vec{x}$ lesen.

Definition (9.18): Quadratische Form

Sei $S \in \mathbb{R}^{n \times n}$ symmetrisch. Die Funktion

$$q_S : \mathbb{R}^n \rightarrow \mathbb{R}, \quad q_S(\vec{x}) = \vec{x}^\top S \vec{x}$$

heißt die zu S gehörige quadratische Form.

Beispiel (9.19): Aus einer Matrix wird ein Polynom


Wir betrachten

$$S = \begin{pmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 3 \end{pmatrix}, \quad \vec{x} = \begin{pmatrix} x \\ y \end{pmatrix}.$$

Dann ist

$$\begin{aligned}
 q_S(\vec{x}) &= \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} \\
 &= \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 2x + \frac{1}{2}y \\ \frac{1}{2}x + 3y \end{pmatrix} \\
 &= 2x^2 + \frac{1}{2}xy + \frac{1}{2}xy + 3y^2 \\
 &= \boxed{2x^2 + xy + 3y^2}.
 \end{aligned}$$

Die symmetrischen Nebendiagonaleinträge tauchen gemeinsam als gemischter Term xy auf.



Das Bild ist eine Schüssel. Der Punkt $\vec{0}$ liegt unten, und jede Richtung vom Ursprung weg erhöht die Energie. Dies liefert

Theorem 25: Zweite Charakterisierung positiver Definitheit

Für eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ gilt:

$$S \text{ positiv definit} \iff \vec{x}^\top S \vec{x} > 0 \text{ für alle } \vec{x} \in \mathbb{R}^n \setminus \{\vec{0}\}.$$

Bemerkung (9.20): Positive Energie $\Leftrightarrow$ positive Eigenwerte

Für einen Eigenvektor $\vec{v} \neq \vec{0}$ mit $S\vec{v} = \lambda\vec{v}$ gilt

$$\vec{v}^\top S \vec{v} = \vec{v}^\top \lambda \vec{v} = \lambda \|\vec{v}\|^2.$$

Da $\|\vec{v}\|^2 > 0$ ist, sieht die quadratische Form in Eigenrichtungen direkt das Vorzeichen des Eigenwerts.

Umgekehrt kann man bei symmetrischen Matrizen jeden Vektor in orthogonale Eigenrichtungen zerlegen. Hat S Eigenwerte $\lambda_1, \dots, \lambda_n$ und eine Orthonormalbasis aus

Eigenvektoren $\vec{v}_1, \dots, \vec{v}_n$, dann lässt sich

$$\vec{x} = \alpha_1 \vec{v}_1 + \dots + \alpha_n \vec{v}_n$$

schreiben, und die quadratische Form wird zu

$$\vec{x}^T S \vec{x} = \lambda_1 \alpha_1^2 + \dots + \lambda_n \alpha_n^2.$$

Sind alle $\lambda_i > 0$, dann ist diese Summe für jeden Vektor $\vec{x} \neq \vec{0}$ positiv.

Beispiel (9.21): Positive Definitheit durch quadratische Ergänzung

Für <https://de.serlo.org/mathe/1631/quadratische-ergaenzung>

$$S = \begin{pmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 3 \end{pmatrix}$$

haben wir

$$q_S \left(\begin{pmatrix} x \\ y \end{pmatrix} \right) = 2x^2 + xy + 3y^2.$$

Durch quadratische Ergänzung (a.k.a. erste binomische Formel rückwärts) können wir die gemischten Terme beseitigen:

$$\begin{aligned} 2x^2 + xy + 3y^2 &= 2\left(x^2 + \frac{1}{2}xy + \frac{1}{16}y^2\right) + 3y^2 - 2 \cdot \frac{1}{16}y^2 \\ &= 2\left(x + \frac{1}{4}y\right)^2 + \frac{23}{8}y^2. \end{aligned}$$

Beide Summanden sind ≥ 0 . Beide Summanden können nur gleichzeitig 0 sein, wenn $y = 0$ und danach auch $x = 0$ gilt. Also ist

$$q_S(\vec{x}) > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

Damit ist S positiv definit.

Beispiel (9.22): Eine Richtung mit negativer Energie

Die Matrix

$$T = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$


hat quadratische Form

$$q_T \left(\begin{pmatrix} x \\ y \end{pmatrix} \right) = x^2 - y^2.$$

Für $\vec{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ erhalten wir

$$\vec{x}^\top T \vec{x} = -1 < 0.$$

Also ist T nicht positiv definit. Geometrisch ergibt sich ein Sattel:



Aufgabe (9.23): Mit Python alle Richtungen testen

Die zweite Charakterisierung verlangt $\vec{x}^\top S \vec{x} > 0$ für *jede* Richtung $\vec{x} \neq \vec{0}$ – das können wir in Python leicht nachprüfen: Wir lassen $\vec{x}(\theta) = (\cos \theta, \sin \theta)^\top$ einmal über den Einheitskreis laufen und beobachten die Energie (vollständiger Code: Appendix C):

```
import numpy as np
S = np.array([[2, 0.5], [0.5, 3]]) # positiv definit
T = np.array([[1, 0], [0, -1]])    # indefinit
theta = np.linspace(0, 2*np.pi, 400)
X = np.vstack([np.cos(theta), np.sin(theta)])
qS = np.sum(X * (S @ X), axis=0)    # x^T S x, spaltenweise
print(qS.min(), qS.max())
```

1. Führen Sie den Code für S und für T aus, oder lesen Sie die Werte an Abbildung 9.1 ab: Welche Energien treten jeweils auf, und was bedeutet das für die Definitheit?
2. Warum genügt es, nur Einheitsvektoren zu testen? *Hinweis:* Berechnen Sie $q_S(c \vec{x})$ für einen Skalar $c \neq 0$.
3. Vergleichen Sie $qS.min()$ und $qS.max()$ mit den Eigenwerten von S . Was fällt auf?




Abbildung 9.1. *Energie auf dem Einheitskreis: Für das positiv definite S bleibt $q_S(\theta)$ strikt über null, beim indefiniten T wechselt $q_T(\theta)$ das Vorzeichen. Minimum und Maximum jeder Kurve sind genau der kleinste und größte Eigenwert.*

Aufgabe (9.24): Quadratische Formen lesen

Entscheiden Sie jeweils mithilfe der quadratischen Form, ob die Matrix positiv definit ist.

$$A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 4 & 1 \\ 1 & 4 \end{pmatrix}.$$

Folgerung (9.25): Summe positiv definiter Matrizen

Sind S_1 und S_2 positiv definit, dann ist auch $S_1 + S_2$ positiv definit.

Begründung: Es gilt:

$$\vec{x}^\top (S_1 + S_2) \vec{x} = \vec{x}^\top S_1 \vec{x} + \vec{x}^\top S_2 \vec{x} > 0$$

für alle $\vec{x} \neq \vec{0}$.

□

Wiederholung (9.26)

Die wichtigsten Punkte dieses Abschnitts:

- Zu jeder symmetrischen Matrix S gehört die quadratische Form

$$q_S(\vec{x}) = \vec{x}^\top S \vec{x}. \quad \text{ergibt Polynom mit xy-Variablen}$$

- Positive Definitheit bedeutet äquivalent:

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

- In Eigenrichtungen misst q_S direkt das Vorzeichen der Eigenwerte.
- Geometrisch ist eine positiv definite quadratische Form eine echte Schüssel mit eindeutigem Minimum bei $\vec{0}$.

4. Dritte Charakterisierung: führende Hauptminoren

Lernziele (9.27)

Nach diesem Abschnitt können Sie...

- führende Hauptuntermatrizen und führende Hauptminoren definieren,
- das Sylvester-Kriterium für positive Definitheit anwenden,
- bei kleinen Matrizen positive Definitheit über Determinanten testen, und
- erklären, warum dieser Test oft praktischer ist als eine direkte Eigenwertberechnung.

Die Eigenwert-Charakterisierung ist sehr klar, aber Eigenwerte zu berechnen ist nicht immer angenehm. Die quadratische Form ist anschaulich, aber die Bedingung

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}$$

prüft scheinbar unendlich viele Vektoren. Für symmetrische Matrizen gibt es einen erstaunlich kompakten Test: Wir schauen nur auf bestimmte Determinanten.

Definition (9.28): Führende Hauptuntermatrix & führender Hauptminor

Sei

$$S = (s_{ij})_{i,j=1,\dots,n} \in \mathbb{R}^{n \times n}.$$

Die Matrix

$$S_k = (s_{ij})_{i,j=1,\dots,k}$$

heißt die **k-te führende Hauptuntermatrix** von S . Sie entsteht, indem man nur die ersten k Zeilen und die ersten k Spalten von S behält und den Rest entsorgt.

Die Determinante

$$\Delta_k = \det(S_k)$$

heißt der **k-te führende Hauptminor**.

Beispiel (9.29): Führende Hauptuntermatrizen markieren

Für

$$S = \begin{pmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix}$$

sind die ersten drei führenden Hauptuntermatrizen

$$S_1 = (2), \quad S_2 = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}, \quad S_3 = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}.$$

Sie sitzen jeweils links oben in der Matrix.

Bemerkung (9.30): Von positiver Energie zu positiven Hauptminoren

Ist S positiv definit, dann gilt

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

Setzen wir spezielle Vektoren ein, deren letzte Koordinaten 0 sind, dann sehen wir nur den linken oberen Block von S . Für

$$\vec{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_k \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

hängt $\vec{x}^\top S \vec{x}$ nur von S_k ab:

$$\vec{x}^\top S \vec{x} = (x_1 \quad \dots \quad x_k) S_k \begin{pmatrix} x_1 \\ \vdots \\ x_k \end{pmatrix}.$$

Wenn S positiv definit ist, dann müssen also auch alle führenden Hauptuntermatrizen S_k positiv definit sein. Damit müssen ihre Determinanten positiv sein. Das sogenannte **Sylvester-Kriterium** sagt: Diese notwendige Bedingung reicht sogar aus.

Theorem 26: Sylvester-Kriterium

Für eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ gilt:

$$S \text{ positiv definit} \iff \det(S_k) > 0 \text{ für alle } k = 1, \dots, n.$$

Beispiel (9.31): Sylvester-Kriterium an einer 4×4 -Matrix

Wir betrachten wieder

$$S = \begin{pmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix}.$$

Die führenden Hauptminoren sind

$$\begin{aligned} \Delta_1 &= \det(2) = 2, \\ \Delta_2 &= \det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 4 - 1 = 3, \\ \Delta_3 &= \det \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} = 4, \\ \Delta_4 &= \det(S) = 5. \end{aligned}$$

Da alle vier führenden Hauptminoren positiv sind, ist S positiv definit.

Beispiel (9.32): Sylvester-Kriterium für 2×2 -Matrix

Für

$$S = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$$

ist das Sylvester-Kriterium besonders einfach:

$$\Delta_1 = a > 0, \quad \Delta_2 = \det(S) = ac - b^2 > 0.$$

Also gilt:

$$\begin{pmatrix} a & b \\ b & c \end{pmatrix} \text{ positiv definit} \iff a > 0 \text{ und } ac - b^2 > 0.$$

Beispiel (9.33): Sylvester als K.O.-Kriterium

Die Matrix

$$T = \begin{pmatrix} 1 & 2 & 0 & 1 \\ 2 & 1 & 3 & 0 \\ 0 & 3 & 1 & 2 \\ 1 & 0 & 2 & 1 \end{pmatrix}$$

hat

$$\Delta_1 = 1 > 0, \quad \Delta_2 = \det(T_{11}) = 1 - 4 = -3 < 0.$$

Schon der zweite führende Hauptminor ist negativ. Also ist T nicht positiv definit.

Aufgabe (9.34): Sylvester-Kriterium anwenden

Entscheiden Sie mit dem Sylvester-Kriterium, ob die folgenden Matrizen positiv definit sind.

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}, \quad B = \begin{pmatrix} -1 & 2 \\ 2 & -5 \end{pmatrix}, \quad C = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}.$$

Vergleichen Sie bei A und B: Was sagt jeweils die Determinante, und warum reicht sie allein noch nicht als allgemeiner Test?

Bemerkung (9.35): Limitierungen des Sylvester-Kriteriums

Das Sylvester-Kriterium ist ein Entscheidungsverfahren: Es sagt uns schnell, ob S positiv definit ist, erklärt aber nicht direkt, wie man mit S effizient rechnet oder lineare Gleichungssysteme löst.

Apropos *Gleichungssystem*: im nächsten Abschnitt ist endlich an der Zeit, mal wieder ordentlich rein-zu-gauß-en.

Wiederholung (9.36)

Die wichtigsten Punkte dieses Abschnitts:

- Die führende Hauptuntermatrix S_k besteht aus den ersten k Zeilen und ersten k Spalten von S .
- Der führende Hauptminor ist $\Delta_k = \det(S_k)$.
- Das Sylvester-Kriterium lautet:

$$S \text{ positiv definit} \iff \Delta_k > 0 \text{ für alle } k = 1, \dots, n.$$

- Der Test ist oft einfacher als Eigenwerte zu berechnen.

5. Vierte Charakterisierung: positive Pivots

Lernziele (9.37)

Nach diesem Abschnitt können Sie...

- positive Definitheit über positive Pivots charakterisieren,
- den Zusammenhang zwischen führenden Hauptminoren und Pivots erklären, und
- eine symmetrische Matrix durch Gauß-Elimination ohne Zeilenvertauschung auf positive Pivots testen.

Das Sylvester-Kriterium testet positive Definitheit über Determinanten. Wenn wir Determinanten aber mit Gauß-Elimination berechnen, tauchen automatisch die **Pivots** auf. Für positiv definite Matrizen passiert dabei etwas sehr Angenehmes:

Alle Pivots sind positiv.

Das ist tatsächlich schon die vierte Charakterisierung positiver Definitheit.

Definition (9.38): Pivot ohne Zeilenvertauschung

Führt man das Gauß-Verfahren ohne Zeilenvertauschungen durch und erhält eine obere Dreiecksmatrix

$$R = \begin{pmatrix} \rho_1 & * & \cdots & * \\ 0 & \rho_2 & \cdots & * \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & \rho_n \end{pmatrix},$$

dann heißen die **Diagonaleinträge**

$$\rho_1, \dots, \rho_n$$

die **Pivots** der Elimination.

Theorem 27: Vierte Charakterisierung positiver Definitheit

Für eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ gilt:

S positiv definit $\iff$ Gauß-Elimination ohne Zeilenvertauschung
hat nur positive Pivots.

Bemerkung (9.39): Pivots und führende Hauptminoren

Beim Gauß-Verfahren ändern wir durch Zeilenadditionen die Determinante nicht. Für die führenden Hauptuntermatrizen gilt daher:

$$\Delta_k = \det(S_k) = \underbrace{\rho_1 \rho_2 \cdots \rho_{k-1}}_{\Delta_{k-1}} \cdot \rho_k.$$

Durch Division können wir die Pivots auch aus den Hauptminoren berechnen:

$$\rho_1 = \Delta_1, \quad \rho_k = \frac{\Delta_k}{\Delta_{k-1}} \quad \text{für } k = 2, \dots, n.$$

Wenn alle führenden Hauptminoren positiv sind, dann sind auch alle Pivots positiv. Umgekehrt liefern positive Pivots sofort positive Produkte und damit positive führende Hauptminoren.

Beispiel (9.40): Positive Definitheit über Pivots verifizieren

Wir betrachten wieder

$$S = \begin{pmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{pmatrix}.$$

Gauß-Elimination ohne Zeilenvertauschung liefert

$$S \rightsquigarrow \begin{pmatrix} 2 & -1 & 0 & 0 \\ 0 & \frac{3}{2} & -1 & 0 \\ 0 & 0 & \frac{4}{3} & -1 \\ 0 & 0 & 0 & \frac{5}{4} \end{pmatrix}.$$

Die Pivots sind also

$$\rho_1 = 2, \quad \rho_2 = \frac{3}{2}, \quad \rho_3 = \frac{4}{3}, \quad \rho_4 = \frac{5}{4}.$$

Da alle Pivots positiv sind, ist S positiv definit.

Das passt perfekt zu den führenden Hauptminoren aus Abschnitt 4:

$$\Delta_1 = 2, \quad \Delta_2 = 3, \quad \Delta_3 = 4, \quad \Delta_4 = 5.$$

Denn

$$\rho_2 = \frac{\Delta_2}{\Delta_1} = \frac{3}{2}, \quad \rho_3 = \frac{\Delta_3}{\Delta_2} = \frac{4}{3}, \quad \rho_4 = \frac{\Delta_4}{\Delta_3} = \frac{5}{4}.$$

Beispiel (9.41): Negative Pivots zeigen Nicht-Definitheit

Für

$$T = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

ist der erste Pivot $\rho_1 = 1$. Eliminieren wir den Eintrag unterhalb des ersten Pivots, erhalten wir

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \rightsquigarrow \begin{pmatrix} 1 & 2 \\ 0 & -3 \end{pmatrix}.$$

Der zweite Pivot ist

$$\rho_2 = -3 < 0.$$

Also ist T nicht positiv definit.

Bemerkung (9.42): Ein Pladoyer für Zeilentausche

Beim gewöhnlichen Gauß-Verfahren vertauschen wir Zeilen, wenn ein Pivot ungünstig oder null ist. Für positiv definite Matrizen ist das aus strukturellen Gründen nicht nötig: Die führenden Hauptminoren sind positiv, also verschwinden die Pivots nicht und haben sogar positives Vorzeichen. Aus numerischer Sicht sollten wir trotzdem vorsichtig sein: **Betragsmäßig kleine Pivots könnten zu großen Rundungsfehlern und damit zu Instabilität führen.**

Aufgabe (9.43): Pivot-Test

Entscheiden Sie mithilfe der Pivots, ob die folgenden Matrizen positiv definit sind.

$$A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}, \quad B = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}.$$

Wiederholung (9.44)

Die wichtigsten Punkte dieses Abschnitts:

- **Pivots** sind die **Diagonaleinträge**, die beim Gauß-Verfahren entstehen.

- Für symmetrische Matrizen gilt:

$$S \text{ positiv definit} \iff \text{alle Pivots ohne Zeilenvertauschung sind positiv.}$$

- Die **Pivots hängen mit den führenden Hauptminoren zusammen:**

$$\rho_k = \frac{\Delta_k}{\Delta_{k-1}} \quad (\Delta_0 = 1).$$

6. Cholesky-Zerlegung und fünfte Charakterisierung

Lernziele (9.45)

Nach diesem Abschnitt können Sie...

- die Cholesky-Zerlegung einer positiv definiten Matrix berechnen,
- den Zusammenhang zwischen positiven Pivots, LDL^T und Cholesky erklären,
- positive Definitheit über $S = A^T A$ mit vollem Rang charakterisieren.

Die vier bisherigen Charakterisierungen sagen uns, wann eine symmetrische Matrix positiv definit ist. Die Cholesky-Zerlegung geht einen Schritt weiter: Sie nutzt positive Definitheit, um die Matrix besonders effizient zu zerlegen. Die Idee ist schlicht: Wenn die Energie in alle Richtungen positiv ist, können wir Wurzeln ziehen.

Theorem 28: Cholesky-Zerlegung

Ist $S \in \mathbb{R}^{n \times n}$ symmetrisch positiv definit, dann gibt es genau eine untere Dreiecksmatrix C mit positiven Diagonaleinträgen, sodass

$$S = CC^T.$$

Diese Zerlegung heißt Cholesky-Zerlegung.

Äquivalent kann man mit einer oberen Dreiecksmatrix $R = C^T$ schreiben:

$$S = R^T R.$$

Bemerkung (9.46): Von positiven Pivots zu Cholesky

Die Cholesky-Zerlegung ergibt sich konzeptionell durch drei Schritte: Ist S positiv definit, dann sind nach der vierten Charakterisierung alle Pivots positiv, und die Gauß-Elimination kommt ohne Zeilentausch aus. Die LR-Zerlegung liefert also $S = LR$ mit den positiven Pivots $\rho_1, \dots, \rho_n$ auf der Diagonale von R . Ziehen wir diese als Diagonalmatrix $D = \text{diag}(\rho_1, \dots, \rho_n)$ heraus, dann erzwingt die Symmetrie von S , dass links und rechts dieselben Faktoren auftreten:

$$S = LDL^T.$$

Dies ist die LDL^T -Zerlegung. Weil alle Diagonaleinträge von D positiv sind, dürfen wir die Wurzel $\sqrt{D}$ ziehen und erhalten

$$S = L\sqrt{D}\sqrt{D}L^T = \underbrace{(L\sqrt{D})}_C \underbrace{(L\sqrt{D})^T}_{C^T}, \quad \text{also} \quad S = CC^T.$$

Für die ausführliche Herleitung siehe Anhang B.

Würden wir die Cholesky-Zerlegung auf diesem Weg berechnen, hätten wir keinen Vorteil gegenüber einer normalen LR-Zerlegung. Es gibt aber glücklicherweise einen sehr viel effizienteren Algorithmus:

Beispiel (9.47): Cholesky für eine 2×2 -Matrix

Wir zerlegen

$$S = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}.$$

Wir suchen eine untere Dreiecksmatrix

$$C = \begin{pmatrix} a & 0 \\ b & c \end{pmatrix} \quad \text{mit } a > 0, c > 0.$$

Dann ist

$$CC^T = \begin{pmatrix} a & 0 \\ b & c \end{pmatrix} \begin{pmatrix} a & b \\ 0 & c \end{pmatrix} = \begin{pmatrix} a^2 & ab \\ ab & b^2 + c^2 \end{pmatrix}.$$

Vergleichen der Einträge liefert

$$a^2 = 4, \quad ab = 2, \quad b^2 + c^2 = 3.$$

Wegen $a > 0$ ist $a = 2$. Dann ist $b = 1$ und schließlich

$$1 + c^2 = 3 \quad \Rightarrow \quad c = \sqrt{2}.$$

Damit ist

$$\begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & \sqrt{2} \end{pmatrix}.$$

Wie kommen wir bei größeren Matrizen systematisch voran? Der Schlüssel ist der Blick *Matrix mal Vektor als Linearkombination der Spalten*: Wir vergleichen in $S = CC^T$ die ersten Spalten beider Seiten. Da C eine untere Dreiecksmatrix ist, ist die erste Zeile von C der Vektor $(c_{11}, 0, \dots, 0)$ und damit die erste Spalte von C^T einfach $(c_{11}, 0, \dots, 0)^T$. Also ist die erste Spalte von S schlicht das c_{11} -Fache der ersten Spalte von C :

The diagram shows the relationship between a column vector $\vec{s}_1$ and the columns of a matrix C . It consists of four main components connected by equals signs:

- Column Vector $\vec{s}_1$:** An orange vertical box containing the elements s_{11} , s_{21} , and s_{31} . Below it is the label $\vec{s}_1$ in orange.
- Matrix C :** A blue square box containing the elements c_{11} , c_{21} , c_{31} in the first column, and 0 , c_{22} , c_{32} in the second column, and 0 , 0 , c_{33} in the third column. Below it is the label C in blue.
- Column Vector (1st Column of C^T):** A blue vertical box containing the elements c_{11} , 0 , and 0 . Below it is the label "1. Spalte von C^T " in blue.
- Column Vector $\vec{c}_1$:** A blue vertical box containing the elements c_{11} , c_{21} , and c_{31} . Below it is the label $\vec{c}_1$ in blue.

The diagram illustrates that the column vector $\vec{s}_1$ is equal to the first column of matrix C , which is also equal to the first column of the transpose of C , $\vec{c}_1$.

Die erste Spalte von C^T hat nur oben einen Eintrag – Matrix mal Spalte liefert also das c_{11} -Fache der ersten Spalte von C .

Der oberste Eintrag dieser Gleichung lautet $s_{11} = c_{11}^2$, und damit bekommen wir schon die gesamte erste Spalte von C geschenkt:

$$c_{11} = \sqrt{s_{11}}, \quad \vec{c}_1 = \frac{1}{c_{11}} \vec{s}_1.$$

Dieselbe Methode funktioniert für jede weitere Spalte: Die j -te Spalte von C^T hat unterhalb von Position j nur Nullen, also liefert Matrix mal Spalte

$$\vec{s}_j = c_{j1} \vec{c}_1 + \dots + c_{j,j-1} \vec{c}_{j-1} + c_{jj} \vec{c}_j. \quad \text{i.e. Spaltenkombination}$$

Die Gewichte $c_{j1}, \dots, c_{j,j-1}$ stehen in den bereits berechneten Spalten von C . Wir lösen also nach $c_{jj} \vec{c}_j$ auf, lesen am j -ten Eintrag c_{jj}^2 ab und teilen den Rest der Spalte durch c_{jj} .

Beispiel (9.48): Cholesky spaltenweise: eine 3×3 -Matrix

Wir zerlegen

$$S = \begin{pmatrix} 4 & 2 & 4 \\ 2 & 10 & 8 \\ 4 & 8 & 9 \end{pmatrix}.$$

Spalte 1: Es gilt $\vec{s}_1 = c_{11} \vec{c}_1$. Der oberste Eintrag liefert $c_{11}^2 = 4$, also $c_{11} = 2$ und $1/c_1 * s_1$

$$\vec{c}_1 = \frac{1}{2} \begin{pmatrix} 4 \\ 2 \\ 4 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ 2 \end{pmatrix}.$$

Spalte 2: Es gilt $\vec{s}_2 = c_{21} \vec{c}_1 + c_{22} \vec{c}_2$. Das Gewicht $c_{21} = 1$ kennen wir schon aus $\vec{c}_1$, also

$$c_{22} \vec{c}_2 = \vec{s}_2 - c_{21} \vec{c}_1 = \begin{pmatrix} 2 \\ 10 \\ 8 \end{pmatrix} - 1 \cdot \begin{pmatrix} 2 \\ 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 9 \\ 6 \end{pmatrix}.$$

jetzige spalte minus
vorheriges ergebnis mal
k eintrag von dem ergebnis

Diagram illustrating the calculation of c_k from c_{kk} using the Cholesky decomposition structure:

$$c_k = \frac{1}{\sqrt{c_{kk}}} \cdot c_{kk}$$

Der zweite Eintrag liefert $c_{22}^2 = 9$, also $c_{22} = 3$ und

$$\vec{c}_2 = \frac{1}{3} \begin{pmatrix} 0 \\ 9 \\ 6 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \\ 2 \end{pmatrix}.$$

Spalte 3: Mit den bekannten Gewichten $c_{31} = 2$ und $c_{32} = 2$ ist

$$c_{33} \vec{c}_3 = \vec{s}_3 - c_{31} \vec{c}_1 - c_{32} \vec{c}_2 = \begin{pmatrix} 4 \\ 8 \\ 9 \end{pmatrix} - 2 \begin{pmatrix} 2 \\ 1 \\ 2 \end{pmatrix} - 2 \begin{pmatrix} 0 \\ 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix},$$

also $c_{33} = 1$ und $\vec{c}_3 = (0, 0, 1)^\top$. Insgesamt erhalten wir

$$C = \begin{pmatrix} 2 & 0 & 0 \\ 1 & 3 & 0 \\ 2 & 2 & 1 \end{pmatrix}.$$

jetzige Spalte minus vorherige Ergebnisse
mal deren Einträge bezüglich dem durchlauf,
i.e. erster durchlauf für c1 -> erster eintrag
zweiter durchlauf für c2 -> zweiter eintrag
dritter durchlauf für c3 -> dritter eintrag

Die Probe $CC^\top = S$ bestätigt das Ergebnis (rechnen Sie nach!).

Indem wir das Schema auf die einzelnen Einträge herunterbrechen, ergibt sich der **Cholesky-Algorithmus**:

Algorithmus (9.49): Cholesky-Algorithmus

Eingabe: symmetrisch positiv definite Matrix $S = (s_{ij}) \in \mathbb{R}^{n \times n}$

Ausgabe: untere Dreiecksmatrix $C = (c_{ij})$ mit $S = CC^\top$

```

1: for j = 1 bis n do
2:    $c_{jj} \leftarrow \sqrt{s_{jj} - \sum_{k=1}^{j-1} c_{jk}^2}$ 
3:   for i = j + 1 bis n do
4:      $c_{ij} \leftarrow \frac{1}{c_{jj}} \left( s_{ij} - \sum_{k=1}^{j-1} c_{ik} c_{jk} \right)$ 
5:   end for
6: end for
```

Die positive Definitheit von S garantiert, dass die Wurzel in Zeile 2 immer definiert ist und dass wir in Zeile 4 durch c_{jj} teilen dürfen. Vergleichen Sie die beiden Zeilen mit dem Beispiel: Zeile 2 ist das Ablesen von c_{jj}^2 am j-ten Eintrag, Zeile 4 das Teilen des Spaltenrests durch c_{jj} . Eine Frage bleibt jedoch: *Was letzte Preis?*

Bemerkung (9.50): Zeitkomplexität

Für eine $n \times n$ -Matrix benötigt der Cholesky-Algorithmus

$$\frac{1}{6}n^3 + O(n^2)$$

Multiplikationen: Der führende Term entsteht bei den inneren Summen

$$\sum_{k=1}^{j-1} c_{ik}c_{jk} \quad (i > j).$$

Für eine feste Spalte j gibt es $n - j$ Einträge unterhalb der Diagonalen, und jede dieser Summen hat $j - 1$ Multiplikationen. Daher erhalten wir die Anzahl der Multiplikationen durch die doppelte Summe

$$\sum_{j=1}^n (n - j)(j - 1) = \frac{1}{6}n(n^2 - 3n + 2) \quad (\text{bitte nicht nachrechnen}).$$

Die Diagonaleinträge und Divisionen tragen nur Terme der Ordnung $O(n^2)$ bei. Zählt man alle Fließkommaoperationen (auch Additionen und Subtraktionen), erhält man

$$\frac{1}{3}n^3 + O(n^2).$$

Damit ist Cholesky für große n etwa doppelt so schnell wie die LR-Zerlegung.

Beispiel (9.51): Cholesky und Energie

Mit der Cholesky-Zerlegung $S = CC^T$ wird die quadratische Form zu einer quadrieren Länge:

$$\vec{x}^T S \vec{x} = \vec{x}^T C C^T \vec{x} = (C^T \vec{x})^T (C^T \vec{x}) = \|C^T \vec{x}\|^2.$$

Hat C^T vollen Spaltenrang, dann ist $C^T \vec{x} \neq \vec{0}$ für alle $\vec{x} \neq \vec{0}$ und damit

$$\|C^T \vec{x}\|^2 > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

Mit $A = C^T$ folgt die fünfte Charakterisierung positiver Definitheit.

Theorem 29: Fünfte Charakterisierung positiver Definitheit

Für eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ gilt:

$$S \text{ positiv definit} \iff S = A^T A \text{ für eine Matrix } A \text{ mit vollem Spaltenrang.}$$

Bemerkung (9.52): Warum voller Rang entscheidend ist

Ist

$$S = A^T A,$$

dann gilt immer

$$\vec{x}^T S \vec{x} = \vec{x}^T A^T A \vec{x} = \|A \vec{x}\|^2 \geq 0,$$

aber nicht > 0 für alle $\vec{x} \neq \vec{0}$. Dies ist genau dann erfüllt, wenn A keinen von null verschiedenen Vektor auf $\vec{0}$ abbildet, d.h., wenn die Spalten von A linear unabhängig sind. Folglich muss A vollen Spaltenrang haben.

Wichtig: Im Gegensatz zur Cholesky-Zerlegung muss A hier nicht quadratisch sein.

Beispiel (9.53): Warum Rangverlust nur semidefinit liefert

Sei

$$A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix}.$$

Dann ist

$$S = A^T A = \begin{pmatrix} 2 & 3 & 4 \\ 3 & 5 & 7 \\ 4 & 7 & 10 \end{pmatrix}.$$

Für den Vektor

$$\vec{x} = \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}$$

ist

$$A \vec{x} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

und damit

$$\vec{x}^T S \vec{x} = \|A \vec{x}\|^2 = 0$$

für einen Vektor $\vec{x} \neq \vec{0}$. Also ist S positiv semidefinit, aber nicht positiv definit.

Bemerkung (9.54): Relevanz von Cholesky

Cholesky ist in der Praxis schneller und speichersparender als eine allgemeine LR-Zerlegung, weil Symmetrie und positive Definitheit ausgenutzt werden. Typische Anwendungen sind:

- Lösen linearer Gleichungssysteme mit positiv definiten Matrizen,
- Least-Squares-Probleme,

- Simulationen, bei denen gewünschte Kovarianzstrukturen erzeugt werden (siehe Aktivierung unten).

Müssen wir

$$S\vec{x} = \vec{b}$$

lösen und kennen $S = CC^\top$, dann können wir wie bei der LR-Zerlegung die Lösung in zwei Schritten berechnen:

$$C\vec{y} = \vec{b}, \quad C^\top \vec{x} = \vec{y}.$$

Aufgabe (9.55): Mit Python korreliertes Rauschen simulieren

Die Simulations-Anwendung können Sie direkt mit unserem 2×2 -Beispiel ausprobieren: `np.linalg.cholesky` liefert den von Hand berechneten Faktor C , und die Transformation $\vec{x} = C\vec{z}$ verwandelt unkorreliertes Standard-Normal-Rauschen in Daten mit der gewünschten Kovarianzmatrix S (vollständiges Plot-Skript: Appendix C).

```
import numpy as np
S = np.array([[4, 2], [2, 3]])
C = np.linalg.cholesky(S) # [[2, 0], [1, sqrt(2)]]
z = np.random.standard_normal((2, 800))
x = C @ z
print(np.cov(x))          # ungefaehr S
```

Begründen Sie: Warum hat $\vec{x} = C\vec{z}$ die Kovarianzmatrix S ? Nutzen Sie, dass $\vec{z}$ die Kovarianzmatrix E_2 hat, und die Regel $\text{Cov}(C\vec{z}) = C \text{Cov}(\vec{z}) C^\top$.




Abbildung 9.2. Cholesky macht aus Rauschen Daten: Links unkorreliertes Standard-Normal-Rauschen $\vec{z}$, rechts die Punktwolke $\vec{x} = C\vec{z}$ mit Kovarianzmatrix $S = CC^\top$.

Aufgabe (9.56): Cholesky nachrechnen

Bestimmen Sie eine Cholesky-Zerlegung $S = CC^\top$ für

$$S = \begin{pmatrix} 9 & 3 \\ 3 & 5 \end{pmatrix}.$$

Aufgabe (9.57): Cholesky für eine 3×3 -Matrix

Bestimmen Sie eine Cholesky-Zerlegung $S = CC^\top$ für

$$S = \begin{pmatrix} 4 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 10 \end{pmatrix}.$$

Kontrollieren Sie am Ende durch Ausmultiplizieren, dass wirklich $S = CC^\top$ gilt.

Wiederholung (9.58)

Die wichtigsten Punkte dieses Abschnitts:

- Jede symmetrische positiv definite Matrix besitzt eine Cholesky-Zerlegung

$$S = CC^\top$$

mit unterer Dreiecksmatrix C und positiver Diagonale.

- Positive Pivots ermöglichen die Darstellung

$$S = LDL^\top = (L\sqrt{D})(L\sqrt{D})^\top.$$

- Die fünfte Charakterisierung lautet:

$$S \text{ positiv definit} \iff S = A^\top A \text{ mit } A \text{ von vollem Spaltenrang.}$$

- Ohne vollen Rang erhält man nur positive Semidefinitheit.
- Cholesky macht positive Definitheit rechnerisch nutzbar, besonders beim Lösen linearer Gleichungssysteme.

7. Positiv semidefinite Matrizen

Lernziele (9.59)

Nach diesem Abschnitt können Sie...

- positiv semidefinite Matrizen von positiv definiten Matrizen unterscheiden,
- die wichtigsten Charakterisierungen positiver Semidefinitheit anwenden,
- erklären, warum bei positiv semidefiniten Matrizen Null-Energie-Richtungen auftreten können, und
- Kovarianzmatrizen als natürliche Beispiele positiv semidefiniter Matrizen deuten.

Bisher haben wir vor allem den strengen Fall betrachtet:

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

In vielen Anwendungen ist diese Forderung zu stark. Bei Daten kann es Richtungen geben, in denen keine Streuung vorhanden ist – die Energie ist zwar nicht negativ, aber auch nicht positiv. In diesem Fall sprechen wir von **positiv semidefiniten** Matrizen.

Definition (9.60): Positive Semidefinitheit

Eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ heißt **positiv semidefinit**, falls

$$\vec{x}^\top S \vec{x} \geq 0 \quad \text{für alle } \vec{x} \in \mathbb{R}^n.$$

Der Unterschied zu positiver Definitheit ist also nur ein Gleichheitszeichen, aber eins mit weitreichenden Folgen:

	definit	semidefinit
Eigenwerte	$\lambda_i > 0$	$\lambda_i \geq 0$
Energie	$\vec{x}^\top S \vec{x} > 0$ für $\vec{x} \neq \vec{0}$	$\vec{x}^\top S \vec{x} \geq 0$
Geometrie	keine flache Richtung	flache Richtungen erlaubt

Analog zu positiver Definitheit gibt es auch für positiv semidefinite Matrizen mehrere äquivalente Charakterisierungen. Die Charakterisierungen über Eigenwerte und quadratische Form sind naheliegend, wir ersetzen jeweils das > 0 durch ein ≥ 0 . Allerdings funktioniert die Charakterisierung über führende Hauptminoren und Pivots nicht mehr direkt; beispielsweise hat $\begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}$ nur nichtnegative führende Hauptminoren, ist aber nicht positiv semidefinit. Für die letzte Charakterisierung ergibt sich wieder eine analoge Formulierung: $S = A^\top A$ für *irgendeine* Matrix A – nicht notwendigerweise von vollem Spaltenrang!

Theorem 30: Charakterisierungen positiver Semidefinitheit

Für eine symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ sind äquivalent:

1. Alle Eigenwerte von S sind nichtnegativ:

$$\lambda_i \geq 0 \quad \text{für alle } i.$$

2. Die quadratische Form ist nichtnegativ:

$$\vec{x}^\top S \vec{x} \geq 0 \quad \text{für alle } \vec{x} \in \mathbb{R}^n.$$

3. S ist eine sogenannte **Gram-Matrix**:

$$S = A^\top A \quad \text{für irgendeine Matrix } A.$$

Beispiel (9.61): Eine flache Richtung

Die Matrix

$$S = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

ist positiv semidefinit. Denn

$$\vec{x}^\top S \vec{x} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = (x_1 + x_2)^2 \geq 0.$$


Für

$$\vec{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

gilt aber

$$\vec{x}^\top S \vec{x} = 0.$$

Diese Matrix ist also nicht positiv definit. Geometrisch gibt es eine flache Richtung: Entlang der Gerade $x_1 + x_2 = 0$ verschwindet die Energie.



Bemerkung (9.62): Gram-Matrix und Null-Energie

Ist

$$S = A^\top A,$$

dann gilt automatisch

$$\vec{x}^\top S \vec{x} = \vec{x}^\top A^\top A \vec{x} = \|A \vec{x}\|^2 \geq 0.$$

Null-Energie bedeutet dann

$$\vec{x}^\top S \vec{x} = 0 \iff A \vec{x} = \vec{0}.$$

Im Gegensatz zum positiv definiten Fall kann A hier also einen nicht-trivialen Nullraum besitzen – die Elemente aus $\mathcal{N}(A)$ sind die Null-Energie-Richtungen von S .

Beispiel (9.63): Kovarianzmatrix mit perfekter Korrelation

Betrachten wir zwei zentrierte Merkmale mit denselben Beobachtungswerten (drei Beobachtungen als Zeilen, zwei Merkmale als Spalten):

$$A = \begin{pmatrix} -1 & -1 \\ 0 & 0 \\ 1 & 1 \end{pmatrix}.$$

Die empirische Kovarianzmatrix ist

$$S = \frac{1}{2} A^\top A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

Beide Merkmale haben Varianz 1, und ihre Kovarianz ist ebenfalls 1 – die Merkmale sind perfekt korreliert.

Für die Richtung

$$\vec{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

heben sich die Beiträge der beiden Merkmale gegenseitig auf, und damit gilt

$$\vec{x}^\top S \vec{x} = 0.$$

Die Kovarianzmatrix ist also positiv semidefinit, aber nicht positiv definit.

Bemerkung (9.64): Cholesky im semidefiniten Fall

Auch positiv semidefinite Matrizen besitzen Zerlegungen der Form

$$S = CC^\top.$$

Der Unterschied zum positiv definiten Fall: Die Diagonaleinträge von C dürfen jetzt 0 sein. Deshalb kann der einfache Cholesky-Algorithmus an einer Null-Diagonale stehenbleiben oder eine nicht eindeutige Zerlegung liefern.

Für unser Beispiel gilt etwa

$$\begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}.$$

Man sieht direkt: Die zweite Diagonalrichtung trägt keine neue Länge bei.

Aufgabe (9.65): Semidefinitheit erkennen

Entscheiden Sie, ob die folgenden symmetrischen Matrizen positiv definit, positiv semidefinit oder keines von beiden sind:

$$S_1 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}, \quad S_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad S_3 = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

1. Prüfen Sie die Eigenwerte.
2. Schreiben Sie die quadratische Form $\vec{x}^\top S_i \vec{x}$ auf.
3. Deuten Sie bei den positiv semidefiniten Beispielen die Null-Energie-Richtung.

Wiederholung (9.66)

Die wichtigsten Punkte dieses Abschnitts:

- Positiv semidefinit bedeutet

$$\vec{x}^\top S \vec{x} \geq 0 \quad \text{für alle } \vec{x}.$$

- Äquivalent dazu sind nichtnegative Eigenwerte.
- Gram-Matrizen $A^\top A$ und Kovarianzmatrizen $\frac{1}{n-1} A A^\top$ sind automatisch positiv semidefinit.
- Eigenwert 0 bedeutet: Es gibt eine Richtung mit Energie 0.
- Für positive Semidefinitheit müssen alle Hauptminoren nichtnegativ sein, nicht nur die führenden.

A. Lösungen zu den Aktivierungsaufgaben**Lösung zu Aufgabe (9.7) (Kovarianzmatrix)**

Es gilt

$$A^T A = \begin{pmatrix} 1 & 0 & -1 \\ 2 & -1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 0 & -1 \\ -1 & -1 \end{pmatrix} = \begin{pmatrix} 2 & 3 \\ 3 & 6 \end{pmatrix}.$$

Also ist

$$S = \frac{1}{2} A^T A = \begin{pmatrix} 1 & \frac{3}{2} \\ \frac{3}{2} & 3 \end{pmatrix}.$$

Die Varianzen sind 1 und 3, die Kovarianz ist $\frac{3}{2}$.

Für

$$\vec{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

erhält man

$$\vec{x}^T S \vec{x} = \begin{pmatrix} 1 & -1 \end{pmatrix} \begin{pmatrix} -\frac{1}{2} \\ -\frac{3}{2} \end{pmatrix} = 1 \geq 0.$$

Für jeden Vektor $\vec{x}$ gilt das, weil

$$\vec{x}^T S \vec{x} = \frac{1}{2} \|A\vec{x}\|^2 \geq 0.$$

Lösung zu Aufgabe (9.15) (Eigenwert-Test)

Bei A lesen wir die Eigenwerte direkt von der Diagonale ab. Für B berechnen wir

$$\det(B - \lambda E_2) = \begin{vmatrix} 1 - \lambda & 3 \\ 3 & 1 - \lambda \end{vmatrix} = (1 - \lambda)^2 - 9 = (\lambda - 4)(\lambda + 2).$$

Für C entwickeln wir ebenfalls die charakteristische Determinante:

$$\begin{aligned} \det(C - \lambda E_3) &= \begin{vmatrix} 1 - \lambda & 2 & 3 \\ 2 & 4 - \lambda & 6 \\ 3 & 6 & 9 - \lambda \end{vmatrix} \\ &= (1 - \lambda)((4 - \lambda)(9 - \lambda) - 36) - 2(2(9 - \lambda) - 18) \\ &\quad + 3(12 - 3(4 - \lambda)) \\ &= -\lambda^3 + 14\lambda^2 = -\lambda^2(\lambda - 14). \end{aligned}$$

Damit lauten die Eigenwerte

$$A : 4, 1; \quad B : 4, -2; \quad C : 14, 0, 0.$$

Damit ist A positiv definit. Die Matrix B ist nicht positiv semidefinit, da sie den negativen Eigenwert -2 besitzt. Die Matrix C ist positiv semidefinit, aber nicht positiv definit, weil ein Eigenwert 0 ist.

Geometrisch besitzt B eine Richtung mit negativer Energie. Bei C gibt es eine Richtung mit Energie 0.

Lösung zu Aufgabe (9.23) (Aktivierung in Python: alle Richtungen testen)

Für S liegt die Energie für alle Richtungen im Intervall $[1,793, 3,207]$ – sie bleibt strikt über null, also ist S positiv definit. Für T gilt auf dem Einheitskreis

$$q_T(\vec{x}(\theta)) = \cos^2(\theta) - \sin^2(\theta) = \cos(2\theta).$$

Die Energie von T durchläuft daher das Intervall $[-1, 1]$. Insbesondere gibt es Richtungen mit negativer Energie, also ist T indefinit.

Einheitsvektoren genügen, weil die quadratische Form bei Skalierung das Vorzeichen nicht ändert: Für $c \neq 0$ gilt

$$q_S(c\vec{x}) = (c\vec{x})^\top S (c\vec{x}) = c^2 \vec{x}^\top S \vec{x} = \underbrace{c^2}_{>0} q_S(\vec{x}).$$

Schließlich gilt $q_S^{\min} = \lambda_{\min}$ und $q_S^{\max} = \lambda_{\max}$ (für S : $\frac{5 \pm \sqrt{2}}{2} \approx 1,793$ und $3,207$). Die Energie von S auf dem Einheitskreis ist also genau das Intervall zwischen dem kleinsten und größten Eigenwert.

Lösung zu Aufgabe (9.24) (Quadratische Formen lesen)

Die quadratischen Formen lauten

$$q_A(x, y) = 3x^2 + 2y^2, \quad q_B(x, y) = x^2 + 4xy + y^2, \quad q_C(x, y) = 4x^2 + 2xy + 4y^2.$$

Bei A ist wegen der Quadrate $q_A(x, y) > 0$ für alle $(x, y) \neq (0, 0)$, also ist A positiv definit.

Für B liefert zum Beispiel

$$\vec{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

die Energie

$$q_B(1, -1) = 1 - 4 + 1 = -2 < 0.$$

Also ist B nicht positiv definit.

Für C formen wir um:

$$q_C(x, y) = 4x^2 + 2xy + 4y^2 = 3x^2 + (x + y)^2 + 3y^2.$$

Für $(x, y) \neq (0, 0)$ ist dieser Ausdruck strikt positiv. Also ist C positiv definit.

Lösung zu Aufgabe (9.34) (Sylvester-Kriterium anwenden)

Für

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 2 \end{pmatrix}$$

gilt

$$\Delta_1 = 3 > 0, \quad \Delta_2 = \det(A) = 6 - 1 = 5 > 0.$$

Also ist A positiv definit.

Für

$$B = \begin{pmatrix} -1 & 2 \\ 2 & -5 \end{pmatrix}$$

gilt

$$\Delta_1 = -1 < 0, \quad \Delta_2 = \det(B) = 5 - 4 = 1 > 0.$$

Obwohl die Determinante positiv ist, ist B wegen $\Delta_1 < 0$ nicht positiv definit.

Für

$$C = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$$

sind die führenden Hauptminoren

$$\Delta_1 = 2, \quad \Delta_2 = \det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 3, \quad \Delta_3 = \det(C) = 4.$$

Alle sind positiv, also ist C positiv definit.

Bei A und B ist die Determinante jeweils positiv. Dennoch ist nur A positiv definit, denn bei B ist der erste führende Hauptminor negativ. Die Determinante allein reicht also nicht als Test: Sie kontrolliert nur das Produkt der Eigenwerte, nicht deren einzelne Vorzeichen.

Lösung zu Aufgabe (9.43) (Pivot-Test)

Für

$$A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$$

ist der erste Pivot 4. Nach Elimination bleibt unten rechts

$$3 - \frac{2}{4} \cdot 2 = 2.$$

Die Pivots sind also 4 und 2, beide positiv. Damit ist A positiv definit.

Für

$$B = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$$

ist der erste Pivot 2. Der zweite Pivot ist

$$2 - \frac{3}{2} \cdot 3 = -\frac{5}{2}.$$

Also ist B nicht positiv definit.

Für

$$C = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}$$

ist der erste Pivot 1. Nach dem ersten Eliminationsschritt erhält man im unteren Block

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Der zweite Pivot ist 2, der dritte ist

$$2 - \frac{1}{2} \cdot 1 = \frac{3}{2}.$$

Die Pivots sind

$$1, \quad 2, \quad \frac{3}{2},$$

also ist C positiv definit.

Bei C sind die führenden Hauptminoren

$$\Delta_1 = 1, \quad \Delta_2 = 2, \quad \Delta_3 = 3.$$

Passend dazu gilt

$$p_1 = \Delta_1 = 1, \quad p_2 = \frac{\Delta_2}{\Delta_1} = 2, \quad p_3 = \frac{\Delta_3}{\Delta_2} = \frac{3}{2}.$$

Lösung zu Aufgabe (9.55) (Aktivierung in Python: korrelierte Daten simulieren)

`np.linalg.cholesky` liefert

$$C = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix},$$

in Übereinstimmung mit der Handrechnung. Da $\vec{z}$ die Kovarianzmatrix E_2 hat, gilt

$$\text{Cov}(C\vec{z}) = C \text{Cov}(\vec{z}) C^\top = C E_2 C^\top = C C^\top = S.$$

`np.cov(x)` weicht nur durch den Stichprobenfehler von S ab. In Abbildung 9.2 wird aus der kreisrunden Rauschwolke die gekippte Ellipsenwolke mit Varianzen 4 und 3 und Kovarianz 2.

Lösung zu Aufgabe (9.56) (Cholesky nachrechnen)

Wie im 2×2 -Beispiel setzen wir

$$C = \begin{pmatrix} a & 0 \\ b & c \end{pmatrix} \quad \text{mit } a, c > 0$$

an. Der Vergleich von

$$C C^\top = \begin{pmatrix} a^2 & ab \\ ab & b^2 + c^2 \end{pmatrix} \quad \text{mit} \quad S = \begin{pmatrix} 9 & 3 \\ 3 & 5 \end{pmatrix}$$

liefert $a^2 = 9$, also $a = 3$, dann $b = \frac{3}{a} = 1$ und schließlich

$$1 + c^2 = 5 \quad \Rightarrow \quad c = 2.$$

Also

$$S = \begin{pmatrix} 3 & 0 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 3 & 1 \\ 0 & 2 \end{pmatrix}.$$

Lösung zu Aufgabe (9.57) (Cholesky für eine 3×3 -Matrix)

Wir gehen spaltenweise vor wie im Beispiel.

Spalte 1: Aus $\vec{s}_1 = c_{11} \vec{c}_1$ liefert der oberste Eintrag $c_{11}^2 = 4$, also $c_{11} = 2$ und

$$\vec{c}_1 = \frac{1}{2} \begin{pmatrix} 4 \\ 2 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}.$$

Spalte 2: Mit dem bekannten Gewicht $c_{21} = 1$ ist

$$c_{22} \vec{c}_2 = \vec{s}_2 - c_{21} \vec{c}_1 = \begin{pmatrix} 2 \\ 5 \\ 2 \end{pmatrix} - 1 \cdot \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 4 \\ 2 \end{pmatrix}.$$

Der zweite Eintrag liefert $c_{22}^2 = 4$, also $c_{22} = 2$ und $\vec{c}_2 = \frac{1}{2}(0, 4, 2)^\top = (0, 2, 1)^\top$.

Spalte 3: Mit den Gewichten $c_{31} = 0$ und $c_{32} = 1$ ist

$$c_{33} \vec{c}_3 = \vec{s}_3 - c_{31} \vec{c}_1 - c_{32} \vec{c}_2 = \begin{pmatrix} 0 \\ 2 \\ 10 \end{pmatrix} - 0 \cdot \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} - 1 \cdot \begin{pmatrix} 0 \\ 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 9 \end{pmatrix},$$

also $c_{33}^2 = 9$, das heißt $c_{33} = 3$ und $\vec{c}_3 = \frac{1}{3}(0, 0, 9)^\top = (0, 0, 3)^\top$. Insgesamt:

$$C = \begin{pmatrix} 2 & 0 & 0 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{pmatrix}.$$

Die Kontrolle durch Ausmultiplizieren bestätigt

$$CC^\top = \begin{pmatrix} 2 & 0 & 0 \\ 1 & 2 & 0 \\ 0 & 1 & 3 \end{pmatrix} \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & 3 \end{pmatrix} = \begin{pmatrix} 4 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 10 \end{pmatrix} = S.$$

Lösung zu Aufgabe (9.65) (Semidefinitheit erkennen)

Für

$$S_1 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$$

sind die Eigenwerte 4 und 0. Außerdem gilt

$$\vec{x}^\top S_1 \vec{x} = 2(x + y)^2 \geq 0.$$

Also ist S_1 positiv semidefinit, aber nicht positiv definit. Die Null-Energie-Richtungen bilden die Gerade

$$\left\{ t \begin{pmatrix} 1 \\ -1 \end{pmatrix} \mid t \in \mathbb{R} \right\}.$$

Entlang dieser Geraden gilt $x + y = 0$, daher verschwindet die Energie vollständig.

Für

$$S_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

sind die Eigenwerte 1 und -1 . Die quadratische Form ist

$$\vec{x}^\top S_2 \vec{x} = 2xy.$$

Für $(x, y) = (1, -1)$ wird sie negativ. Also ist S_2 nicht positiv semidefinit und damit auch nicht positiv definit.

Für

$$S_3 = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

sind die Eigenwerte 1 und 0. Die quadratische Form ist

$$\vec{x}^\top S_3 \vec{x} = x^2 \geq 0.$$

Also ist S_3 positiv semidefinit, aber nicht positiv definit. Die Null-Energie-Richtungen bilden die Gerade

$$\left\{ t \begin{pmatrix} 0 \\ 1 \end{pmatrix} \mid t \in \mathbb{R} \right\}.$$

Entlang der y -Achse gilt $x = 0$, sodass die Energie x^2 verschwindet.

B. Beweis der Äquivalenz der Charakterisierungen

Im Folgenden sei S eine symmetrische Matrix:

$$S = S^\top \in \mathbb{R}^{n \times n}.$$

Eigenwerte und quadratische Form

Wir zeigen zuerst:

$$\lambda_i > 0 \text{ für alle } i \iff \vec{x}^\top S \vec{x} > 0 \text{ für alle } \vec{x} \neq \vec{0}.$$

Da S symmetrisch ist, gibt es nach dem Spektralsatz eine orthogonale Matrix Q und eine Diagonalmatrix

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}$$

mit

$$S = Q \Lambda Q^\top.$$

Setzen wir

$$\vec{y} = Q^\top \vec{x},$$

dann gilt wegen der Orthogonalität von Q :

$$\vec{x} \neq \vec{0} \iff \vec{y} \neq \vec{0}.$$

Außerdem ist

$$\vec{x}^\top S \vec{x} = \vec{x}^\top Q \Lambda Q^\top \vec{x} = \vec{y}^\top \Lambda \vec{y} = \sum_{i=1}^n \lambda_i y_i^2.$$

Sind alle Eigenwerte positiv, dann ist für jedes $\vec{y} \neq \vec{0}$ mindestens ein $y_i^2 > 0$, also

$$\sum_{i=1}^n \lambda_i y_i^2 > 0.$$

Damit ist die quadratische Form positiv.

Umgekehrt setzen wir voraus, dass

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}$$

gilt. Sei $\vec{v}_i$ ein Eigenvektor zum Eigenwert λ_i . Dann gilt

$$0 < \vec{v}_i^\top S \vec{v}_i = \vec{v}_i^\top \lambda_i \vec{v}_i = \lambda_i \|\vec{v}_i\|^2.$$

Da $\|\vec{v}_i\|^2 > 0$ ist, folgt

$$\lambda_i > 0.$$

Damit sind alle Eigenwerte positiv.

Der Ringschluss der rechnerischen Charakterisierungen

Jetzt zeigen wir den Ringschluss

$$\begin{aligned} &\text{quadratische Form} \Rightarrow \text{führende Hauptminoren} \Rightarrow \text{positive Pivots} \\ &\Rightarrow S = A^\top A \text{ mit } A \text{ von vollem Spaltenrang} \Rightarrow \text{quadratische Form.} \end{aligned}$$

Quadratische Form $\Rightarrow$ führende Hauptminoren

Sei

$$\vec{x}^\top S \vec{x} > 0 \quad \text{für alle } \vec{x} \neq \vec{0}.$$

Sei S_k die führende $k \times k$ -Hauptuntermatrix von S . Für einen Vektor

$$\vec{z} \in \mathbb{R}^k, \quad \vec{z} \neq \vec{0},$$

betrachten wir den eingebetteten Vektor

$$\vec{x} = \begin{pmatrix} \vec{z} \\ \vec{0} \end{pmatrix} \in \mathbb{R}^n.$$

Dann ist

$$\vec{z}^\top S_k \vec{z} = \vec{x}^\top S \vec{x} > 0.$$

Also ist jede führende Hauptuntermatrix S_k selbst positiv definit. Nach der Eigenwert-Charakterisierung hat S_k nur positive Eigenwerte. Daher ist

$$\Delta_k = \det(S_k) = \text{Produkt der Eigenwerte von } S_k > 0.$$

Alle führenden Hauptminoren sind also positiv.

Führende Hauptminoren $\Rightarrow$ positive Pivots

Seien nun alle führenden Hauptminoren positiv:

$$\Delta_1, \Delta_2, \dots, \Delta_n > 0, \quad \Delta_0 := 1.$$

Bei der Gauß-Elimination ohne Zeilenvertauschung gilt für den k -ten Pivot

$$p_k = \frac{\Delta_k}{\Delta_{k-1}}.$$

Diese Formel kann man so lesen: Die Determinante der führenden $k \times k$ -Untermatrix ist das Produkt der ersten k Pivots:

$$\Delta_k = p_1 p_2 \cdots p_k.$$

Damit folgt nacheinander

$$p_1 = \Delta_1, \quad p_2 = \frac{\Delta_2}{\Delta_1}, \quad \dots, \quad p_k = \frac{\Delta_k}{\Delta_{k-1}}.$$

Da alle Δ_k positiv sind, sind auch alle Pivots positiv:

$$p_k > 0 \quad \text{für alle } k.$$

Insbesondere wird kein Pivot null, und es ist keine Zeilenvertauschung nötig.

Positive Pivots $\Rightarrow S = A^\top A$ mit A voller Spaltenrang

Vorausgesetzt, die Gauß-Elimination kommt ohne Zeilenvertauschung aus und alle Pivots sind positiv. Dann liefert die LR-Zerlegung

$$S = LR,$$

wobei L eine normierte untere Dreiecksmatrix ist und R eine obere Dreiecksmatrix.

Die positiven Pivots stehen auf der Diagonale von R . Wir ziehen sie als Diagonalmatrix heraus:

$$D = \begin{pmatrix} p_1 & 0 & \cdots & 0 \\ 0 & p_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & p_n \end{pmatrix}, \quad p_i > 0.$$

Dann kann man R als

$$R = D\tilde{R}$$

schreiben, wobei $\tilde{R}$ eine obere Dreiecksmatrix mit Einsen auf der Diagonale ist. Wegen der Symmetrie von S tritt derselbe Eliminationsfaktor rechts transponiert wieder auf, also

$$\tilde{R} = L^\top.$$

Damit erhalten wir die Zerlegung

$$S = LDL^\top.$$

Da alle Diagonaleinträge von D positiv sind, existiert

$$\sqrt{D} = \begin{pmatrix} \sqrt{p_1} & 0 & \cdots & 0 \\ 0 & \sqrt{p_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{p_n} \end{pmatrix}.$$

Somit ist

$$S = LDL^\top = L\sqrt{D}\sqrt{D}L^\top = (L\sqrt{D})(L\sqrt{D})^\top.$$

Mit

$$C = L\sqrt{D}$$

erhalten wir die Cholesky-Zerlegung

$$\boxed{S = CC^\top.}$$

Die Matrix C ist eine untere Dreiecksmatrix mit positiver Diagonale, also invertierbar. Mit $A = C^\top$ ist $S = A^\top A$ mit A voller Spaltenrang.

$S = A^\top A$ mit A voller Spaltenrang $\Rightarrow$ quadratische Form positiv

Sei

$$S = A^\top A$$

mit einer Matrix $A \in \mathbb{R}^{m \times n}$ von vollem Spaltenrang. Für jeden Vektor $\vec{x} \in \mathbb{R}^n$ gilt

$$\vec{x}^\top S \vec{x} = \vec{x}^\top A^\top A \vec{x} = (A \vec{x})^\top (A \vec{x}) = \|A \vec{x}\|^2.$$

Da A vollen Spaltenrang hat, sind ihre Spalten linear unabhängig. Deshalb ist

$$\mathcal{N}(A) = \{\vec{0}\}.$$

Für $\vec{x} \neq \vec{0}$ folgt somit

$$A \vec{x} \neq \vec{0}.$$

Also folgt

$$\vec{x}^\top S \vec{x} = \|A \vec{x}\|^2 > 0.$$

Damit ist die quadratische Form positiv.

Zusammenfassung

Für symmetrische Matrizen sind damit die folgenden Aussagen äquivalent:

$\lambda_i > 0$ für alle Eigenwerte $\Longleftrightarrow$ $\vec{x}^\top S \vec{x} > 0$ für alle $\vec{x} \neq \vec{0}$ $\Longleftrightarrow$ $\Delta_k > 0$ für alle führenden Hauptminoren $\Longleftrightarrow$ alle Pivots sind positiv $\Longleftrightarrow$ $S = A^\top A$ mit A voller Spaltenrang
--

C. Python-Skripte zu den Aktivierungen

Energie auf dem Einheitskreis (Aufgabe (9.23))

Datei energie_kurve.py:

```

"""Erzeugt energie_kurve.png: Energie  $q(\theta) = x^T M x$  auf dem Einheitskreis.

Fuer positiv definites S bleibt die Kurve strikt ueber null, fuer das
indefinite T wechselt sie das Vorzeichen. Minimum und Maximum der Kurven
sind genau der kleinste bzw. groesste Eigenwert (Rayleigh-Quotient).
"""
import numpy as np
import matplotlib.pyplot as plt

THRO_BLUE = "#005F9E"
THRO_ORANGE = "#E56A21"
THRO_TEAL = "#009688"

S = np.array([[2.0, 0.5], [0.5, 3.0]]) # positiv definit (Beispiel aus Abschnitt
3)
T = np.array([[1.0, 0.0], [0.0, -1.0]]) # indefinit (Sattel aus Abschnitt 3)

theta = np.linspace(0, 2 * np.pi, 400)
X = np.vstack([np.cos(theta), np.sin(theta)]) # Einheitsvektoren als Spalten
qS = np.sum(X * (S @ X), axis=0) #  $x^T S x$  fuer jede Spalte
qT = np.sum(X * (T @ X), axis=0)

lamS = np.linalg.eigvalsh(S)
lamT = np.linalg.eigvalsh(T)
print("q_S in [%.3f, %.3f], Eigenwerte von S:" % (qS.min(), qS.max()), lamS)
print("q_T in [%.3f, %.3f], Eigenwerte von T:" % (qT.min(), qT.max()), lamT)

fig, ax = plt.subplots(figsize=(8.6, 4.2))
ax.axhline(0, color="black", linewidth=0.9)
ax.plot(theta, qS, color=THRO_BLUE, linewidth=2.2,
        label=r"$q_S(\theta)$: positiv definit, bleibt $> 0$")
ax.plot(theta, qT, color=THRO_ORANGE, linewidth=2.2,
        label=r"$q_T(\theta)$: indefinit, wechselt das Vorzeichen")
for lam in lamS:
    ax.axhline(lam, color=THRO_BLUE, linewidth=0.9, linestyle=":", alpha=0.7)
for lam in lamT:
    ax.axhline(lam, color=THRO_ORANGE, linewidth=0.9, linestyle=":", alpha=0.7)
ax.annotate(r"$\lambda_{\max}(S)$", xy=(0.15, lamS[1] + 0.08),
           color=THRO_BLUE, fontsize=9)
ax.annotate(r"$\lambda_{\min}(S)$", xy=(0.15, lamS[0] + 0.08),
           color=THRO_BLUE, fontsize=9)
ax.annotate(r"$\lambda_{\max}(T)$", xy=(2.5, lamT[1] + 0.08),
           color=THRO_ORANGE, fontsize=9)
ax.annotate(r"$\lambda_{\min}(T)$", xy=(2.5, lamT[0] + 0.08),
           color=THRO_ORANGE, fontsize=9)
ax.set_xlim(0, 2 * np.pi)

```

```

ax.set_xticks([0, np.pi / 2, np.pi, 3 * np.pi / 2, 2 * np.pi])
ax.set_xticklabels([r"$0$", r"$\pi/2$", r"$\pi$", r"$3\pi/2$", r"$2\pi$"])
ax.set_xlabel(r"Richtung $\vec{x}(\theta) = (\cos\theta, \sin\theta)^\top$")
ax.set_ylabel(r"Energie $\vec{x}^\top M \vec{x}$")
ax.legend(loc="upper right", fontsize=9)
fig.tight_layout()
fig.savefig("energie_kurve.png", dpi=200, bbox_inches="tight")
print("energie_kurve.png geschrieben")

```

Korrelierte Daten per Cholesky (Aufgabe (9.55))

Datei cholesky_sampling.py:

```

"""Erzeugt cholesky_sampling.png: korrelierte Daten per Cholesky-Faktor.

Standard-Normal-Rauschen z wird mit dem Cholesky-Faktor C von
S = [[4, 2], [2, 3]] (Beispiel aus Abschnitt 6) zu x = C z transformiert.
Die Punktwolke x hat dann (empirisch) genau die Kovarianzmatrix S.
"""
import numpy as np
import matplotlib.pyplot as plt

THRO_BLUE = "#005F9E"
THRO_ORANGE = "#E56A21"

rng = np.random.default_rng(9)

S = np.array([[4.0, 2.0], [2.0, 3.0]])
C = np.linalg.cholesky(S)
print("Cholesky-Faktor C =\n", C)          # [[2, 0], [1, sqrt(2)]]

z = rng.standard_normal((2, 800))        # unkorreliertes Rauschen
x = C @ z                                # gewünschte Kovarianzstruktur
print("empirische Kovarianz von x =\n", np.cov(x))

fig, axes = plt.subplots(1, 2, figsize=(9.6, 4.4), sharex=True, sharey=True)
axes[0].scatter(z[0], z[1], s=6, alpha=0.45, color=THRO_BLUE)
axes[0].set_title(r"Rauschen $\vec{z}$: Kovarianz $E_2$",
                  color=THRO_BLUE, fontsize=11)
axes[1].scatter(x[0], x[1], s=6, alpha=0.45, color=THRO_ORANGE)
axes[1].set_title(r"$\vec{x} = C\vec{z}$: Kovarianz $S$",
                  color=THRO_ORANGE, fontsize=11)

# Kovarianz-Ellipse (2-sigma) aus den Eigenpaaren von S
lam, V = np.linalg.eigh(S)
t = np.linspace(0, 2 * np.pi, 200)
ell = V @ (2 * np.sqrt(lam)[:, None] * np.vstack([np.cos(t), np.sin(t)]))
axes[1].plot(ell[0], ell[1], color=THRO_BLUE, linewidth=1.8)

for ax in axes:

```

```
ax.set_xlim(-7, 7)
ax.set_ylim(-7, 7)
ax.set_aspect("equal")
ax.set_xlabel("Merkmal 1")
axes[0].set_ylabel("Merkmal 2")
fig.tight_layout()
fig.savefig("cholesky_sampling.png", dpi=200, bbox_inches="tight")
print("cholesky_sampling.png geschrieben")
```