

INHALTSVERZEICHNIS

10. Singulärwertzerlegung	2
1. Motivation: Die perfekte Zerlegung für jede Matrix	2
2. SVD und geometrische Interpretation	6
2.1. Der Satz über die Singulärwertzerlegung	6
2.2. Rechte und linke Singulärvektoren	7
2.3. Die Einheitskugel wird zum Ellipsoid	8
2.4. Die SVD ist nicht eindeutig	12
3. Zusammenhang der SVD mit $A^T A$ und AA^T	13
3.1. Der Umweg über symmetrische Matrizen	13
3.2. Die SVD enthüllt zwei Spektralzerlegungen	14
3.3. $A^T A$ und AA^T besitzen dieselben positiven Eigenwerte	15
4. Berechnung einer SVD von Hand	16
5. Reduzierte SVD, Rang und fundamentale Unterräume	21
5.1. Welche Spalten tragen tatsächlich zu A bei?	21
5.2. Die vier fundamentalen Unterräume	22
6. Rang-1-Zerlegung und beste Rang- k -Approximation	24
6.1. Die SVD als Summe einfacher Muster	24
6.2. Frobeniusnorm: Ein Maß für den Approximationsfehler	25
6.3. Die abgeschnittene SVD	26
6.4. Eckart–Young: Abschneiden ist optimal	27
7. Bild- und Datenkompression	28
7.1. Bildkompression mit der SVD	28
7.2. Singulärwerte helfen bei der Wahl von k	30
8. Anwendungen der SVD und Zusammenfassung	31
A. Lösungen zu den Aktivierungsaufgaben	35
B. Beweise zu ausgewählten Sätzen	39
B.1. Technische Vorbereitungen	39
B.2. Existenz der Singulärwertzerlegung	40
B.3. Folgerungen für Gram-Matrizen und fundamentale Unterräume . .	41

Kapitel 10

SINGULÄRWERTZERLEGUNG

1. Motivation: Die perfekte Zerlegung für jede Matrix

Lernziele (10.1)

Nach diesem Abschnitt können Sie...

- erklären, weshalb der Spektralsatz nicht direkt auf allgemeine rechteckige Matrizen anwendbar ist,
- das Ziel der Singulärwertzerlegung als Verallgemeinerung des Spektralsatzes beschreiben,
- die Rollen der drei Faktoren U , Σ und $V^\top$ intuitiv einordnen und
- begründen, weshalb eine Zerlegung in unterschiedlich wichtige Richtungen für Datenkompression nützlich ist.

Ausgangslage: Die meisten Matrizen sind nicht quadratisch

In Kapitel 8 haben wir für symmetrische Matrizen eine nahezu perfekte Beschreibung gefunden. Der Spektralsatz zerlegt jede symmetrische Matrix $S \in \mathbb{R}^{n \times n}$ in

$$S = Q \Lambda Q^\top.$$

Dabei ist $Q^\top$ die Transformation von der kanonischen Basis in eine Orthonormalbasis aus Eigenvektoren. In dieser Basis sieht S denkbar einfach aus: Die Diagonalmatrix Λ skaliert jede Eigenrichtung unabhängig, keine der Richtungen werden vermischt. Anschließend übersetzt Q das Ergebnis zurück in die ursprünglichen Koordinaten.

In Data Science und maschinellem Lernen sind unsere wichtigsten Matrizen jedoch selten symmetrisch und häufig nicht einmal quadratisch:

- Eine Datenmatrix enthält m Beobachtungen mit jeweils n Merkmalen.
- Ein Graustufenbild mit m Zeilen und n Spalten ist eine Matrix aus Pixelintensitäten.

- Die Gewichtsmatrix einer Schicht eines neuronalen Netzes bildet Eingaben einer Dimension auf Ausgaben einer möglicherweise anderen Dimension ab.

Für eine allgemeine Matrix $A \in \mathbb{R}^{m \times n}$ können wir den Spektralsatz nicht direkt verwenden:

- Ist $m \neq n$, besitzt A im üblichen Sinn gar keine Eigenwerte, denn $A\vec{x} \in \mathbb{R}^m$ und $\lambda\vec{x} \in \mathbb{R}^n$ leben in verschiedenen Räumen.
- Selbst für $m = n$ muss A weder symmetrisch noch diagonalisierbar sein.
- Eine allgemeine Matrix kann Vektoren drehen, spiegeln, strecken, stauchen und sogar Dimensionen vollständig löschen.

Beispiel (10.2): Rechteckige Matrizen haben keine Eigenvektoren

Betrachten wir

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{pmatrix} \in \mathbb{R}^{2 \times 3}.$$

Die Matrix bildet Vektoren aus dem $\mathbb{R}^3$ auf Vektoren im $\mathbb{R}^2$ ab:

$$\begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \mapsto A \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} x_1 + x_3 \\ 2x_2 \end{pmatrix}.$$

Eine Eigenwertgleichung $A\vec{x} = \lambda\vec{x}$ kann hier niemals wahr sein: Die linke Seite liegt in $\mathbb{R}^2$, die rechte Seite in $\mathbb{R}^3$. Trotzdem besitzt A „bevorzugte“ Richtungen. Beispielsweise gilt

$$A \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad A \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \sqrt{2} \begin{pmatrix} 1 \\ 0 \end{pmatrix}. \quad (\text{Hinweis: } \frac{2}{\sqrt{2}} = \sqrt{2})$$

Die Eingabe- und Ausgaberrichtungen sind zwar verschieden, aber die Wirkung von A auf diesen Richtungen ist wieder nur eine Skalierung:

$$A \begin{pmatrix} 0 \\ 4 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 8 \end{pmatrix} = 2 \cdot \begin{pmatrix} 0 \\ 4 \end{pmatrix}.$$

und

$$A \begin{pmatrix} \frac{4}{\sqrt{2}} \\ 0 \\ \frac{4}{\sqrt{2}} \end{pmatrix} = \sqrt{2} \begin{pmatrix} 4 \\ 0 \end{pmatrix}.$$

Der Unterschied zu Eigenvektoren ist also, dass wir für rechteckige Matrizen auf der linken und auf der rechten Seite unterschiedliche Vektoren brauchen. Wir werden diese später als **Singulärvektoren** kennenlernen; die Skalierungsfaktoren heißen **Singulärwerte**.

Die Singulärwertzerlegung

Die **Singulärwertzerlegung**, kurz **SVD** vom englischen *Singular Value Decomposition*, liefert uns das rechteckige Gegenstück zum Spektralsatz. Für jede Matrix $A \in \mathbb{R}^{m \times n}$ findet sie orthogonale Koordinatensysteme im Eingabe- und Ausgaberaum, sodass A dazwischen nur noch entlang senkrechter Richtungen skaliert:

$$A = U \Sigma V^T.$$


Dabei sind

$$U \in \mathbb{R}^{m \times m}, \quad \Sigma \in \mathbb{R}^{m \times n}, \quad V \in \mathbb{R}^{n \times n}.$$

Die Matrizen U und V sind orthogonal: Die Spalten von U bilden eine Orthonormalbasis von $\mathbb{R}^m$, die Spalten von V eine Orthonormalbasis von $\mathbb{R}^n$. Die rechteckige Diagonalmatrix Σ besitzt auf ihrer Hauptdiagonale r positive Zahlen

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \quad r = \text{rank}(A),$$

und sonst nur Nullen. Die Zahlen $\sigma_1, \sigma_2, \dots, \sigma_r$ heißen **Singulärwerte** von A .



Für quadratische Matrizen können wir uns orthogonale Koordinatenwechsel als Drehungen oder Spiegelungen vorstellen. Die SVD sagt dann anschaulich:

Jede lineare Abbildung lässt sich durch drei Schritte beschreiben:
Drehung oder Spiegelung der Eingabe, Skalierung entlang
senkrechter Richtungen und schließlich eine weitere Drehung oder
Spiegelung.

Bei rechteckigen Matrizen kommt hinzu, dass Σ die Dimension ändert.

Bemerkung (10.3): Spektralsatz und SVD im Vergleich

Spektralsatz	Singulärwertzerlegung
$S = Q \Lambda Q^T$	$A = U \Sigma V^T$
$S = S^T \in \mathbb{R}^{n \times n}$	$A \in \mathbb{R}^{m \times n}$ beliebig
eine gemeinsame Eigenbasis	passende Basen in zwei Räumen
Eigenwerte $\lambda_i \in \mathbb{R} \quad (i = 1, \dots, n)$	Singulärwerte $\sigma_i > 0 \quad (i = 1, \dots, \text{rank}(A))$

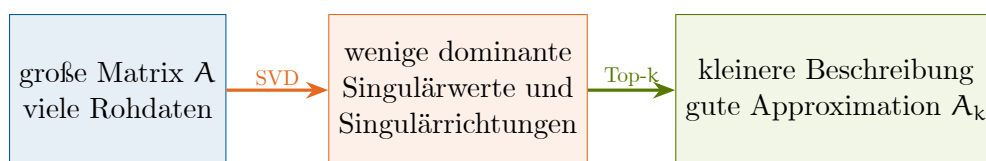
Beim Spektralsatz reichen dieselben Richtungen für Eingabe und Ausgabe. Die SVD erlaubt unterschiedliche **rechte und linke Singulärrichtungen** – diese zusätzliche Freiheit reicht aus, damit die Zerlegung für jede Matrix möglich ist.

SVD als Werkzeug für Datenkompression

Die Singulärwerte messen, wie stark die zugehörigen Richtungen zur Wirkung der Matrix beitragen. Große Singulärwerte haben einen starken Einfluss, kleine Singulärwerte kaum. Das eröffnet uns eine Möglichkeit, die Matrix zu approximieren:

Behalten wir nur die wichtigsten Singulärrichtungen, erhalten wir eine kleinere Beschreibung der Matrix, die möglichst viel ihrer Struktur bewahrt.

In einem Graustufenbild beispielsweise sind benachbarte Pixel meist ähnlich, große Flächen besitzen vergleichbare Helligkeiten und viele Bildbereiche wiederholen sich strukturell. Üblicherweise hat die Pixelmatrix also einen deutlich niedrigeren Rang als ihre Dimension. Die SVD kann diese Redundanz erkennen und das Bild als Summe weniger wichtiger Muster beschreiben.



Dieses Prinzip werden wir später mathematisch präzisieren. Es bildet nicht nur die Grundlage der Bild- und Datenkompression, sondern auch der Hauptkomponentenanalyse (PCA), der Rauschunterdrückung und vieler weiterer Verfahren des maschinellen Lernens.

Aufgabe (10.4): Aktivierung: Warum brauchen wir zwei Basen?

Betrachten Sie erneut

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 2 & 0 \end{pmatrix}.$$

1. Geben Sie die Dimension des Eingabe- und des Ausgaberaums an.
2. Überprüfen Sie, dass

$$\vec{v}_1 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \quad \vec{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \quad \vec{v}_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}$$

eine Orthonormalbasis des Eingaberaums bilden.

3. Berechnen Sie $A\vec{v}_1$, $A\vec{v}_2$ und $A\vec{v}_3$. Welche Richtung wird am stärksten skaliert, welche vollständig gelöscht?
4. Erklären Sie anhand des Beispiels, weshalb Eingabe- und Ausgaberrichtungen nicht dieselben Vektoren sein können.

2. SVD und geometrische Interpretation

Lernziele (10.5)

Nach diesem Abschnitt können Sie...

- den Satz über die Singulärwertzerlegung präzise formulieren,
- die Dimensionen und geometrischen Rollen von U , Σ und V^T erklären,
- die Gleichung $A\vec{v}_i = \sigma_i\vec{u}_i$ interpretieren, und
- die wesentlichen Ursachen für die Nicht-Eindeutigkeit von Singulärvektoren beschreiben.

2.1. Der Satz über die Singulärwertzerlegung

Wir haben das Ziel im vorigen Abschnitt bereits kennengelernt: Eine allgemeine Matrix soll in passenden orthonormalen Koordinatensystemen so einfach wie möglich wirken. Der *Satz über die Singulärwertzerlegung* garantiert, dass dies immer gelingt:

Theorem 30: Existenz der Singulärwertzerlegung

Zu jeder Matrix $A \in \mathbb{R}^{m \times n}$ existieren orthogonale Matrizen

$$U = (\vec{u}_1 \mid \cdots \mid \vec{u}_m) \in \mathbb{R}^{m \times m}, \quad V = (\vec{v}_1 \mid \cdots \mid \vec{v}_n) \in \mathbb{R}^{n \times n}$$

und eine rechteckige Diagonalmatrix $\Sigma \in \mathbb{R}^{m \times n}$, sodass

$$A = U\Sigma V^T.$$

Ist $r = \text{rank}(A)$, so können die Diagonaleinträge von Σ als

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

gewählt werden; alle übrigen Diagonaleinträge sind 0. Die Zahlen $\sigma_1, \dots, \sigma_r$ heißen die **positiven Singulärwerte** von A .

Vollständiger Existenzbeweis: Appendix B.

Die Bezeichnung „rechteckige Diagonalmatrix“ bedeutet: Nur auf der Hauptdiagonale dürfen Einträge von 0 verschieden sein. Je nach Form von A sieht Σ beispielsweise so

aus:

$$\begin{array}{cc} m < n & m > n \\ \Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \end{pmatrix} & \Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}. \end{array}$$

Nullspalten zeigen, welche **Eingaberichtungen** von A vollständig gelöscht werden; **Nullzeilen**, welche **Ausgaberichtungen** von A niemals erreicht werden.

Bemerkung (10.6): Dimensionskontrolle

Die Dimensionen in der SVD passen genau zusammen:

$$\underbrace{A}_{m \times n} = \underbrace{U}_{m \times m} \underbrace{\Sigma}_{m \times n} \underbrace{V^T}_{n \times n}.$$

Von rechts nach links gelesen gilt für $\vec{x} \in \mathbb{R}^n$:

$$\vec{x} \xrightarrow{V^T} V^T \vec{x} \in \mathbb{R}^n \xrightarrow{\Sigma} \Sigma V^T \vec{x} \in \mathbb{R}^m \xrightarrow{U} U \Sigma V^T \vec{x} = A \vec{x} \in \mathbb{R}^m.$$

Nur der mittlere Faktor Σ kann die Dimension ändern.

2.2. Rechte und linke Singulärvektoren

Multiplizieren wir die SVD von rechts mit V , erhalten wir wegen $V^T V = E_n$:

$$A = U \Sigma V^T \quad \implies \quad \boxed{AV = U \Sigma.}$$

Auf der linken Seite stehen die Bilder der Spalten von V :

$$AV = (A\vec{v}_1 \mid \dots \mid A\vec{v}_n).$$

Auf der rechten Seite skaliert Σ die ersten r Spalten von U mit den Singulärwerten und setzt alle übrigen Spalten auf null:

$$U \Sigma = (\sigma_1 \vec{u}_1 \mid \dots \mid \sigma_r \vec{u}_r \mid \vec{0} \mid \dots \mid \vec{0}).$$

Durch Spaltenvergleich erhalten wir Gleichungen, die Eigenwertgleichungen sehr ähneln:

$$\boxed{A\vec{v}_i = \sigma_i \vec{u}_i \quad \text{für } i = 1, \dots, r.}$$

Definition (10.7): Linke und rechte Singulärvektoren

Die Vektoren

$$\vec{v}_1, \dots, \vec{v}_n \in \mathbb{R}^n$$

heißen **rechte Singulärvektoren**. Sie bilden eine **ONB des Eingaberaums**.

Die Vektoren

$$\vec{u}_1, \dots, \vec{u}_m \in \mathbb{R}^m$$

heißen **linke Singulärvektoren**. Sie bilden eine **ONB des Ausgaberaums**.

Merkhilfe: $V^\top$ steht *rechts* von $\Sigma \Rightarrow$ *rechte* Singulärvektoren.

Die Gleichung $A\vec{v}_i = \sigma_i \vec{u}_i$ verrät uns die Geometrie der Singulärwertzerlegung:

1. Wir starten in der **Einheitsrichtung $\vec{v}_i$** des Eingaberaums.
2. Die Matrix **A** skaliert diese Richtung um den Faktor **σ_i** .
3. Das **Ergebnis zeigt in die Ausgaberrichtung $\vec{u}_i$** .

Für $i > r$ gilt dagegen

$$A\vec{v}_i = \vec{0}.$$

Diese **rechten Singulärvektoren** zeigen also in Richtungen, die von **A** vollständig gelöscht werden.

2.3. Die Einheitskugel wird zum Ellipsoid

Die abgeschlossene **Einheitskugel** im $\mathbb{R}^n$ ist

$$\{\vec{x} \in \mathbb{R}^n \mid \|\vec{x}\| \leq 1\}.$$



Ihr Rand besteht aus allen Vektoren der Länge 1; im $\mathbb{R}^2$ ist dies der Einheitskreis. Durch Betrachtung der Einheitskugel können wir die geometrische Wirkung der SVD gut nachvollziehen:

- **$V^\top$** dreht oder spiegelt die Kugel. Ihre Form ändert sich dabei nicht.
- **Σ** streckt oder staucht entlang senkrechter Achsen und kann Richtungen auf **0** zusammendrücken.
- **U** dreht oder spiegelt das Ergebnis in seine endgültige Lage.

Das Bild der Einheitskugel ist deshalb ein gefülltes Ellipsoid, möglicherweise zusammengedrückt auf einen niedrigerdimensionalen Unterraum. Abbildung 10.1 zeigt die vier Schritte der SVD für eine 2-dimensionale Matrix mit vollem Rang. Wir schreiben


$$\mathcal{V} = (\vec{v}_1, \vec{v}_2), \quad \mathcal{U} = (\vec{u}_1, \vec{u}_2)$$

für die rechte beziehungsweise linke Singulärbasis; mit $[\vec{x}]_{\mathcal{B}}$ bezeichnen wir wieder die Koordinaten des Vektors $\vec{x}$ bezüglich der Basis $\mathcal{B}$. Abbildung 10.2 zeigt die SVD einer rechteckigen Matrix von $\mathbb{R}^3$ nach $\mathbb{R}^2$, die die Einheitskugel auf eine Ellipse abbildet.

1. Eingabe: Standardachsen und $\vec{v}_1, \vec{v}_2$ **4. U : Ausgabe in Standardachsen**

$$A = U\Sigma V^T$$

$$V^T \downarrow$$

2. V^T : Koordinaten bezüglich $\mathcal{V}$ 

$$\Sigma$$

$\mathcal{V}$ -Koord. $\rightarrow$ $\mathcal{U}$ -Koord.


3. Σ : Koordinaten bezüglich $\mathcal{U}$ 

Abbildung 10.1. Die SVD als Folge von drei einfachen Operationen: V^T schreibt die Eingabe in Koordinaten bezüglich der rechten Singulärbasis $\mathcal{V}$, Σ skaliert diese Koordinaten und interpretiert sie als Koordinaten bezüglich der linken Singulärbasis $\mathcal{U}$, und U setzt daraus den Ausgabevektor in Standardkoordinaten zusammen.




Abbildung 10.2. Eine rechteckige SVD von $\mathbb{R}^3$ nach $\mathbb{R}^2$: Wir starten mit Datenvektoren $\vec{x} \in \mathbb{R}^3$. Danach beschreibt $\vec{c} = V^T \vec{x}$ dieselben Daten bezüglich der Basis $\mathcal{V}$. Die rechteckige Matrix Σ verwirft den Eintrag c_3 und setzt $\vec{y} = \Sigma \vec{c} = (\sigma_1 c_1, \sigma_2 c_2)^T \in \mathbb{R}^2$. Anschließend dreht U diese zweidimensionalen Koordinaten bezüglich der Basis $\mathcal{U}$ zu $\vec{z} = U \vec{y}$ im Ausgaberaum.

Folgerung (10.8): Geometrische Bedeutung der Singulärwerte

Die positiven Singulärwerte

$$\sigma_1 \geq \dots \geq \sigma_r > 0$$

sind die Längen der Halbachsen des Ellipsoids, das aus der Einheitskugel durch Anwendung von A entsteht. Die zugehörigen Halbachsen zeigen in die Richtungen $\vec{u}_1, \dots, \vec{u}_r$.

Insbesondere ist σ_1 der größte Streckungsfaktor von A : Kein Vektor der Länge 1 wird durch A länger als σ_1 . Die Richtung $\vec{v}_1$ erreicht genau diese maximale Streckung:

$$\|A\vec{v}_1\| = \|\sigma_1\vec{u}_1\| = \sigma_1.$$

Je kleiner σ_i ist, desto weniger Wirkung besitzt A in Richtung $\vec{v}_i$. Diese Beobachtung wird später erklären, weshalb wir Richtungen mit kleinen Singulärwerten häufig verwerfen können.

Beispiel (10.9): Eine SVD direkt lesen

Gegeben sei eine Matrix mit der SVD

$$A = \underbrace{\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}}_U \underbrace{\begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}}_\Sigma \underbrace{\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}}_V^T.$$

So sehen wir die rechten Singulärvektoren direkt als Spalten von V . Ohne die drei Matrizen auszumultiplizieren können wir ablesen:

- Der größte Singulärwert ist $\sigma_1 = 3$, der zweite ist $\sigma_2 = 1$.

- Die rechte Singulärrichtung

$$\vec{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

wird am stärksten gestreckt.

- Ihr Bild zeigt in Richtung

$$\vec{u}_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad A\vec{v}_1 = 3\vec{u}_1.$$

- Der Einheitskreis wird auf eine Ellipse mit Halbachsenlängen 3 und 1 abgebildet.

2.4. Die SVD ist nicht eindeutig

Die Singulärwerte einer Matrix sind eindeutig bestimmt. Bei den Singulärvektoren gibt es jedoch Freiheiten:

Bemerkung (10.10): Nicht-Eindeutigkeit der Singulärvektoren

- **Vorzeichen:** Aus

$$A\vec{v}_i = \sigma_i \vec{u}_i$$

folgt auch

$$A(-\vec{v}_i) = \sigma_i (-\vec{u}_i).$$

Die Vorzeichen von $\vec{u}_i$ und $\vec{v}_i$ dürfen also gleichzeitig gewechselt werden.

- **Mehrfache Singulärwerte:** Ist ein Singulärwert mehrfach vorhanden, sind die einzelnen Singulärvektoren innerhalb des zugehörigen Unterraums nicht eindeutig. Der Unterraum selbst ist jedoch eindeutig bestimmt.
- **Nullrichtungen:** Die Vektoren $\vec{v}_{r+1}, \dots, \vec{v}_n$ und $\vec{u}_{r+1}, \dots, \vec{u}_m$ können auf verschiedene Arten gewählt werden, um $\vec{v}_1, \dots, \vec{v}_r$ bzw. $\vec{u}_1, \dots, \vec{u}_r$ zu Orthonormalbasen zu ergänzen.

Diese Freiheiten verändern weder die Matrix A noch die geometrische Wirkung ihrer SVD. Beschweren Sie sich deshalb bitte nicht bei mir, wenn Sie für Ihre SVD ein anderes Ergebnis erhalten, als in der Musterlösung angegeben ist. ☹️

Aufgabe (10.11): SVD geometrisch interpretieren

Eine Matrix $A \in \mathbb{R}^{3 \times 2}$ besitze die SVD

$$A = U\Sigma V^T, \quad \Sigma = \begin{pmatrix} 5 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix}.$$

1. In welchem Raum liegen die rechten Singulärvektoren, in welchem die linken?
2. Welche Form hat das Bild des Einheitskreises unter A ? Geben Sie seine Halbachsenlängen an.
3. Welchen Rang besitzt A ?
4. Ergänzen Sie:

$$A\vec{v}_1 = \underline{\hspace{2cm}}, \quad A\vec{v}_2 = \underline{\hspace{2cm}}.$$

5. Erklären Sie, weshalb die dritte Spalte von U die Lage des Ellipsenbildes nicht beeinflusst.

3. Zusammenhang der SVD mit $A^\top A$ und $AA^\top$

Lernziele (10.12)

Nach diesem Abschnitt können Sie...

- erklären, weshalb $A^\top A$ und $AA^\top$ symmetrisch und positiv semidefinit sind,
- die Spektralzerlegungen von $A^\top A$ und $AA^\top$ aus einer SVD von A ableiten,
- Singulärwerte als Quadratwurzeln positiver Eigenwerte bestimmen,
- rechte und linke Singulärvektoren mit den Eigenvektoren der beiden Gram-Matrizen verbinden und
- begründen, weshalb $A^\top A$ und $AA^\top$ dieselben positiven Eigenwerte besitzen.

3.1. Der Umweg über symmetrische Matrizen

Für eine allgemeine Matrix $A \in \mathbb{R}^{m \times n}$ dürfen wir den Spektralsatz nicht direkt anwenden. Wir können aus A jedoch zwei symmetrische Matrizen bauen:

$$\boxed{A^\top A \in \mathbb{R}^{n \times n}} \quad \text{und} \quad \boxed{AA^\top \in \mathbb{R}^{m \times m}}.$$

Die Symmetrie können wir leicht überprüfen:

$$(A^\top A)^\top = A^\top (A^\top)^\top = A^\top A, \quad (AA^\top)^\top = (A^\top)^\top A^\top = AA^\top.$$

Aus Kapitel 9 wissen wir sogar noch mehr: Beide Matrizen sind **positiv semidefinit**, denn für alle passenden Vektoren $\vec{x} \in \mathbb{R}^n$ und $\vec{y} \in \mathbb{R}^m$ gilt für die quadratischen Formen:

$$\vec{x}^\top A^\top A \vec{x} = \|A\vec{x}\|^2 \geq 0, \quad \vec{y}^\top AA^\top \vec{y} = \|A^\top \vec{y}\|^2 \geq 0.$$

Folglich besitzen beide Matrizen nur nichtnegative Eigenwerte und, wegen der Symmetrie, orthonormale Basen aus Eigenvektoren (Spektralsatz). Wenn wir die Verbindung zwischen Eigen- und Singulärwerten und Eigen- und Singulärvektoren verstehen, können wir die SVD von A aus den Spektralzerlegungen von $A^\top A$ und $AA^\top$ konstruieren.

Bemerkung (10.13): Zwei Gram-Matrizen, zwei Räume

- $A^\top A$ wirkt auf dem Eingaberaum $\mathbb{R}^n$. Die Eigenvektoren von $A^\top A$ werden die *rechten* Singulärvektoren.
- $AA^\top$ wirkt auf dem Ausgaberaum $\mathbb{R}^m$. Die Eigenvektoren von $AA^\top$ werden die *linken* Singulärvektoren.

3.2. Die SVD enthüllt zwei Spektralzerlegungen

Nehmen wir zunächst an, die SVD

$$A = U\Sigma V^T$$

sei bereits bekannt. Dann folgt wegen $U^T U = E_m$:

$$\begin{aligned} A^T A &= (U\Sigma V^T)^T (U\Sigma V^T) \\ &= V\Sigma^T U^T U\Sigma V^T \\ &= \boxed{V(\Sigma^T \Sigma)V^T}. \end{aligned}$$

Die Matrix $\Sigma^T \Sigma \in \mathbb{R}^{n \times n}$ ist diagonal. Auf ihrer Diagonale stehen die quadrierten Singulärwerte:

$$\Sigma^T \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0).$$

Damit ist

$$\boxed{A^T A = V \underbrace{\text{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0)}_{\lambda} V^T}$$

einfach die Spektralzerlegung von $A^T A$.

Analog erhalten wir wegen $V^T V = E_n$:

$$\begin{aligned} AA^T &= (U\Sigma V^T)(U\Sigma V^T)^T \\ &= U\Sigma V^T V\Sigma^T U^T \\ &= \boxed{U(\Sigma \Sigma^T)U^T}. \end{aligned}$$

Auch $\Sigma \Sigma^T \in \mathbb{R}^{m \times m}$ besitzt die positiven Diagonaleinträge

$$\sigma_1^2, \dots, \sigma_r^2$$

und sonst nur Nullen. Wir können also unmittelbar ablesen:

Folgerung (10.14): Singulärwerte und Eigenwerte

Für $i = 1, \dots, r = \text{rank}(A)$ gilt:

$$\boxed{A^T A \vec{v}_i = \sigma_i^2 \vec{v}_i, \quad AA^T \vec{u}_i = \sigma_i^2 \vec{u}_i.}$$

Die positiven Singulärwerte von A sind daher die Quadratwurzeln der positiven Eigenwerte von $A^T A$ beziehungsweise AA^T :

$$\boxed{\sigma_i = \sqrt{\lambda_i}.}$$

3.3. $A^\top A$ und $AA^\top$ besitzen dieselben positiven Eigenwerte

Die obige Rechnung zeigt die Behauptung bereits über die SVD. Wir können die Verbindung aber auch direkt erkennen. Sei $\vec{v}$ ein Eigenvektor von $A^\top A$ zum Eigenwert $\lambda > 0$:

$$A^\top A \vec{v} = \lambda \vec{v}.$$

Dann ist $A\vec{v} \neq \vec{0}$, denn sonst wäre auch $A^\top A \vec{v} = \vec{0}$ und damit $\lambda \vec{v} = \vec{0}$, ein Widerspruch zu $\lambda > 0$ und $\vec{v} \neq \vec{0}$. Außerdem gilt

$$AA^\top(A\vec{v}) = A(A^\top A \vec{v}) = A(\lambda \vec{v}) = \lambda(A\vec{v}).$$

Somit ist $A\vec{v}$ ein Eigenvektor von $AA^\top$ zum selben positiven Eigenwert λ . Analog folgt, dass jeder positive Eigenwert von $AA^\top$ auch ein positiver Eigenwert von $A^\top A$ ist.

Lemma (10.15): Gemeinsame positive Eigenwerte

Die Matrizen $A^\top A$ und $AA^\top$ besitzen dieselben positiven Eigenwerte mit denselben algebraischen Vielfachheiten. Zusätzliche Eigenwerte können nur Nullen sein.

Beispiel (10.16): Gleiche positive Eigenwerte, verschiedene Dimensionen

Für

$$\Sigma = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \end{pmatrix}$$

gilt

$$\Sigma^\top \Sigma = \begin{pmatrix} 9 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad \Sigma \Sigma^\top = \begin{pmatrix} 9 & 0 \\ 0 & 4 \end{pmatrix}.$$

Beide Matrizen besitzen die positiven Eigenwerte 9 und 4. Die größere Matrix $\Sigma^\top \Sigma$ besitzt zusätzlich den Eigenwert 0. Die zugehörigen Singulärwerte von Σ sind 3 und 2.

Aufgabe (10.17): Gram-Matrizen vergleichen

Betrachten Sie die Matrix

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

1. Berechnen Sie $A^\top A$ und $AA^\top$.
2. Bestimmen Sie die Eigenwerte beider Matrizen.
3. Welche positiven Eigenwerte stimmen überein? Welche Singulärwerte von A ergeben sich daraus?
4. Warum besitzt eine der beiden Gram-Matrizen zusätzlich den Eigenwert 0?

4. Berechnung einer SVD von Hand

Lernziele (10.18)

Nach diesem Abschnitt können Sie...

- eine vollständige SVD einer einfachen rechteckigen Matrix schrittweise berechnen,
- Eigenwerte und Eigenvektoren von $A^T A$ korrekt zu Singulärwerten und rechten Singulärvektoren ordnen,
- linke Singulärvektoren mit $\vec{u}_i = A\vec{v}_i/\sigma_i$ bestimmen,
- Nullrichtungen zu einer vollständigen Orthonormalbasis ergänzen,
- eine berechnete SVD über $AV = U\Sigma$ kontrollieren.

Beispiel (10.19): SVD von Hand berechnen

Wir berechnen eine vollständige Singulärwertzerlegung der Matrix

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \in \mathbb{R}^{2 \times 3}.$$

Gesucht ist also

$$A = U\Sigma V^T$$

mit

$$U \in \mathbb{R}^{2 \times 2}, \quad \Sigma \in \mathbb{R}^{2 \times 3}, \quad V \in \mathbb{R}^{3 \times 3}.$$

Da die beiden Zeilen von A linear unabhängig sind, ist

$$r = \text{rank}(A) = 2.$$

Wir erwarten also zwei positive Singulärwerte und eine rechte Nullrichtung.

Schritt 1: Eigenvektoren von $A^T A$

Wir beginnen mit der symmetrischen Matrix

$$\begin{aligned} A^T A &= \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \\ &= \boxed{\begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 4 \end{pmatrix}}. \end{aligned}$$

Die Eigenwerte und Eigenvektoren lassen sich hier relativ leicht ablesen:

- Die dritte Koordinatenrichtung wird mit Faktor 4 skaliert.
- Bezüglich der ersten beiden Spalten erkennen wir (durch scharfes Hinsehen) die Richtungen $(1 \ 1 \ 0)^\top$ (zu $\lambda_2 = 2$) und $(1 \ -1 \ 0)^\top$ (zu $\lambda_3 = 0$).

Hinweis: Wenn Sie keine Augen haben (no offense), können Sie die Eigenwerte und Eigenvektoren von $A^\top A$ natürlich auch durch Berechnung des charakteristischen Polynoms und anschließende Lösung der Eigenwertgleichung bestimmen – das charakteristische Polynom von $A^\top A$ ergibt sich hier am leichtesten über die Laplaceentwicklung und ist

$$p(\lambda) = -\lambda(\lambda - 4)(\lambda - 2).$$



Damit erhalten wir die normierten Eigenvektoren

$$\vec{v}_1 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \quad \text{zu } \lambda_1 = 4, \quad \vec{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \quad \text{zu } \lambda_2 = 2,$$

sowie

$$\vec{v}_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} \quad \text{zu } \lambda_3 = 0.$$

Die drei Vektoren bilden eine Orthonormalbasis des $\mathbb{R}^3$ – sie werden die rechten Singulärvektoren von A .

Wir ordnen die Eigenwerte von $A^\top A$ absteigend:

$$\lambda_1 = 4 \geq \lambda_2 = 2 > \lambda_3 = 0.$$

Wichtig: Die zugehörigen Eigenvektoren wählen wir **in genau dieser Reihenfolge** als Spalten von V . Nur so passen später die Spalten von U , die Diagonaleinträge von Σ und die Spalten von V zusammen.

Schritt 2: Singulärwerte und rechte Singulärvektoren

Die Singulärwerte sind die Quadratwurzeln der positiven Eigenwerte:

$$\sigma_1 = \sqrt{4} = 2, \quad \sigma_2 = \sqrt{2}.$$

Aus den geordneten, normierten Eigenvektoren bauen wir

$$V = \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ 1 & 0 & 0 \end{pmatrix}.$$

Die dritte Spalte $\vec{v}_3$ gehört zum Eigenwert 0 von $A^\top A$. Da A und $A^\top A$ denselben Nullraum haben (haben wir im Beweis von Theorem 7 gezeigt), gilt $A\vec{v}_3 = \vec{0}$. Falls Sie mir das nicht glauben, können wir es auch noch einmal nachrechnen:

$$A\vec{v}_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = \vec{0}.$$

Der Vektor $\vec{v}_3$ beschreibt also die Eingaberichtung, die von A vollständig gelöscht wird.

Schritt 3: Linke Singulärvektoren

Für die linken Singulärvektoren $\vec{u}_1$ und $\vec{u}_2$ muss $A\vec{v}_i = \sigma_i \vec{u}_i$ gelten. Wir können also die $\vec{u}_i$ durch

$$\vec{u}_i = \frac{A\vec{v}_i}{\sigma_i}$$

berechnen.

Wichtig: Diese Vektoren haben automatisch Länge 1, denn ist $\vec{v}_i$ ein normierter Eigenvektor von $A^\top A$ zum Eigenwert $\lambda_i = \sigma_i^2$, so gilt

$$\|A\vec{v}_i\|^2 = \vec{v}_i^\top A^\top A \vec{v}_i = \lambda_i = \sigma_i^2.$$

Also besitzt $A\vec{v}_i$ die Länge σ_i ; die Division durch σ_i normiert den Vektor. Für $\vec{v}_1$ erhalten wir

$$A\vec{v}_1 = A \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \quad \vec{u}_1 = \frac{1}{2} \begin{pmatrix} 0 \\ 2 \end{pmatrix} = \boxed{\begin{pmatrix} 0 \\ 1 \end{pmatrix}},$$

für $\vec{v}_2$ ergibt sich

$$A\vec{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix},$$

also

$$\vec{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix} = \boxed{\begin{pmatrix} 1 \\ 0 \end{pmatrix}}.$$

Die beiden Vektoren sind bereits eine Orthonormalbasis des $\mathbb{R}^2$. Somit ist

$$\mathbf{U} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Schritt 4: Die Faktoren zusammensetzen

Da A zwei positive Singulärwerte besitzt und die Form 2×3 hat, ist

$$\Sigma = \begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix}.$$

Insgesamt erhalten wir

$$A = \underbrace{\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}}_U \underbrace{\begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix}}_\Sigma \underbrace{\begin{pmatrix} 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{pmatrix}}_{V^\top}.$$

Schritt 5: Die SVD kontrollieren

Zur Kontrolle könnten wir die drei Faktoren vollständig ausmultiplizieren. Schneller und übersichtlicher ist der Weg über

$$AV = U\Sigma.$$

Es gilt:

$$AV = (A\vec{v}_1 \mid A\vec{v}_2 \mid A\vec{v}_3) = \left(\begin{pmatrix} 0 \\ 2 \end{pmatrix} \mid \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix} \mid \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right),$$

und

$$U\Sigma = (\sigma_1 \vec{u}_1 \mid \sigma_2 \vec{u}_2 \mid \vec{0}) = \left(\begin{pmatrix} 0 \\ 2 \end{pmatrix} \mid \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix} \mid \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right).$$

Damit ist $AV = U\Sigma$ und folglich $A = U\Sigma V^\top$.

Mit derselben Vorgehensweise ergibt sich ein allgemeines Verfahren:

Algorithmus (10.20): SVD über $A^\top A$

1. Berechne $A^\top A$.
2. Bestimme die positiven Eigenwerte

$$\lambda_1 \geq \dots \geq \lambda_r > 0$$


und eine zugehörige orthonormale Menge von Eigenvektoren $\vec{v}_1, \dots, \vec{v}_r$.

3. Setze

$$\sigma_i = \sqrt{\lambda_i} \quad \text{und} \quad \vec{u}_i = \frac{A\vec{v}_i}{\sigma_i} \quad (i = 1, \dots, r).$$

4. Ergänze die gefundenen Singulärvektoren gegebenenfalls zu Orthonormalbasen $\{\vec{v}_1, \dots, \vec{v}_n\}$ und $\{\vec{u}_1, \dots, \vec{u}_m\}$.
5. Mit $U = (\vec{u}_1 \mid \dots \mid \vec{u}_m)$, $V = (\vec{v}_1 \mid \dots \mid \vec{v}_n)$ und einer passenden rechteckigen Diagonalmatrix Σ ist

$$A = U\Sigma V^\top.$$



Bemerkungen

Bemerkung (10.21): Numerische Berechnung der SVD

Für kleine Matrizen ist der Weg über $A^\top A$ hervorragend geeignet, weil er die Verbindung zum Spektralsatz sichtbar macht. Numerische Software berechnet eine SVD großer Matrizen jedoch nicht auf diesem direkten Weg. Die Bildung von $A^\top A$ kann Rundungsfehler verstärken und quadriert die Konditionszahl.

Bemerkung (10.22): Ergänzung zu Orthonormalbasen

Um die $\vec{v}_i$ zu einer ONB des Eingaberaums zu ergänzen, können wir beispielsweise das Gram-Schmidt-Verfahren verwenden. Wenn nicht klar ist, welche der Standardbasisvektoren bereits von den $\vec{v}_i$ aufgespannt werden, können wir auch einfach das Gram-Schmidt-Verfahren mit $\vec{v}_1, \dots, \vec{v}_r, \vec{e}_1, \dots, \vec{e}_n$ starten – die $\vec{e}_j$ werden dann im Verfahren auf $\vec{0}$ gesetzt, wenn sie bereits von den $\vec{v}_i$ aufgespannt werden. Analog können wir die $\vec{u}_i$ zu einer ONB des Ausgaberaums ergänzen.

Bemerkung (10.23): Typische Fehler bei der Handrechnung

- Eigenvektoren von $A^\top A$ müssen vor dem Einsetzen in V normiert werden.
- Eigenwerte, Singulärwerte und Singulärvektoren müssen in derselben Reihenfolge stehen.
- Nur für $\sigma_i > 0$ darf durch σ_i geteilt werden. Nullrichtungen werden stattdessen zu Orthonormalbasen ergänzt.
- Bei $\vec{u}_i = A\vec{v}_i/\sigma_i$ darf die Division durch den Singulärwert nicht vergessen werden.
- Prüfen Sie stets die Dimensionen von U , Σ und V .

Aufgabe (10.24): Vollständige SVD berechnen

Bestimmen Sie eine vollständige Singulärwertzerlegung der Matrix

$$B = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 1 \end{pmatrix}.$$

1. Berechnen Sie $B^T B$ und bestimmen Sie eine Orthonormalbasis aus Eigenvektoren.
2. Bestimmen Sie die Singulärwerte und die Matrix V .
3. Berechnen Sie die linken Singulärvektoren und setzen Sie U und Σ zusammen.
4. Kontrollieren Sie Ihre Zerlegung mit $BV = U\Sigma$.
5. Welche Eingaberichtung wird von B vollständig gelöscht?

5. Reduzierte SVD, Rang und fundamentale Unterräume**Lernziele (10.25)**

Nach diesem Abschnitt können Sie...

- vollständige und reduzierte SVD unterscheiden,
- den Rang einer Matrix an ihren positiven Singulärwerten ablesen,
- Bild, Zeilenraum und beide Nullräume mithilfe der Singulärvektoren beschreiben und
- erklären, weshalb die reduzierte SVD dieselbe Matrix mit weniger Daten darstellt.

5.1. Welche Spalten tragen tatsächlich zu A bei?

Ist $r = \text{rank}(A)$, dann besitzt Σ genau r positive Diagonaleinträge. In der vollständigen SVD

$$A = U\Sigma V^T$$

werden deshalb alle Spalten $\vec{u}_{r+1}, \dots, \vec{u}_m$ und $\vec{v}_{r+1}, \dots, \vec{v}_n$ mit Nullen in Σ kombiniert. Sie sind wichtig, um U und V zu vollständigen orthogonalen Matrizen zu machen, tragen aber nichts zum Produkt A bei. Wir beschränken uns auf die wirksamen Teile:

$$U_r = (\vec{u}_1 \mid \dots \mid \vec{u}_r) \in \mathbb{R}^{m \times r}, \quad V_r = (\vec{v}_1 \mid \dots \mid \vec{v}_r) \in \mathbb{R}^{n \times r}$$

und


$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}.$$

Definition (10.26): Reduzierte Singulärwertzerlegung

Für $A \in \mathbb{R}^{m \times n}$ mit Rang r heißt

$$A = U_r \Sigma_r V_r^\top$$

die **reduzierte SVD** oder **ökonomische SVD** von A . Dabei besitzen U_r und V_r orthogonale Spalten und Σ_r enthält die r Singulärwerte.



Nur die r wirksamen Richtungen bleiben übrig.

5.2. Die vier fundamentalen Unterräume

Aus früheren Kapiteln kennen wir die vier fundamentalen Unterräume einer Matrix. Die SVD liefert für jeden von ihnen unmittelbar eine besonders schöne Orthonormalbasis.

Theorem 31: Fundamentale Unterräume aus der SVD

Sei $A \in \mathbb{R}^{m \times n}$ von Rang r mit SVD $A = U \Sigma V^\top$. Dann gilt:

$$\begin{aligned} \text{Bild}(A) &= \text{span}(\{\vec{u}_1, \dots, \vec{u}_r\}), \\ \mathcal{N}(A^\top) &= \text{span}(\{\vec{u}_{r+1}, \dots, \vec{u}_m\}), \\ \text{Bild}(A^\top) &= \text{span}(\{\vec{v}_1, \dots, \vec{v}_r\}), \\ \mathcal{N}(A) &= \text{span}(\{\vec{v}_{r+1}, \dots, \vec{v}_n\}). \end{aligned}$$


Die Aussagen lassen sich direkt aus der Geometrie lesen:

- Die Vektoren $\vec{u}_1, \dots, \vec{u}_r$ sind genau die erreichbaren Ausgaberrichtungen.
- Die Vektoren $\vec{v}_{r+1}, \dots, \vec{v}_n$ sind genau die Eingaberichtungen, die auf $\vec{0}$ abgebildet werden.
- Die übrigen beiden Räume sind die jeweils orthogonalen Ergänzungen.

Um zu verstehen, dass $\text{Bild}(A^\top) = \text{span}(\{\vec{v}_1, \dots, \vec{v}_r\})$ gilt, transponieren wir die SVD:

$$A^\top = V \Sigma^\top U^\top.$$

Also ist jede Spalte von $A^\top$ (d.h. jede Zeile von A) eine Linearkombination der Spalten von V : die i -te Spalte von $A^\top$ ist die Linearkombination der ersten r Spalten von V mit den Koeffizienten aus der i -ten Spalte von $\Sigma^\top U^\top$.



Weil U und V orthogonal sind, zerfallen Eingabe- und Ausgaberaum jeweils in zwei senkrecht aufeinander stehende Teile:

$$\mathbb{R}^n = \text{Bild}(A^\top) \oplus \mathcal{N}(A), \quad \mathbb{R}^m = \text{Bild}(A) \oplus \mathcal{N}(A^\top).$$

Das Symbol $\oplus$ bedeutet hier „orthogonale Direktsumme“: Jeder Vektor im Raum lässt sich eindeutig als Summe eines Vektors aus dem einen Teilraum und eines Vektors aus dem anderen Teilraum schreiben, und die beiden Teile stehen senkrecht aufeinander. Die SVD zerlegt also Eingabe- und Ausgaberaum vollständig in wirksame und unwirksame Richtungen.

Beispiel (10.27): Reduzierte SVD und Unterräume des Beispiels

Für die Matrix

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

aus Abschnitt 4 gilt $r = 2$. Die reduzierte SVD lautet

$$A = U_2 \Sigma_2 V_2^\top$$

mit

$$U_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \Sigma_2 = \begin{pmatrix} 2 & 0 \\ 0 & \sqrt{2} \end{pmatrix}, \quad V_2 = \begin{pmatrix} 0 & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} \\ 1 & 0 \end{pmatrix}.$$

Da $r = m = 2$, ist $\text{Bild}(A) = \mathbb{R}^2$ und $\mathcal{N}(A^\top) = \{\vec{0}\}$. Im Eingaberaum gilt

$$\mathcal{N}(A) = \text{span} \left(\left\{ \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} \right\} \right).$$

Die reduzierte SVD verzichtet auf diese Nullrichtung.

Aufgabe (10.28): Aktivierung: Unterräume aus Singulärvektoren ablesen

Eine Matrix $B \in \mathbb{R}^{4 \times 3}$ habe Rang 2 und eine SVD mit

$$U = (\vec{u}_1 \mid \vec{u}_2 \mid \vec{u}_3 \mid \vec{u}_4), \quad V = (\vec{v}_1 \mid \vec{v}_2 \mid \vec{v}_3).$$

1. Geben Sie Orthonormalbasen für $\text{Bild}(B)$, $\mathcal{N}(B^\top)$, $\text{Bild}(B^\top)$ und $\mathcal{N}(B)$ an.
2. Welche Dimension besitzt jeder der vier Unterräume?
3. Geben Sie die Dimensionen der drei Faktoren der reduzierten Singulärwertzerlegung $B = U_2 \Sigma_2 V_2^\top$ an.

6. Rang-1-Zerlegung und beste Rang-k-Approximation

Lernziele (10.29)

Nach diesem Abschnitt können Sie...

- eine Matrix mithilfe ihrer SVD als Summe von Rang-1-Matrizen darstellen,
- die Frobeniusnorm als Gesamtfehler aller Matrixeinträge interpretieren,
- eine abgeschnittene SVD A_k bilden und
- mit Eckart–Young optimale Rang-k-Approximationen bestimmen.

6.1. Die SVD als Summe einfacher Muster

Aus der reduzierten SVD

$$A = U_r \Sigma_r V_r^\top$$

erhalten wir durch Ausmultiplizieren als „Spalte mal Zeile“

$$A = \sigma_1 \vec{u}_1 \vec{v}_1^\top + \cdots + \sigma_r \vec{u}_r \vec{v}_r^\top = \sum_{i=1}^r \sigma_i \vec{u}_i \vec{v}_i^\top.$$

Jede Matrix $\vec{u}_i \vec{v}_i^\top$ besitzt Rang 1: Alle ihre Spalten sind Vielfache von $\vec{u}_i$. Wir können A daher als Summe von r einfachen Rang-1-Mustern lesen. Der Singulärwert σ_i gewichtet, wie stark das jeweilige Muster zur Matrix A beiträgt.

$$\begin{array}{|c|} \hline A \\ \hline \end{array} = \begin{array}{|c|} \hline \sigma_1 \vec{u}_1 \vec{v}_1^\top \\ \hline \text{wichtigstes} \\ \text{Muster} \\ \hline \end{array} + \begin{array}{|c|} \hline \sigma_2 \vec{u}_2 \vec{v}_2^\top \\ \hline \text{zweites} \\ \text{Muster} \\ \hline \end{array} + \cdots + \begin{array}{|c|} \hline \sigma_r \vec{u}_r \vec{v}_r^\top \\ \hline \text{schwächstes} \\ \text{Muster} \\ \hline \end{array}$$

6.2. Frobeniusnorm: Ein Maß für den Approximationsfehler

In der Praxis machen große Matrizen ständig Probleme: Sie benötigen viel Speicherplatz, und Operationen wie Matrixmultiplikation sind kaum noch durchführbar. Hat eine Matrix A aber nur wenige große Singulärwerte, so können wir, indem wir nur die zugehörigen Rang-1-Muster behalten und die restlichen verwerfen, eine deutlich kleinere Matrix konstruieren, die (hoffentlich) sehr viel von der Struktur und den Informationen von A erhält. Wenn wir die Rang-1-Muster von genau k Singulärwerten behalten, nennen wir dies eine **Rang- k -Approximation** von A . Um einschätzen zu können, wie gut eine solche Approximation ist, benötigen wir aber erst einmal ein Maß für den Fehler einer Näherung B von A . Es gibt viele Möglichkeiten, einen solchen Fehler zu messen – die gebräuchlichste ist die sogenannte **Frobeniusnorm**.

Definition (10.30): Frobeniusnorm

Für $A = (a_{ij}) \in \mathbb{R}^{m \times n}$ heißt

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}$$

die **Frobeniusnorm** von A . Sie entspricht der euklidischen Länge, wenn wir alle mn Matrixeinträge hintereinander als einen langen Vektor auffassen.

Für eine Näherung B misst

$$\|A - B\|_F$$

also den gesamten quadratischen Unterschied aller Einträge. Bei Bildern ist dies beispielsweise der Gesamtfehler aller Pixelwerte.

Beispiel (10.31): Frobeniusnorm unserer Beispielmatrix

Für unsere Beispielmatrix

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

ergibt sich

$$\|A\|_F = \sqrt{1^2 + 1^2 + 0^2 + 0^2 + 0^2 + 2^2} = \sqrt{6}.$$

Aufgabe (10.32): Frobeniusnorm von Σ

Zu unserer Beispielmatrix gehört

$$\Sigma = \begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix}.$$

Berechnen Sie $\|\Sigma\|_F$. Was fällt Ihnen auf?

Da orthogonale Matrizen Längen erhalten, verändern sie die Frobeniusnorm nicht. Deshalb können wir die Norm einer Matrix $A = U\Sigma V^T$ direkt an ihren Singulärwerten ablesen:

$$\|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}.$$

Die Größe σ_i^2 beschreibt somit den Anteil des i -ten Rang-1-Musters an der quadrierten Frobeniusnorm.

6.3. Die abgeschnittene SVD

Probieren wir unsere Idee von vorhin einmal aus: Wir behalten nur die ersten k wichtigsten Muster und verwerfen die restlichen. Dies nennen wir die **abgeschnittene SVD** von A .

Definition (10.33): Abgeschnittene SVD

Für $k \leq r$ heißt

$$A_k = \sum_{i=1}^k \sigma_i \vec{u}_i \vec{v}_i^T = U_k \Sigma_k V_k^T$$

die **abgeschnittene SVD** oder **Rang- k -Approximation** von A .

Weil A_k eine Summe von k Rang-1-Matrizen ist, gilt

$$\text{rank}(A_k) \leq k.$$

und, da jedes der Rang-1-Muster eine neue, linear unabhängige Richtung beiträgt, gilt sogar $\text{rank}(A_k) = k$. Die abgeschnittene SVD ist also tatsächlich eine Rang- k -Approximation

von A . Dann ist der verworfene Anteil von A

$$A - A_k = \sum_{i=k+1}^r \sigma_i \vec{u}_i \vec{v}_i^\top,$$

und sein Frobeniusfehler beträgt

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

6.4. Eckart–Young: Abschneiden ist optimal

Vielleicht gäbe es eine bessere Rang- k -Matrix als A_k , um A optimal zu approximieren? Der Satz von Eckart–Young sagt: bezüglich der Frobeniusnorm gibt es keine.

Theorem 32: Eckart–Young für die Frobeniusnorm

Sei $A \in \mathbb{R}^{m \times n}$ und sei A_k ihre abgeschnittene SVD, $k \leq \text{rank}(A)$. Dann gilt für jede Matrix $B \in \mathbb{R}^{m \times n}$ mit $\text{rank}(B) \leq k$:

$$\|A - B\|_F \geq \|A - A_k\|_F.$$

Der kleinstmögliche Approximationsfehler ist also

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

Die Aussage ist bemerkenswert: Wir müssen nicht für jede Matrix A individuell nach der besten Rang- k -Approximation suchen, sondern können einfach die abgeschnittene SVD bilden. Dies ist die Grundlage für viele Anwendungen der SVD, insbesondere in der Bild- und Datenkompression.

Beispiel (10.34): Fehler einer Rang-2-Approximation

Eine Matrix A habe die Singulärwerte

$$\sigma_1 = 10, \quad \sigma_2 = 4, \quad \sigma_3 = 2, \quad \sigma_4 = 1.$$

Dann ist A_2 die beste Rang-2-Approximation bezüglich der Frobeniusnorm. Ihr Fehler beträgt

$$\|A - A_2\|_F = \sqrt{\sigma_3^2 + \sigma_4^2} = \sqrt{2^2 + 1^2} = \sqrt{5}.$$

Zum Vergleich ist

$$\|A\|_F = \sqrt{10^2 + 4^2 + 2^2 + 1^2} = 11.$$

Mit nur zwei Rang-1-Mustern bleibt also bereits der größte Teil der Informationen erhalten.

Aufgabe (10.35): Aktivierung: Welche Rang-k-Approximation reicht?

Eine Datenmatrix besitze die Singulärwerte

$$12, \quad 5, \quad 3, \quad 1.$$

1. Berechnen Sie $\|A\|_F$.
2. Bestimmen Sie die Fehler $\|A - A_1\|_F$, $\|A - A_2\|_F$ und $\|A - A_3\|_F$.
3. Welches kleinste k garantiert einen Frobeniusfehler von höchstens 3,5?
4. Erklären Sie, weshalb keine andere Rang- k -Matrix einen kleineren Frobeniusfehler als A_k besitzen kann.

7. Bild- und Datenkompression**Lernziele (10.36)**

Nach diesem Abschnitt können Sie...

- ein Graustufenbild als Matrix interpretieren,
- den Speicherbedarf einer Rang- k -Darstellung berechnen, und
- den Zusammenhang zwischen Singulärwerten, Kompressionsrate und Bildqualität erklären.

7.1. Bildkompression mit der SVD

Ein Graustufenbild mit m Pixelzeilen und n Pixelspalten lässt sich als Matrix

$$A = (a_{ij}) \in \mathbb{R}^{m \times n}$$

darstellen. Der Eintrag a_{ij} beschreibt die Helligkeit des Pixels in Zeile i und Spalte j . Um das Bild exakt zu speichern, benötigen wir daher mn Zahlen.

Natürliche Bilder besitzen jedoch viel Redundanz: Benachbarte Pixel ähneln sich, Flächen haben ähnliche Helligkeiten und Kanten setzen sich über viele Pixel fort. Deshalb kann eine Rang- k -Approximation

$$A_k = U_k \Sigma_k V_k^T$$

häufig bereits einen großen Teil der sichtbaren Struktur bewahren.

Abbildung 10.3 zeigt die typische Wirkung:

- Für sehr kleines k bleiben nur grobe horizontale und vertikale Muster.
- Zusätzliche Rang-1-Komponenten ergänzen Kanten, Rundungen und feinere Details.




Abbildung 10.3. Ein synthetisches Graustufenbild und seine abgeschnittenen SVDs. Mit wachsendem k kommen feinere Strukturen zurück; der relative Fehler ist $\|A - A_k\|_F / \|A\|_F$.

- Kleine Singulärwerte beeinflussen das Bild nur schwach und können verworfen werden.

Wann spart die Darstellung wirklich Speicher?

Die Originalmatrix benötigt mn Zahlen. Für die reduzierte Rang- k -Darstellung speichern wir

$$U_k \in \mathbb{R}^{m \times k}, \quad \Sigma_k \in \mathbb{R}^{k \times k}, \quad V_k^T \in \mathbb{R}^{k \times n}.$$

Da Σ_k diagonal ist, genügen ihre k Diagonaleinträge. Insgesamt benötigen wir daher

$$\boxed{k(m + n + 1) \text{ Zahlen}}$$

statt mn Zahlen.

Beispiel (10.37): Speicherbedarf des Beispieldbildes

Das Bild aus Abbildung 10.3 besitzt 180×180 Pixel, also

$$180 \cdot 180 = 32\,400$$

Pixelwerte. Als Matrix hat es höchstens Rang

$$\min(180, 180) = 180.$$

Eine Rang-20-Approximation reduziert den Rang also von höchstens 180 auf 20. Für $k = 20$ benötigt die SVD-Darstellung nur

$$20(180 + 180 + 1) = 7\,220$$

Zahlen, also ungefähr 22,3% der ursprünglichen Anzahl. Kompression erhalten wir genau dann, wenn

$$k(m + n + 1) < mn.$$

Für zu großes k kann die faktorierte Darstellung sogar mehr Speicher benötigen als die Originalmatrix.

7.2. Singulärwerte helfen bei der Wahl von k

Nach Eckart–Young beträgt der optimale Frobeniusfehler

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

Fallen die Singulärwerte schnell ab, kann ein kleines k bereits eine gute Approximation liefern. Fallen sie langsam ab, müssen wir mehr Komponenten speichern.




Abbildung 10.4. Singulärwerte des synthetischen Beispielbildes. Die orangefarbenen Linien markieren die in Abbildung 10.3 verwendeten Werte von k .

Eine mögliche Kennzahl ist der Anteil der erhaltenen quadrierten Frobeniusnorm:

$$\text{erhaltener Anteil} = \frac{\sigma_1^2 + \dots + \sigma_k^2}{\sigma_1^2 + \dots + \sigma_r^2}.$$

Je näher dieser Anteil an 1 liegt, desto kleiner ist der relative Frobeniusfehler. Ob der sichtbare Qualitätsverlust akzeptabel ist, hängt dennoch von der Anwendung ab.

Bemerkung (10.38): Farbbilder und allgemeine Datenkompression

Ein Farbbild kann als drei Matrizen für Rot, Grün und Blau behandelt werden; jede Farbmatrix wird separat komprimiert. Dasselbe Prinzip funktioniert allgemeiner für Datenmatrizen: Wir speichern nur die wichtigsten Singulärrichtungen und erhalten eine niedrigdimensionale Beschreibung der Daten. Diese Idee greifen wir im nächsten Abschnitt auf.

Aufgabe (10.39): Kompressionsrate und Qualität

Ein Graustufenbild besitzt 600×400 Pixel.

1. Wie viele Zahlen benötigt die Originalmatrix?
2. Wie viele Zahlen benötigt eine Rang-25-Darstellung?
3. Welchem prozentualen Anteil der ursprünglichen Anzahl entspricht dies?
4. Das Bild habe Rang 300 und Singulärwerte $\sigma_1, \dots, \sigma_{300}$. Formulieren Sie den relativen Frobeniusfehler der Rang-25-Approximation.

8. Anwendungen der SVD**Lernziele (10.40)**

Nach diesem Abschnitt können Sie...

- erklären, wie PCA, Kompression und Matrix Completion auf niedrigrangigen Strukturen beruhen,
- die Rolle der Nuklearnorm als messbare Ersatzgröße für niedrigen Rang beschreiben und
- typische SVD-Anwendungen anhand weniger Stichpunkte wiedererkennen.

Die SVD ist mehr als ein Rechenverfahren für einzelne Matrizen. Sie ist die Antwort auf die Frage:

Welche wenigen orthogonalen Richtungen erklären den größten Teil der Daten?

Wenn eine Matrix nur wenige große Singulärwerte besitzt, steckt ihre wesentliche Information in wenigen Rang-1-Mustern – das lässt sich für viele Anwendungen nutzen.

PCA: Richtungen größter Streuung finden

Die **Hauptkomponentenanalyse** (**Principal Component Analysis**, kurz **PCA**) sucht die Richtungen, entlang derer eine Datenwolke am stärksten streut. In Kapitel 7 haben wir das Beispiel *Genes mirror geography within Europe* kennengelernt: Novembre et al. betrachteten genetische Daten von etwa 3000 Europäerinnen und Europäern mit über einer halben Million DNA-Merkmalen und projizierten sie auf zwei Hauptkomponenten. In dieser zweidimensionalen Darstellung spiegelte die genetische Datenwolke überraschend gut die Geographie Europas wider.

Jetzt können wir sagen, was linear-algebraisch dahinter passiert. Man bildet eine zentrierte Datenmatrix A , berechnet eine SVD

$$A = U\Sigma V^T$$

und behält nur die beiden rechten Singulärrichtungen $\vec{v}_1, \vec{v}_2$ zu den größten Singulärwerten. Die neuen zweidimensionalen Koordinaten sind

$$\boxed{Z_2 = AV_2 = U_2 \Sigma_2.}$$

PCA ist in dieser Sicht also eine abgeschnittene SVD einer Datenmatrix: Die ersten Singulärrichtungen sind die Achsen, auf denen die Daten am meisten variieren.

Bemerkung (10.41): Weiterführende Literatur zur PCA

- Novembre et al.: *Genes mirror geography within Europe*. Nature 456, 98–101 (2008). <https://doi.org/10.1038/nature07331>
- Deisenroth, Faisal und Ong: *Mathematics for Machine Learning*. Cambridge University Press (2020). Kapitel 10. <https://mml-book.github.io/book/mml-book.pdf>
- Jolliffe: *Principal Component Analysis*. 2. Auflage, Springer Series in Statistics, Springer (2002).

Matrix Completion: Das Netflix-Problem

Der Netflix-Preis ist ein von Netflix im Jahr 2006 ausgeschriebener Wettbewerb, dessen Ziel es war, Film-Ratings vorherzusagen. Dazu stellte Netflix eine unvollständige Bewertungsmatrix zur Verfügung. Die Zeilen stehen für Nutzerinnen und Nutzer, die Spalten für Filme, und ein Eintrag ist eine Bewertung. Die meisten Einträge fehlen allerdings, da niemand Zeit hat, alle Filme auf Netflix zu bewerten (nicht einmal verbeamtete Professoren). Trotzdem ist es für Netflix wichtig, die fehlenden Bewertungen vorherzusagen, um darüber bessere Empfehlungen geben zu können.



**Auf die
Klausur
vorbereiten**

**Netflix
bingen
(für die
Wissenschaft)**

Beispiel (10.42): Eine unvollständige Bewertungsmatrix

	Star Wars	Herr der Ringe	Birdman	Barbie	Crazy, Stupid Love
Person 1	5	5	1	2	?
Person 2	4	5	?	1	2
Person 3	1	2	5	4	5
Person 4	?	1	4	5	5
Person 5	5	?	2	?	1

Die Frage ist: *Wie können wir die fehlenden Werte gut vorhersagen?*

Die Sieger-Idee lautete: Geschmack wird oft durch wenige latente Faktoren erklärt, etwa Genre, Tempo, Humor, Alter des Films oder Vorliebe für bestimmte Schauspielerinnen und Schauspieler. Man sucht also eine Matrix X , die zu den beobachteten Bewertungen passt und zugleich möglichst niedrigen Rang besitzt. Direkt

$$\text{rank}(X) \text{ minimieren}$$

ist algorithmisch schwierig. Die **Nuklearnorm**

$$\|X\|_* = \sigma_1 + \dots + \sigma_r$$

ist die Summe der Singulärwerte und dient als gute Ersatzgröße: Kleine Nuklearnorm begünstigt wenige große Singulärwerte und damit niedrigrangige Lösungen. Eine ideale Matrix-Completion-Formulierung lautet daher schematisch:

$$\min \|X\|_* \quad \text{unter der Bedingung: } X_{ij} = R_{ij} \text{ für alle beobachteten Bewertungen.}$$

Die Singulärwertzerlegung kann uns also wissenschaftlich begründen, dass Fans von *New Kids* wahrscheinlich auch auf *Sharknado* stehen werden – hilfreich, oder?

Bemerkung (10.43): Weiterführende Literatur zu Matrix Completion

- Candès und Recht: *Exact Matrix Completion via Convex Optimization*. Foundations of Computational Mathematics 9, 717–772 (2009). <https://doi.org/10.1007/s10208-009-9045-5>
- Candès und Tao: *The Power of Convex Relaxation: Near-Optimal Matrix Completion*. IEEE Transactions on Information Theory 56(5), 2053–2080 (2010). <https://doi.org/10.1109/TIT.2010.2044061>

Weitere Anwendungen

- **Textanalyse und semantische Suche:** Eine Term-Dokument-Matrix wird durch eine abgeschnittene SVD in wenige latente Themenrichtungen zerlegt; dies ist die Grundidee der Latent Semantic Analysis. Weiterführend: Deerwester et al.: *Indexing by Latent Semantic Analysis*. Journal of the American Society for Information Science 41(6), 391–407 (1990). DOI
- **Entrauschen:** Wenn ein Signal niedrigrangig ist und Rauschen viele kleine Singulärrichtungen erzeugt, kann man kleine Singulärwerte abschneiden oder gezielt schrumpfen. Weiterführend: Gavish und Donoho: *Optimal Shrinkage of Singular Values*. IEEE Transactions on Information Theory 63(4), 2137–2152 (2017). DOI
- **Modellkompression in neuronalen Netzen:** Große Gewichtsmatrizen oder Faltungskerne werden durch niedrigrangige Faktoren approximiert, um Parameter und Rechenzeit zu sparen. Weiterführend: Denton et al.: *Exploiting Linear Structure Within Convolutional Networks for Efficient Evaluation*. Advances in Neural Information Processing Systems 27, 1269–1277 (2014). DOI

- **Pseudoinverse und kleinste Quadrate:** Mit der SVD invertieren wir nur Richtungen mit positivem Singulärwert; Nullrichtungen bleiben kontrolliert. So liefert die Moore–Penrose-Pseudoinverse die Least-Squares-Lösung mit kleinster Norm. Weiterführend: Golub und Reinsch: *Singular Value Decomposition and Least Squares Solutions*. Numerische Mathematik 14, 403–420 (1970). DOI
- **Gesichtserkennung und Eigenfaces:** Bilder von Gesichtern werden als hochdimensionale Vektoren betrachtet und in einen niedrigdimensionalen Unterraum projiziert. Weiterführend: Turk und Pentland: *Eigenfaces for Recognition*. Journal of Cognitive Neuroscience 3(1), 71–86 (1991). DOI
- **Schnelle Approximation riesiger Matrizen:** Randomisierte SVD-Verfahren suchen zuerst einen kleinen Unterraum, der die Wirkung der Matrix gut einfängt, und berechnen dort eine günstige Approximation. Weiterführend: Halko, Martinsson und Tropp: *Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions*. SIAM Review 53(2), 217–288 (2011). DOI

Wiederholung (10.44): Singulärwertzerlegung

- Jede reelle Matrix besitzt eine SVD $A = U\Sigma V^\top$.
- Die Singulärwerte sind die Quadratwurzeln der positiven Eigenwerte von $A^\top A$ und $AA^\top$.
- Die reduzierte SVD enthält genau die wirksamen Richtungen und macht Rang sowie fundamentale Unterräume sichtbar.
- Abschneiden nach k Komponenten ergibt eine beste Rang- k -Approximation.
- PCA, Bildkompression, Matrix Completion, Textanalyse, Pseudoinverse/Least Squares und Modellkompression nutzen dieselbe Grundidee: wenige große Singulärwerte beschreiben die Hauptstruktur.

A. Lösungen zu den Aktivierungsaufgaben**Lösung zu Aufgabe (10.4) (Warum brauchen wir zwei Basen?)**

- (1) Die Matrix $A \in \mathbb{R}^{2 \times 3}$ bildet den Eingaberaum $\mathbb{R}^3$ in den Ausgaberaum $\mathbb{R}^2$ ab.
 (2) Alle drei Vektoren haben Länge 1. Außerdem gilt

$$\vec{v}_1^\top \vec{v}_2 = \vec{v}_1^\top \vec{v}_3 = 0, \quad \vec{v}_2^\top \vec{v}_3 = \frac{1}{2}(1 - 1) = 0.$$

Damit bilden sie eine Orthonormalbasis des $\mathbb{R}^3$.

- (3) Es gilt

$$A\vec{v}_1 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}, \quad A\vec{v}_2 = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix}, \quad A\vec{v}_3 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Somit wird $\vec{v}_1$ um den Faktor 2 und $\vec{v}_2$ um den Faktor $\sqrt{2}$ skaliert. Die Richtung $\vec{v}_3$ wird vollständig gelöscht.

(4) Die Eingaberichtungen liegen im $\mathbb{R}^3$, ihre Bilder im $\mathbb{R}^2$. Deshalb benötigen wir rechte Singulärvektoren als Basis des Eingaberaums und linke Singulärvektoren als Basis des Ausgaberaums.

Lösung zu Aufgabe (10.11) (Geometrische Interpretation)

- Die rechten Singulärvektoren liegen im Eingaberaum $\mathbb{R}^2$, die linken im Ausgaberaum $\mathbb{R}^3$.
- Der Einheitskreis wird auf eine Ellipse in der Ebene $\text{span}(\vec{u}_1, \vec{u}_2)$ abgebildet. Ihre Halbachsen zeigen in Richtung $\vec{u}_1$ und $\vec{u}_2$ und haben Längen 5 beziehungsweise 2.
- Da genau zwei Singulärwerte positiv sind, gilt $\text{Rang}(A) = 2$.
- Es gilt

$$A\vec{v}_1 = 5\vec{u}_1, \quad A\vec{v}_2 = 2\vec{u}_2.$$

- Die dritte Spalte $\vec{u}_3$ ergänzt $\vec{u}_1, \vec{u}_2$ zu einer Orthonormalbasis des $\mathbb{R}^3$. Da ihr kein positiver Singulärwert zugeordnet ist, trägt sie nicht zum Bild von A bei.

Lösung zu Aufgabe (10.17) (Gram-Matrizen)

- (1) Direkte Multiplikation ergibt

$$A^\top A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 4 \end{pmatrix}, \quad AA^\top = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}.$$

- (2) Der obere linke 2×2 -Block von $A^\top A$ besitzt die Eigenwerte 2 und 0. Daher sind

$$\text{Eigenwerte}(A^\top A) = \{4, 2, 0\}, \quad \text{Eigenwerte}(AA^\top) = \{4, 2\}.$$

(3) Die positiven Eigenwerte stimmen überein. Somit lauten die positiven Singulärwerte

$$\sigma_1 = 2, \quad \sigma_2 = \sqrt{2}.$$

(4) Die größere Matrix $A^\top A \in \mathbb{R}^{3 \times 3}$ besitzt den zusätzlichen Eigenwert 0. Beide Gram-Matrizen haben Rang 2, aber $A^\top A$ wirkt auf einem dreidimensionalen Raum.

Lösung zu Aufgabe (10.24) (Vollständige SVD)

Zunächst gilt

$$B^\top B = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix}.$$

Eine nach absteigenden Eigenwerten geordnete Orthonormalbasis ist

$$\vec{v}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \vec{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \quad \vec{v}_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

Die zugehörigen Eigenwerte sind 4, 2 und 0. Daher

$$\sigma_1 = 2, \quad \sigma_2 = \sqrt{2}, \quad V = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}.$$

Für die linken Singulärvektoren erhalten wir

$$\vec{u}_1 = \frac{B\vec{v}_1}{2} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \vec{u}_2 = \frac{B\vec{v}_2}{\sqrt{2}} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Somit ist eine vollständige SVD gegeben durch

$$B = \underbrace{\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}}_U \underbrace{\begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix}}_\Sigma V^\top.$$

Tatsächlich gilt

$$BV = \begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{pmatrix} = U\Sigma.$$

Die vollständig gelöschte Eingaberichtung ist $\vec{v}_3$.

Lösung zu Aufgabe (10.28) (Fundamentale Unterräume)

Da $\text{Rang}(\mathbf{B}) = 2$, gelten

$$\begin{aligned}\text{Bild}(\mathbf{B}) &= \text{span}(\vec{\mathbf{u}}_1, \vec{\mathbf{u}}_2), & \mathcal{N}(\mathbf{B}^\top) &= \text{span}(\vec{\mathbf{u}}_3, \vec{\mathbf{u}}_4), \\ \text{Bild}(\mathbf{B}^\top) &= \text{span}(\vec{\mathbf{v}}_1, \vec{\mathbf{v}}_2), & \mathcal{N}(\mathbf{B}) &= \text{span}(\vec{\mathbf{v}}_3).\end{aligned}$$

Die Dimensionen lauten entsprechend 2, 2, 2 und 1. Für die reduzierte SVD

$$\mathbf{B} = \mathbf{U}_2 \Sigma_2 \mathbf{V}_2^\top$$

haben die Faktoren die Dimensionen

$$\mathbf{U}_2 \in \mathbb{R}^{4 \times 2}, \quad \Sigma_2 \in \mathbb{R}^{2 \times 2}, \quad \mathbf{V}_2^\top \in \mathbb{R}^{2 \times 3}.$$

Lösung zu Aufgabe (10.32) (Frobeniusnorm von Σ)

Es gilt

$$\|\Sigma\|_F = \sqrt{2^2 + (\sqrt{2})^2} = \sqrt{6}.$$

Das ist genau derselbe Wert wie für unsere Beispielmatrix $\mathbf{A}$:

$$\|\mathbf{A}\|_F = \|\Sigma\|_F.$$

Die SVD schreibt $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^\top$. Die orthogonalen Matrizen $\mathbf{U}$ und $\mathbf{V}^\top$ ändern Längen nicht; deshalb bleibt die Frobeniusnorm beim Übergang von $\mathbf{A}$ zu Σ erhalten.

Lösung zu Aufgabe (10.35) (Rang-k-Approximation)

Aus den Singulärwerten folgt

$$\|\mathbf{A}\|_F = \sqrt{12^2 + 5^2 + 3^2 + 1^2} = \sqrt{179}.$$

Die Fehler der abgeschnittenen SVDs sind

$$\|\mathbf{A} - \mathbf{A}_1\|_F = \sqrt{5^2 + 3^2 + 1^2} = \sqrt{35},$$

$$\|\mathbf{A} - \mathbf{A}_2\|_F = \sqrt{3^2 + 1^2} = \sqrt{10},$$

$$\|\mathbf{A} - \mathbf{A}_3\|_F = 1.$$

Da $\sqrt{10} \leq 3,5$, aber $\sqrt{35} > 3,5$, ist das kleinste mögliche k gleich 2. Nach dem Satz von Eckart–Young ist $\mathbf{A}_k$ unter allen Matrizen vom Rang höchstens k optimal bezüglich der Frobeniusnorm.

Lösung zu Aufgabe (10.39) (Kompressionsrate und Qualität)

Die Originalmatrix benötigt

$$600 \cdot 400 = 240\,000$$

Zahlen. Eine Rang-25-Darstellung benötigt

$$25(600 + 400 + 1) = 25\,025$$

Zahlen. Dies entspricht

$$\frac{25\,025}{240\,000} \cdot 100\% \approx 10,43\%.$$

Der relative Frobeniusfehler lautet

$$\frac{\|\mathbf{A} - \mathbf{A}_{25}\|_{\text{F}}}{\|\mathbf{A}\|_{\text{F}}} = \sqrt{\frac{\sigma_{26}^2 + \dots + \sigma_{300}^2}{\sigma_1^2 + \dots + \sigma_{300}^2}}.$$

B. Beweise zu ausgewählten Sätzen

B.1. Technische Vorbereitungen

Lemma (10.45): Kern einer Gram-Matrix

Für jede Matrix $A \in \mathbb{R}^{m \times n}$ gilt

$$\mathcal{N}(A^\top A) = \mathcal{N}(A).$$

Insbesondere ist $\text{rank}(A^\top A) = \text{rank}(A)$.

Beweis von Lemma (10.45). Aus $A\vec{x} = \vec{0}$ folgt sofort $A^\top A\vec{x} = \vec{0}$. Umgekehrt gelte $A^\top A\vec{x} = \vec{0}$. Dann ist

$$0 = \vec{x}^\top A^\top A\vec{x} = \|A\vec{x}\|^2.$$

Also gilt $A\vec{x} = \vec{0}$. Damit stimmen die Kerne überein. Nach dem Rank-Nullity-Theorem (Theorem 5) folgt

$$\text{rank}(A^\top A) = n - \dim \mathcal{N}(A^\top A) = n - \dim \mathcal{N}(A) = \text{rank}(A). \quad \blacksquare$$

Lemma (10.46): Bilder positiver Eigenrichtungen

Seien $\vec{v}_1, \dots, \vec{v}_r$ orthonormale Eigenvektoren von $A^\top A$ zu positiven Eigenwerten

$$\lambda_i = \sigma_i^2 > 0.$$

Dann bilden die Vektoren

$$\vec{u}_i = \frac{A\vec{v}_i}{\sigma_i}, \quad i = 1, \dots, r,$$

eine orthonormale Menge im $\mathbb{R}^m$ und erfüllen

$$A\vec{v}_i = \sigma_i \vec{u}_i, \quad A^\top \vec{u}_i = \sigma_i \vec{v}_i.$$

Beweis von Lemma (10.46). Die erste Gleichung gilt nach Definition. Für $1 \leq i, j \leq r$ erhalten wir wegen $A^\top A\vec{v}_j = \sigma_j^2 \vec{v}_j$:

$$\begin{aligned} \vec{u}_i^\top \vec{u}_j &= \frac{1}{\sigma_i \sigma_j} \vec{v}_i^\top A^\top A \vec{v}_j \\ &= \frac{\sigma_j^2}{\sigma_i \sigma_j} \vec{v}_i^\top \vec{v}_j. \end{aligned}$$

Für $i \neq j$ ist dies 0, für $i = j$ ist es 1. Die Vektoren $\vec{u}_i$ sind also orthonormal. Außerdem gilt

$$A^\top \vec{u}_i = \frac{1}{\sigma_i} A^\top A \vec{v}_i = \frac{\sigma_i^2}{\sigma_i} \vec{v}_i = \sigma_i \vec{v}_i. \quad \blacksquare$$

Lemma (10.47): Ergänzung einer orthonormalen Menge

Jede orthonormale Menge $\vec{q}_1, \dots, \vec{q}_s$ im $\mathbb{R}^d$ lässt sich zu einer Orthonormalbasis

$$\vec{q}_1, \dots, \vec{q}_s, \vec{q}_{s+1}, \dots, \vec{q}_d$$

des $\mathbb{R}^d$ ergänzen.

Beweis von Lemma (10.47). Die Vektoren $\vec{q}_1, \dots, \vec{q}_s$ sind linear unabhängig. Nach dem Basisergänzungssatz können wir sie zu einer Basis des $\mathbb{R}^d$ ergänzen. Wenden wir das Gram–Schmidt-Verfahren auf diese Basis an, bleiben die bereits orthonormalen ersten s Vektoren unverändert und wir erhalten eine Orthonormalbasis des gesamten Raums. $\blacksquare$

B.2. Existenz der Singulärwertzerlegung

Beweis von Satz über die Singulärwertzerlegung. Sei $A \in \mathbb{R}^{m \times n}$ und $r = \text{rank}(A)$. Für $A = 0_{m \times n}$ ist die Aussage mit beliebigen orthogonalen Matrizen U, V und $\Sigma = 0$ erfüllt. Sei daher $r \geq 1$.

Die Matrix $A^\top A$ ist symmetrisch und positiv semidefinit. Nach dem Spektralsatz besitzt sie daher eine Orthonormalbasis aus Eigenvektoren. Wir ordnen diese so, dass

$$A^\top A \vec{v}_i = \lambda_i \vec{v}_i, \quad \lambda_1 \geq \dots \geq \lambda_r > 0,$$

und, falls $r < n$, zusätzlich $\lambda_{r+1} = \dots = \lambda_n = 0$ gilt. Dass genau r Eigenwerte positiv sind, folgt aus Lemma (10.45), denn $\dim \mathcal{N}(A^\top A) = \dim \mathcal{N}(A) = n - r$. Setze

$$\sigma_i = \sqrt{\lambda_i} \quad \text{und} \quad \vec{u}_i = \frac{A \vec{v}_i}{\sigma_i} \quad (i = 1, \dots, r).$$

Nach Lemma (10.46) sind $\vec{u}_1, \dots, \vec{u}_r$ orthonormal. Nach Lemma (10.47) lassen sie sich zu einer Orthonormalbasis ergänzen:

$$\vec{u}_1, \dots, \vec{u}_m$$

des $\mathbb{R}^m$. Definiere

$$U = (\vec{u}_1 \mid \dots \mid \vec{u}_m), \quad V = (\vec{v}_1 \mid \dots \mid \vec{v}_n)$$

und die rechteckige Diagonalmatrix $\Sigma \in \mathbb{R}^{m \times n}$ mit Diagonaleinträgen $\sigma_1, \dots, \sigma_r$ und sonst nur Nullen. Dann sind U und V orthogonal.

Für $i \leq r$ gilt $A\vec{v}_i = \sigma_i \vec{u}_i$. Für $i > r$ ist $\lambda_i = 0$, also liegt $\vec{v}_i$ nach Lemma (10.45) in $\mathcal{N}(A)$ und es gilt $A\vec{v}_i = \vec{0}$. Somit stimmen die Spalten von AV und $U\Sigma$ überein:

$$AV = (\sigma_1 \vec{u}_1 \mid \cdots \mid \sigma_r \vec{u}_r \mid \vec{0} \mid \cdots \mid \vec{0}) = U\Sigma.$$

Multiplikation von rechts mit $V^\top$ ergibt

$$A = U\Sigma V^\top. \quad \blacksquare$$

B.3. Folgerungen für Gram-Matrizen und fundamentale Unterräume

Beweis von Lemma (10.15). Aus der SVD $A = U\Sigma V^\top$ folgen

$$A^\top A = V\Sigma^\top \Sigma V^\top, \quad AA^\top = U\Sigma \Sigma^\top U^\top.$$

Die positiven Diagonaleinträge von $\Sigma^\top \Sigma$ und $\Sigma \Sigma^\top$ sind jeweils

$$\sigma_1^2, \dots, \sigma_r^2$$

mit denselben Vielfachheiten. Alle übrigen Eigenwerte sind 0. Damit besitzen $A^\top A$ und $AA^\top$ dieselben positiven Eigenwerte mit denselben Vielfachheiten. $\blacksquare$

Lemma (10.48): Fundamentale Unterräume aus der SVD

Für eine SVD $A = U\Sigma V^\top$ einer Rang- r -Matrix gilt

$$\begin{aligned} \text{Bild}(A) &= \text{span}(\vec{u}_1, \dots, \vec{u}_r), & \mathcal{N}(A^\top) &= \text{span}(\vec{u}_{r+1}, \dots, \vec{u}_m), \\ \text{Bild}(A^\top) &= \text{span}(\vec{v}_1, \dots, \vec{v}_r), & \mathcal{N}(A) &= \text{span}(\vec{v}_{r+1}, \dots, \vec{v}_n). \end{aligned}$$

Beweis von Lemma (10.48). Aus der Rang-1-Darstellung

$$A = \sum_{i=1}^r \sigma_i \vec{u}_i \vec{v}_i^\top$$

folgt zunächst $\text{Bild}(A) \subseteq \text{span}(\vec{u}_1, \dots, \vec{u}_r)$. Da $A\vec{v}_i = \sigma_i \vec{u}_i$ und $\sigma_i > 0$ gilt, liegt jeder Vektor $\vec{u}_i$ für $i \leq r$ im Bild von A . Damit gilt Gleichheit.

Analog folgt aus

$$A^\top = \sum_{i=1}^r \sigma_i \vec{v}_i \vec{u}_i^\top$$

die Aussage über $\text{Bild}(A^\top)$. Für $j > r$ gilt unmittelbar $A\vec{v}_j = \vec{0}$ und $A^\top \vec{u}_j = \vec{0}$. Die angegebenen orthonormalen Mengen besitzen wegen des Rank-Nullity-Theorems bereits die vollständigen Dimensionen der beiden Kerne und bilden daher deren Basen. $\blacksquare$