Machine Learning

Summary

Photo by Nick Fewings on Unsplash

What did we cover in this class?

- Supervised Learning
  - Regression
    - Linear Regression
    - Polynomial Regression
    - Lasso, Ridge, Elastic Net Regularization
    - Regression Trees
  - Classification
    - Knn-Classification
    - Bayes Classification (Optimal, Naïve)
    - Decision Tree Classification (in all it's variants)
    - SVM
    - ANN
  - Boosting and Extreme Gradiant Boosting for Classification and Regression

all about bias-variance tradeoff
what are adv disadv of these models
which one is the best fit for my use case

- Unsupervised Learning
  - Clustering
    - K-means
    - EM

wie bilde ich meine objekte in den vektorraum
wenn die abbildung schlecht ist, dann versagt jegliches model

1. Introduction and kNN
2. Model Evaluation
3. Linear Regression
4. Advanced Regression
5. Optimal, Gaussian, NB Classifier
6. Decision Trees
7. SVM
8. (Artificial Neural Networks)
9. Boosting
10. XGBoost
11. Partitioning Clustering
12. GMM and EM

SVM: was macht der kernel? prinzip des kernel tricks verstanden haben
ensemble learning: bagging parallel und dann zusammenfügen durch z.b. majority vote oder durchschnittswert
boosting sequential, weitere modelle verbessern vorheriges ergebnis
stacking und blending sind bagging verfahren: paralleles training, blending ein schritt weiter als nur bagging (gewichtung und durchschnitt),
stacking trainiert ein weiteres modell, was die gewichtung pro datensatz trainiert und optimiert
blending und stacking nicht so populär, weil wenn man genug decision trees hat, dann hat das ähnlichen effekt

bagging < bagging + blending/stacking < boosting
blending/stacking nicht viel verwendung, da erhöhte komplexität aber boosting inhärent so viel besser

wenn ein datenset eine klassenimbalanz hat und eine stark ungleiche verteilung von den klassen herrscht, dann wird kein verfahren so richtig funktionieren, da es sie wenigen instanzen von seltenen klassen schwer fassen kann
-> verfahren scheitern

Summary of Core Concepts

- Supervised vs. Unsupervised Learning
- Generalization – Underfitting vs. Overfitting and the Bias-Variance-Tradeoff
- Regularization – Controlling Overfitting

ridge, lasso, elastic net (essentially penalizes large values for params)
inherent controlling via parameters of the given model
ensemble learning - e.g. shallow decision tree but many of them
i.e. small steps to control bias-variance

- Ensemble Learning
- Evaluation Metrics and how to compute them
- Hyperparameters and how to tune them

many models have default params that make no sense, always need to tune them
e.g. decision tree without tuning would massively go into overfitting
vs learning rate which has a sensible init value

Butterflies you should be able to recognize


01 Tagpfauenauge


02 Hauchel Bläuling


03 Schachbrett


04 Zitronenfalter


05 Schwalbenschwanz


06 Aurorafalter


07 Kleiner Fuchs


08 Kaisermantel


09 Taubenschwänzchen


10 Trauermantel


11 Admiral


12 C-Falter

Thank you for your active participation

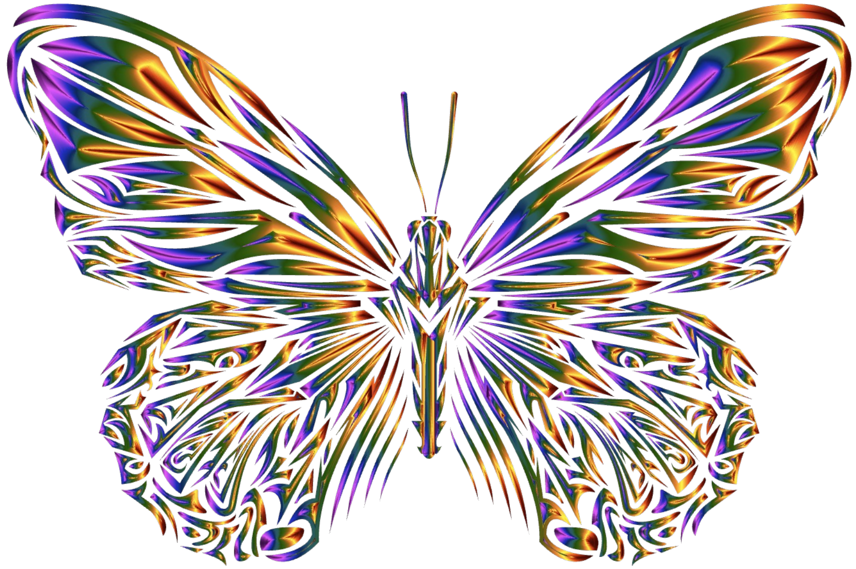

Photo by David Clode on Unsplash