

Requirements Engineering

RE für Data Science & AI

RE für Data Science & AI

AI Projects...

NEWSLETTERS • CFO DAILY

MIT report: 95% of generative AI pilots at companies are failing



By Sheryl Estrada

Senior Writer And Author Of CFO Daily

August 18, 2025, 6:54 AM ET



GETTY IMAGES

Source: <https://fortune.com/2025/08/18/mit-report-95-percent-generative-ai-pilots-at-companies-failing-cfo/>

KI-Projekte scheitern oft in der Pilotphase

Von Tillmann Neuscheler 11.06.2026, 11:44 Lesezeit: 3 Min.



Immer mehr Unternehmen stellen ihrer Belegschaft KI-Tools zur Verfügung.
Große Produktivitätsfortschritte sind jedoch bislang noch selten.

Quelle: <https://www.faz.net/aktuell/wirtschaft/unternehmen/mckinsey-warum-ki-projekte-in-der-pilotphase-scheitern-accq-200903489.html>

RE für Data Science & AI

Überblick

- **MIT Research (2025)** estimates that 95% of generative AI pilots fail, often due to brittle workflows and misaligned expectations. This is significantly higher than the failure rate of traditional IT projects, with misalignment between business goals and technical execution being a primary cause.
- **RAND Corporation (2024)** found that more than 80% of AI projects fail to reach meaningful production deployment, which is exactly twice the failure rate of IT projects without AI components. The root causes include misaligned expectations, poor data readiness, and lack of proper collaboration between business and technical teams.
- **DeepSense.ai (2025)** reports that up to 85% of AI initiatives fail, with most never reaching production. The primary cause is misalignment between business goals, data readiness, and technical execution.
- **S&P Global (2025)** data shows that 42% of companies scrapped most of their AI initiatives, with misaligned expectations and lack of cross-functional collaboration being key factors.
- **PMI (Project Management Institute)** highlights that 70-80% of AI projects fail, often due to vague objectives or misaligned expectations regarding return on investment (ROI).

Was lernen wir daraus?

RE für Data Science & AI

Aufgabe - Aus Fehlern lernen

12 December 2024

Why Most AI Projects Fail: 10 Mistakes to Avoid

By Ron Schmelzer and Kathleen Walch

Why do so many AI projects crash and burn? Explore the 10 critical missteps—from neglecting data quality to overpromising—and learn how to avoid them.

- Lesen Sie folgenden Blogpost: <https://www.pmi.org/blog/why-most-ai-projects-fail>
 - Diskutieren Sie zwei Gründe dieser Gründe.
 - Suchen oder überlegen Sie sich Beispiele dafür.
 - Stellen Sie Ihre Ergebnisse vor. Was sind Ihre Erfahrungen?
-
- Zeitansatz: 10 Min. 5 Min Präsentation

RE für Data Science & AI

- Warum scheitern die meisten KI-Projekte?
- Aufgrund **unklarer und unpassender Anforderungen!**

RE für Data Science & AI

DataScience und AI

Aspekt	Data Science-Produkte	KI-Produkte
Ziel	Daten analysieren und Erkenntnisse gewinnen (z. B. Berichte, Dashboards).	Autonome Entscheidungen treffen oder Vorhersagen generieren (z. B. Chatbots, autonome Fahrzeuge).
Output	Statische oder interaktive Analysen (z. B. "Welche Kunden kaufen am meisten?").	Dynamische Aktionen (z. B. "Empfehle dem Nutzer Produkt X" oder "Steuere die Drohne um Hindernis Y").
Technische Basis	Statistische Methoden, Deskriptive Analytik, Visualisierung	Maschinelles Lernen (ML), Deep Learning, NLP, Computer Vision
Datenverarbeitung	Batch-Verarbeitung (z. B. tägliche Berichte) oder Ad-hoc-Analysen .	Echtzeit-Verarbeitung (z. B. Fraud Detection in Millisekunden).
Menschliche Rolle	Mensch interpretiert die Daten (z. B. Business Analyst).	Mensch interagiert mit dem System (z. B. Nutzer, die KI-Entscheidungen hinterfragen).
Beispiele	- Sales Dashboards (Power BI) - Kundensegmentierung - A/B-Test-Auswertung	- Chatbots (z. B. Customer Service) - Autonome Fahrzeuge - Kredit-Scoring-Systeme - Empfehlungssysteme (Netflix, Amazon)

RE für Data Science & AI

Wie kann Requirements Engineering helfen, DataScience- oder KI-Projekte erfolgreich zum Abschluss zu bringen?

RE für Data Science & AI


Anforderungen an KI-Systeme sind nicht statisch

- **Dynamischer Charakter:** Modelle entwickeln sich mit den Daten weiter; Anforderungen können sich ändern.
- **Datenabhängigkeit:** Qualität, Verzerrungen und Verfügbarkeit wirken sich direkt auf den Erfolg aus.
- **Ethische/rechtliche Einschränkungen:** DSGVO, Fairness und Transparenz.

RE für Data Science & AI

Anforderungen an KI-Systeme sind nicht statisch


- **Herkömmliche Software:** Feste Regeln, vorhersehbare Ergebnisse.
- **KI-Systeme:** Die Modellleistung verschlechtert sich bzw. verbessert, die Daten zudem auch.
- Die Anforderungen können sich ändern (z. B. neue Datenquellen, Nutzer-Feedback).
- Beispiel: Systeme im Bereich Predictive Maintenance passen sich an neue Sensordaten an.



RE für Data Science & AI

Unterschiede zwischen traditionellen Systemen und KI-gestützten Systemen

- Traditionell: Feste Schwellenwerte für Wartungswarnungen.
- KI-gestützt: Kontinuierliches Lernen aus Sensordaten; Warnungen passen sich im Laufe der Zeit an.



RE für Data Science & AI

Warum RE für KI wichtig ist

KI $\neq$ traditionelle Software:

- Anforderungen sind dynamisch (Modelle verbessern sich bzw. verschlechtern sich mit den Daten).
- Nicht-funktionale Anforderungen (z. B. Fairness, Erklärbarkeit) sind entscheidend.

RE für Data Science & AI

Warum ist RE im Bereich KI/Data Science anders?

Herausforderung	Beispiel	Lösungsansatz
Mehrdeutige Ziele	„Kundenzufriedenheit verbessern“ → Was bedeutet das?	Definieren Sie messbare Kennzahlen (z. B. „Kundenabwanderung um 15 % reduzieren“).
Datenabhängigkeiten	Die Modellleistung hängt von der Datenqualität und möglichen Verzerrungen ab.	Datenanforderungen im Vorfeld dokumentieren.
Ethische/rechtliche Risiken	Einhaltung der DSGVO, Verringerung von Verzerrungen.	Ethik-Checklisten in die RE einbeziehen.
Dynamische Anforderungen	Die Bedürfnisse der Nutzer entwickeln sich weiter, während das Modell lernt.	Iterative Aktualisierungen einplanen.

RE für Data Science & AI

Kernunterschiede zu klassischen/agilen Modellen

Aspekt	Klassisches RE	Agiles RE	RE für KI/Datenprodukte
Fokus	Funktionale Anforderungen	Flexibilität, schnelle Anpassung	Datenqualität, Modellperformance, Ethik
Anforderungsquellen	Stakeholder-Interviews, Use Cases	User Stories, Backlog Refinement	Datenanalyse, Kontextanalyse, Experimente
Validierung	Abnahme durch Stakeholder	Inkrementelle Tests	Modell-Evaluation, Bias-Tests, Datenaudits
Dokumentation	Statische Spezifikationen	Lebendige Dokumentation (z. B. Backlog)	Daten-Lineage, Modellversionierung
Iteration	Phasenbasiert (z. B. Wasserfall)	Sprint-basiert (Scrum)	Datengetrieben, modellzentriert

**Aufgrund der Aktualität fokussieren wir uns ab hier auf
KI. Bezüge zu DataScience werde ich immer wieder
einsteuern.**

RE für Data Science & AI

Warum scheitern KI-Projekte?

Mehrdeutige Ziele

- „Kundenzufriedenheit verbessern“ → Was bedeutet das?
- Definieren Sie messbare Kennzahlen (z. B. „Kundenabwanderung um 15 % reduzieren“).

Datenabhängigkeiten

- Die Modellleistung hängt von der Datenqualität und möglichen Verzerrungen ab.
- Datenanforderungen im Vorfeld dokumentieren.

Ethische/rechtliche Risiken

- Einhaltung der DSGVO, Verringerung von Verzerrungen.
- Ethik-Checklisten in die RE einbeziehen.

Dynamische Anforderungen

- Die Bedürfnisse der Nutzer entwickeln sich weiter, während das Modell lernt.
- Iterative Aktualisierungen einplanen.

RE für Data Science & AI

Daten-Lineage

Daten-Lineage bezeichnet die Nachverfolgung von Daten durch deren gesamten Lebenszyklus.


Aspekt	Beschreibung
Herkunft	Woher stammen die Daten? Welche Quellen wurden verwendet?
Transformationen	Welche Prozesse, Berechnungen oder Änderungen durchliefen die Daten?
Abhängigkeiten	Welche Systeme, Pipelines oder Modelle hängen voneinander ab?
Zielorte	Wohin werden die Daten weitergeleitet oder gespeichert?

Warum ist Ihrer Meinung nach Data-Lineage wichtig bzw. wird wichtiger?

Vorgehensmodelle für RE im Bereich KI

CRISP-DM


- 6 Phasen: Geschäftsverständnis → Bereitstellung.
- Iterativ: Nicht linear – Phasen werden bei Bedarf wiederholt.
- Warum dies bei KI funktioniert: Der Fokus liegt auf der Abstimmung zwischen Daten und Geschäftsanforderungen.
- ABER:
 - Es gibt keine Überwachungs- und Wartungsphase, in der bereitgestellte KI-Modelle wie LLMs überwacht und bei Bedarf angepasst werden.
 - Zudem sind die Teamrollen nicht klar



Vorgehensmodelle für RE im Bereich KI

Team Data Science Process (TDSP)

- „If you combine Scrum and CRISP-DM, you will get something that looks like Microsoft’s Team Data Science Process.“ (DataSciencePM, 2026)
- Vier Komponenten
 - Definition des Data-Science-Lebenszyklus
 - standardisierte Projektstruktur
 - empfohlene Infrastruktur und Ressourcen
 - empfohlene Tools und Hilfsprogramme
- Klare Rollendefinition:
 - Solution Architekt
 - Projektmanager/Projekt Lead
 - Data Engineer
 - Data Scientist
 - Anwendungsentwickler




Quelle: <https://www.datascience-pm.com/tdsp/>

Vorgehensmodelle für RE im Bereich KI

MLOps

- Kombination von Machine Learning & DevOps
- Berücksichtigung des Lebenszyklus (Training, Deployment & Monitoring)
- Fokus auf Automatisierung
- Lebenszyklusphasen
 1. Datenvorbereitung
 2. Modelltraining
 3. Deployment
 4. Monitoring
- Vorteile
 - Teamzusammenarbeit
 - Stabilität
 - Effizienz
 - Impact



Bildquelle: <https://media.geeksforgeeks.org/wp-content/uploads/20260328144911382188/What-is-MLOps.webp>


MLOps

- MLOps (Machine Learning Operations)
- Industrialisierung von KI-Modellen durch Automatisierung und Continuous Delivery.
- **Komponenten:**
 - CI/CD für Modelle: Automatisierte Pipelines für Training, Testing, Deployment.
 - Monitoring: Überwachung von Modellperformance und Datenqualität.
 - Versionierung: Modell- und Datenversionierung (z. B. MLflow, DVC).
 - Feedback Loops: Automatisierte Retraining-Trigger bei Performance-Verschlechterung.

Vorgehensmodelle für RE im Bereich KI

CRISP-ML(Q)

- Anpassung des CRISP-DM-Modells
- 6 Phasen: Geschäftsverständnis → Überwachung und Wartung.
- Iterativ: Nicht linear – Phasen werden bei Bedarf wiederholt.



@visenger



Vorgehensmodelle für RE im Bereich KI

Business- und Datenverständnis

- Ein Erfolgsfaktor für viele KI-Projekte ist ein fundiertes Verständnis des Geschäfts, des organisatorischen Kontexts sowie der Datenquellen und -strukturen.
- **Ziel:** Definition von Geschäftszielen, Leistungskennzahlen (KPIs) und Erfolgskennzahlen.
- **Ergebnis:** Problemstellung, die die Ziele des KI-Projekts mit den organisatorischen Anforderungen in Einklang bringt.
- **Wichtige Überlegungen:** Beziehen Sie die Stakeholder frühzeitig ein, um die Abstimmung mit der übergeordneten Geschäftsstrategie und den Anforderungen sicherzustellen.

(basierend auf (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

Vorbereitung der Daten

- Daten bilden die Grundlage für die meisten KI-Initiativen. Ein umfassendes Verständnis der Daten sowie deren Erforschung und Analyse sind entscheidend für die weiteren Schritte im Prozess.
- **Ziel:** Erfassung, Überprüfung und Analyse verfügbarer Datenquellen, um deren Qualität und Relevanz zu beurteilen.
- **Ergebnis:** Identifizierung von Lücken, Ausreißern und Mustern in den Daten.
- **Wichtige Überlegungen:** Einsatz von Visualisierungstechniken und statistischen Analysen zur Gewinnung von Erkenntnissen.

(basierend auf (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

Aufbereitung der Daten

- Die Datenaufbereitung ist von entscheidender Bedeutung, stellt jedoch oft die zeitaufwendigste Phase dar.
- **Ziel:** Bereinigung, Transformation und Formatierung von Daten für KI-Anwendungen.
- **Ergebnis:** Ein gut strukturierter Datensatz, der für das Modelltraining und die Modellbewertung bereit ist.
- **Wichtige Aspekte:** Behandlung fehlender Werte, Kodierung kategorialer Variablen und Normalisierung der Daten. Sicherstellung der Reproduzierbarkeit durch Dokumentation.

(basierend auf (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

Modellierungsphase

- Die Modellierungsphase umfasst die Auswahl und Anwendung von Algorithmen des maschinellen Lernens.
- **Ziel:** Bewertung/Erstellung von Modellen, die das definierte Geschäftsproblem effektiv lösen.
- **Ergebnis:** In Frage kommende Modelle, die anhand geeigneter Kennzahlen bewertet wurden.
- **Wichtige Überlegungen:** Experimentieren Sie mit verschiedenen Modellen/Algorithmen, Parametern und Merkmalen, um die Leistung und Anwendbarkeit zu optimieren.

(based on (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

Evaluierung des Modells

- Die Modellbewertung ist entscheidend, um sicherzustellen, dass die Lösung den geschäftlichen und technischen Erwartungen entspricht.
- **Ziel:** Validierung der Modellleistung anhand von Trainings-, Validierungs- und Testdatensätzen.
- **Ergebnis:** Gründlich bewertetes Modell, bereit für den Einsatz oder die Weiterentwicklung.
- **Wichtige Überlegungen:** Gehen Sie über die Genauigkeit hinaus; berücksichtigen Sie Fairness, Interpretierbarkeit und Robustheit. Beziehen Sie die Beteiligten ein, um die Ergebnisse im Hinblick auf die Geschäftsziele zu überprüfen.

(based on (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

Monitoring und Wartung

- Die Bereitstellung markiert den Übergang des Modells von der Evaluierungs- und Entwicklungsphase in die Produktionsphase.
- **Ziel:** Integration des Modells in Produktionssysteme für den Einsatz in der Praxis.
- **Ergebnis:** Funktionsfähiges, live betriebenes KI-System.
- **Wichtige Überlegungen:** Kontinuierliche Überwachung der Leistung, um Konzeptdrift, Skalierbarkeit und betriebliche Probleme anzugehen.

(basierend auf (Bhakti, 2024))

Vorgehensmodelle für RE im Bereich KI

CRISP-ML(Q) - Zusammenfassung

- Geeignet
 - Ausgelegt auf langfristigen Betrieb
 - Qualitätssicherung und Monitoring (Echtzeit-Anwendung) wichtig sind
 - Expertise im Team/Organisation im Bereich MLOps und QA besteht
 - Regulatorische Anforderungen berücksichtigt werden müssen
 - Ausreichend Budget zur Verfügung steht
- Nicht/weniger geeignet
 - Nicht für einfache Projekte geeignet
 - Budgets begrenzt sind
 - Agile Methoden bevorzugt werden
 - Kein Monitoring notwendig ist
- CRISP-DM ist der defacto Standard, CRISP-ML(Q) ist neu und noch nicht so standardisiert

Vorgehensmodelle für RE im Bereich KI

Vergleich von Vorgehensmodellen

Modell	Phasen	Stärken	Schwächen
CRISP-DM	Business Understanding, Data Understanding, Modeling, Evaluation, Deployment	Branchenstandard, flexibel, iterativ	Keine Monitoring-Phase, fehlende QA
CRISP-ML(Q)	Business & Data Understanding, Data Preparation, Modeling, Evaluation, Deployment, Monitoring & Maintenance	QA-Methoden , Monitoring-Phase, industrie-neutral	Komplexer als CRISP-DM
TDSP	Business Understanding, Data Acquisition, Modeling, Deployment, Customer Acceptance	Agile Integration, Team-Kollaboration	Weniger Fokus auf QA
MLOps	CI/CD für Modelle, Monitoring, Versionierung, Feedback Loops	Automatisierung, Skalierbarkeit	Erfordert technische Infrastruktur

Vorgehensmodelle für RE im Bereich KI

Stakeholder

- Geschäftsbereiche/Management: Ziele definieren (z. B. „Umsatz steigern“).
- Data Scientists/AI Engineers: Modelle erstellen; benötigen bereinigte Daten.
- IT-Teams: Systeme bereitstellen/integrieren.
- Anwender: Feedback geben; dem System vertrauen.
- Ethik: Einhaltung der Vorschriften sicherstellen.

Take aways

- Viele Projekte im Initiativen im Bereich KI scheitern oder werden nicht erfolgreich abgeschlossen.
- Dies liegt einerseits an unklaren Zielen aber auch an fehlendem RE in den Initiativen
- Data Science & KI-Projekte erfordern andere Vorgehensweisen als traditionelle Software
- Am Markt entwickeln sich aktuell verschiedene Vorgehensmodelle für die Anwendung im Bereich KI & DataScience
- Einige dieser Modelle sind eher für den Betrieb und im Einsatz in regulierten Bereichen geeignet, andere sind eher leichtgewichtig und für agile Umgebungen sinnvoll
- Die Einbindung von Stakeholdern ist gerade im Bereich KI & DataScience ein Faktor, der häufig zu wenig berücksichtigt wird.